

**PENERAPAN RAG DIGITAL TWIN
FRAMEWORK UNTUK PREDIKSI KADAR
GLUKOSA DARAH PADA PASIEN DIABETES
TIPE 2**

Proposal Tugas Akhir

Oleh

**Daffari Adiyatma
18222003**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Desember 2025**

LEMBAR PENGESAHAN

PENERAPAN RAG DIGITAL TWIN FRAMEWORK UNTUK PREDIKSI KADAR GLUKOSA DARAH PADA PASIEN DIABETES TIPE 2

Proposal Tugas Akhir

Oleh

**Daffari Adiyatma
18222003**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 6 Desember 2025

Pembimbing 1

Pembimbing 2

Prof. Dr. Ir. Suhono Harso Supangkat, Ir. Devi Willieam Anggara S.T., M.Phil.,
M. Eng. Ph.D
NIP. 196212031988111001 No Peg. 124110055

DAFTAR ISI

DAFTAR GAMBAR	v
DAFTAR TABEL	vi
DAFTAR KODE	vii
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	4
I.4 Batasan Masalah	5
I.5 Metodologi	5
I.5.1 Studi Literatur	5
I.5.2 Analisis Kebutuhan dan Perancangan Sistem	6
I.5.3 Implementasi Sistem	6
I.5.4 Validasi dan Evaluasi	7
II STUDI LITERATUR	8
II.1 Konsep Digital Twin	8
II.2 Digital Twin dalam Bidang Kesehatan	10
II.3 Manajemen Diabetes dan Pendekatan Digital	12
II.4 Faktor-Faktor yang Mempengaruhi Kadar Gula Darah	14
II.4.1 Asupan Nutrisi dan Karbohidrat	14
II.4.2 Aktivitas Fisik	15
II.4.3 Faktor Psikologis dan Stres	15
II.5 Metode Machine Learning untuk Prediksi Kadar Glukosa	15
II.6 Retrieval-Augmented Generation (RAG) Framework	17
II.7 Penelitian Terkait	19
II.8 Tantangan Implementasi di Indonesia	21
III ANALISIS MASALAH	23
III.1 Analisis Kondisi Saat Ini	23
III.2 Analisis Kebutuhan	25
III.2.1 Identifikasi Masalah Pengguna	25
III.2.2 Kebutuhan Fungsional	26
III.2.3 Kebutuhan Nonfungsional	27

III.3 Analisis Pemilihan Solusi	28
III.3.1 Alternatif Solusi	28
III.3.2 Analisis Penentuan Solusi	30
IV Desain Konsep Solusi	31
IV.1 Sistem Saat Ini (Before)	31
IV.2 Model Konseptual Solusi (To-Be)	31
IV.3 Perbandingan Sistem Before dan After	33
IV.4 Diagram Use Case	34
IV.4.1 Use Case Aktor Pasien	34
IV.4.2 Use Case Aktor Dokter/Tenaga Medis	35
IV.5 Alur Proses Sistem (BPMN)	36
IV.6 Arsitektur Model Machine Learning	37
IV.7 Arsitektur Retrieval-Augmented Generation (RAG)	38
IV.8 Pemetaan Use Case terhadap FR dan NFR	39
V Rencana Selanjutnya	40
V.1 Rencana Implementasi	40
V.1.1 Persiapan Lingkungan dan Perangkat Pengembangan	40
V.1.2 Persiapan Data	41
V.1.3 Pengembangan Model Prediksi	41
V.1.4 Pembangunan Digital Twin	41
V.1.5 Integrasi Retrieval-Augmented Generation (RAG)	41
V.1.6 Pengembangan Antarmuka dan Visualisasi	42
V.1.7 Dokumentasi dan Penyusunan Laporan	42
V.2 Desain Pengujian dan Evaluasi	42
V.2.1 Verifikasi Sistem	42
V.2.2 Validasi Model Prediksi	42
V.2.3 Evaluasi Integrasi Digital Twin dan RAG	43
V.3 Analisis Risiko dan Mitigasi	43
V.4 Timeline Pengerjaan	43

DAFTAR GAMBAR

II.1	Model konseptual <i>Digital Twin</i> yang menunjukkan keterhubungan antara ruang fisik dan ruang virtual. Diadaptasi dari Grieves dan Vickers (2017).	9
II.2	Arsitektur umum <i>Digital Twin</i> dalam bidang kesehatan yang mengintegrasikan data dari perangkat medis, sensor, dan catatan kesehatan elektronik. Diadaptasi dari Cappon, Facchinetti, dan Sparacino (2024).	10
II.3	Contoh sistem pemantauan kadar glukosa darah berkelanjutan (<i>Continuous Glucose Monitoring</i>) yang digunakan dalam manajemen diabetes. Diadaptasi dari Battelino, Danne, Bergenstal, dkk. (2019).	13
II.4	Arsitektur model <i>Long Short-Term Memory (LSTM)</i> dengan mekanisme <i>attention</i> untuk prediksi kadar glukosa darah jangka pendek. Model ini mengombinasikan lapisan <i>self-attention</i> , unit <i>LSTM</i> , dan lapisan keluaran terhubung penuh untuk memproses deret waktu kadar glukosa. Diadaptasi dari Ghimire, Chen, Schenck, dkk. (2024).	16
II.5	Arsitektur <i>Retrieval-Augmented Generation (RAG)</i> yang terdiri atas dua komponen utama: <i>Retriever</i> untuk mengambil dokumen relevan dari basis pengetahuan eksternal dan <i>Generator</i> untuk menghasilkan keluaran berbasis konteks. Model dilatih secara end-to-end sehingga kedua komponen dapat dioptimalkan bersamaan. Diadaptasi dari Lewis dkk. (2020).	18
III.1	Model konseptual sistem manajemen diabetes konvensional. Sistem saat ini terdiri atas subsistem klinis, pasien, dan perangkat medis dengan aliran data satu arah tanpa integrasi analitik cerdas.	24
IV.1	Model konseptual sistem usulan berbasis <i>Digital Twin</i> dan <i>Retrieval-Augmented Generation</i>	32
IV.2	Diagram <i>use case</i> sistem usulan.	35
IV.3	Diagram BPMN sistem usulan yang mencakup proses input data, prediksi, deteksi risiko, dan validasi medis.	36

IV.4 Pipeline arsitektur model LSTM dengan mekanisme <i>Attention</i> untuk prediksi glukosa.	37
IV.5 Pipeline arsitektur RAG yang menghubungkan hasil prediksi dengan basis pengetahuan medis.	38
V.1 Timeline Pelaksanaan Tugas Akhir (Januari-Mei 2026).	44

DAFTAR TABEL

II.1 Ringkasan penelitian terkait <i>Digital Twin</i> dan prediksi kadar glukosa darah.	20
III.1 Kebutuhan Fungsional Sistem	26
III.2 Kebutuhan Nonfungsional Sistem	28
III.3 Matriks Perbandingan Lima Alternatif Solusi	30
IV.1 Perbandingan Karakteristik Sistem Saat Ini dan Sistem Usulan	34
IV.2 Pemetaan Use Case terhadap Functional Requirements (FR) dan Non-Functional Requirements (NFR).	39
V.1 Analisis Risiko dan Mitigasi	43

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Penyakit diabetes melitus (DM) merupakan salah satu masalah kesehatan global yang paling serius pada abad ke-21. Menurut laporan International Diabetes Federation (IDF) tahun 2024, jumlah penderita diabetes di Indonesia mencapai lebih dari 19 juta orang dan diperkirakan terus meningkat seiring dengan perubahan gaya hidup dan urbanisasi cepat di kawasan Asia Tenggara (International Diabetes Federation 2024). Dari seluruh kasus tersebut, sekitar 90–95% tergolong Diabetes Melitus Tipe 2 (T2DM), yang ditandai dengan resistensi insulin dan penurunan sensitivitas sel terhadap glukosa (World Health Organization 2023). Kondisi ini meningkatkan risiko komplikasi kronis seperti penyakit jantung, gagal ginjal, neuropati, dan kebutaan apabila tidak ditangani dengan manajemen glukosa darah yang baik.

Sebagian besar sistem pengelolaan diabetes di Indonesia masih bersifat reaktif. Data dari Kementerian Kesehatan Republik Indonesia (2019) dan Knowledge Sourcing Intelligence (2020) menunjukkan bahwa sebagian besar kasus diabetes di Indonesia tidak terdiagnosis, dengan hanya sekitar 26% penderita yang mengetahui status penyakitnya. Hal ini sejalan dengan tinjauan sistematis oleh Alkaff dkk. (2021) yang menyimpulkan bahwa sistem kesehatan di Indonesia masih berfokus pada pendekatan kuratif dibandingkan pencegahan. Penggunaan *continuous glucose monitoring* (CGM) dan *insulin pump* telah terbukti membantu pasien dalam memantau kadar glukosa secara *real-time* dan menyesuaikan dosis insulin secara lebih presisi (Battelino, Danne, Bergenstal, dkk. 2019). Selain itu, pendekatan berbasis *machine learning* mulai digunakan untuk memprediksi fluktuasi glukosa darah berdasarkan data historis pasien Woldaregay, Årsand, Walderhaug, dkk. (2019). Teknologi *digital twin*, yang merupakan replika virtual dari kondisi fisiologis pasien, mulai di terapkan dalam manajemen diabetes untuk mensimulasikan respons metabolik pasi-

en terhadap berbagai skenario pengobatan (Bruynseels, Santoni de Sio, dan Hoven 2018).

Selain faktor asupan nutrisi dan aktivitas fisik, faktor psikologis seperti stres juga memegang peranan krusial dalam fluktuasi glukosa darah harian. Kompleksitas hubungan antara variabel fisiologis dan psikologis ini sering menjadi tantangan dalam pemodelan akurasi tinggi (Woldaregay, Årsand, Walderhaug, dkk. 2019). Secara biologis, stres psikologis dapat memicu respons neuroendokrin yang meningkatkan kadar kortisol, yang kemudian berdampak langsung pada peningkatan resistensi insulin dan kenaikan kadar glukosa darah (Hackett dan Steptoe 2017). Oleh karena itu, sistem prediksi yang komprehensif idealnya mengintegrasikan variabel gaya hidup dan kondisi mental untuk menghasilkan rekomendasi yang lebih akurat dan personal. Penelitian terkini oleh Rad dkk. (2024) mengusulkan *framework digital twin* komprehensif berbasis *Personal Health Knowledge Graph* (PHKG) yang mampu mengintegrasikan data dari *Electronic Health Records* (EHR), *wearable devices*, dan *mobile health applications* dengan standar HL7 FHIR. *Framework* ini telah terbukti efektif dalam prediksi glukosa dengan *Root Mean Square Error* (RMSE) 19,83 mg/dL dan mampu memberikan rekomendasi insulin personal serta saran diet yang disesuaikan. Penelitian serupa oleh Zhang dkk. (2024) mengintegrasikan *machine learning* dengan data *multiomic* untuk memprediksi progresi diabetes tipe 2, menunjukkan potensi *digital twin* dalam *personalized medicine*. Cappon, Facchinetto, dan Sparacino (2024) dalam *systematic review* mereka menemukan bahwa meskipun pendekatan *digital twin* menjanjikan, sebagian besar implementasinya masih mengandalkan infrastruktur teknologi yang kompleks dan perangkat medis yang mahal.

Meskipun *framework-framework* tersebut menunjukkan hasil yang menjanjikan, implementasinya menghadapi hambatan signifikan di konteks Indonesia. Pertama, dari sisi infrastruktur digital kesehatan, meskipun pemerintah Indonesia mewajibkan adopsi rekam medis elektronik (EMR) pada akhir 2023, transisi ini masih menghadapi berbagai tantangan teknologi, budaya, dan infrastruktur Harahap dkk. (2024). Studi yang melibatkan 9 provinsi di Indonesia menunjukkan variasi signifikan dalam kesiapan teknologi informasi dan komunikasi (TIK) antarfasilitas kesehatan, dengan perlunya peningkatan sumber daya manusia (SDM), infrastruktur, perangkat keras, dan optimalisasi sistem informasi untuk mencapai kematangan TIK (Aisyah dkk. 2024). Sebagian besar fasilitas kesehatan belum menyediakan akses terintegrasi ke rekam kesehatan pasien dengan pertukaran informasi yang masih bersifat satu arah, dari fasilitas kesehatan ke pasien (Harahap, Handayani, dan Hidayanto 2023).

Kedua, dari sisi keterjangkauan perangkat monitoring, *framework* Rad dkk. (2024) mengasumsikan ketersediaan *Continuous Glucose Monitoring* (CGM) untuk data *real-time*. Namun, studi Ramadaniati dkk. (2024) menunjukkan bahwa CGM memerlukan biaya setara satu bulan gaji untuk membeli *reader* dan dua bulan gaji untuk pasokan sensor bulanan, dengan upah minimum harian di Indonesia sekitar US\$3,50. Hal ini menyebabkan CGM tidak terjangkau bagi mayoritas pasien dia-betes di Indonesia, terutama mengingat bahwa untuk membeli pasokan pengobatan selama 30 hari (*insulin pen*, jarum pen, dan monitoring mandiri berdasarkan 5 kali tes per hari), pasien perlu menghabiskan hampir seluruh gaji bulanan mereka.

Ketiga, kompleksitas teknis *framework* Rad dkk. (2024) yang memerlukan pengembangan *ontology* berbasis HL7 FHIR, implementasi GLAV (*Global-Local as View*) *framework* untuk integrasi data, dan penggunaan *Conditional Random Fields* untuk *mapping* data, membutuhkan *expertise* spesialis yang belum banyak tersedia di Indonesia. Penelitian menunjukkan bahwa di negara berkembang, adopsi EMR berbeda karena beberapa faktor termasuk infrastruktur sistem kesehatan, tingkat pendidikan dan pelatihan tenaga kesehatan, pendanaan, dan penerimaan budaya terhadap EMR, sehingga di banyak negara berkembang, penggunaan EMR belum sepenuhnya diterapkan (Abodunrin, Akande, dan Osagbemi 2020).

Dari uraian tersebut, tampak bahwa pengelolaan diabetes di Indonesia masih menghadapi hambatan dalam pemanfaatan teknologi prediktif yang efisien dan terjangkau. Kondisi ini menunjukkan adanya kesenjangan antara potensi teknologi *digital twin* yang telah terbukti efektif di negara maju dengan kemampuan implementasinya di Indonesia. Diperlukan studi lebih lanjut untuk memahami bagaimana konsep *digital twin* dapat disesuaikan dengan keterbatasan infrastruktur, biaya, serta sumber daya lokal sehingga mampu memberikan manfaat nyata dalam konteks sistem kesehatan nasional.

I.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, permasalahan utama dalam tugas akhir ini adalah kesenjangan antara kebutuhan manajemen diabetes yang komprehensif (menca-kup aspek fisik dan psikologis) dengan keterbatasan infrastruktur kesehatan di Indo-nesia yang menghambat penerapan teknologi *digital twin* konvensional. Pasien dan tenaga medis memerlukan alat bantu yang tidak hanya memprediksi angka, tetapi juga mampu mensimulasikan dampak keputusan harian dan memberikan rekomen-dasi yang kontekstual.

Berdasarkan permasalahan tersebut, rumusan masalah dalam tugas akhir ini adalah:

1. Bagaimana memformulasikan arsitektur sistem *digital twin* yang disederhanakan agar dapat beroperasi menggunakan data pemantauan mandiri (*self-monitoring*) yang mencakup variabel fisik (makanan, aktivitas) dan psikologis (stres), tanpa ketergantungan pada sensor medis kompleks?
2. Bagaimana mengembangkan model cerdas yang tidak hanya memprediksi kadar glukosa darah, tetapi juga mampu mensimulasikan dampak perubahan pola makan, aktivitas fisik, dan tingkat stres terhadap kondisi pasien (*what-if analysis*)?
3. Bagaimana mekanisme pemberian rekomendasi keputusan dan penjelasan klinis yang relevan untuk membantu pasien menentukan aksi mitigasi yang tepat berdasarkan hasil prediksi sistem?
4. Bagaimana validasi performa sistem dalam merepresentasikan kondisi fisiologis pasien dan akurasi rekomendasi yang dihasilkan dibandingkan dengan standar referensi yang ada?

I.3 Tujuan

Tujuan umum penelitian ini adalah mengeksplorasi dan mengembangkan pendekatan *digital twin* berbasis data simulatif dan pemantauan mandiri untuk prediksi serta simulasi kadar glukosa darah, yang dirancang khusus untuk mendukung pengambilan keputusan klinis di lingkungan dengan sumber daya terbatas.

Secara khusus, tujuan penelitian ini meliputi:

1. Merumuskan kebutuhan dan desain konseptual sistem *digital twin* yang disederhanakan yang mengakomodasi input data harian manual (*logbook*) untuk variabel asupan karbohidrat, dosis insulin, aktivitas fisik, dan tingkat stres.
2. Mengembangkan modul prediktif berbasis pembelajaran mesin (seperti LSTM atau *Random Forest*) yang mampu menjalankan simulasi skenario perubahan gaya hidup untuk memprediksi respon glukosa tubuh.
3. Mengimplementasikan modul *Retrieval-Augmented Generation* (RAG) yang menghubungkan hasil prediksi/simulasi dengan basis pengetahuan medis untuk menghasilkan penjelasan klinis dan rekomendasi aksi yang personal.
4. Melakukan validasi terhadap akurasi prediksi sistem menggunakan metrik evaluasi standar (RMSE, MAE, *Clarke Error Grid*) serta mengevaluasi relevansi rekomendasi keputusan yang dihasilkan.

I.4 Batasan Masalah

Penelitian ini dibatasi oleh hal-hal berikut:

1. Sistem tidak melibatkan perangkat keras, sensor IoT, atau integrasi dengan sistem EHR yang ada.
2. Fokus penelitian adalah pada pengembangan dan pengujian sistem *digital twin* berbasis perangkat lunak dengan pendekatan pembelajaran mesin langsung, tanpa implementasi *Personal Health Knowledge Graph*.
3. Model mencakup prediksi kadar glukosa berdasarkan variabel pendukung utama yaitu asupan karbohidrat, dosis insulin, aktivitas fisik, dan tingkat stres subjektif (diperoleh melalui *self-monitoring*), tanpa melibatkan faktor genetik atau data *multiomic* yang kompleks.
4. Evaluasi dilakukan terhadap performa sistem dalam skenario simulatif sebagai *proof-of-concept*, bukan pada uji klinis langsung dengan pasien nyata.
5. Sistem yang dikembangkan berfokus pada satu *use case* utama yaitu prediksi glukosa darah, tidak mencakup optimasi insulin atau rekomendasi *meal planning*.

I.5 Metodologi

Tahapan metodologi dirancang untuk memastikan proses penelitian berjalan secara sistematis, mulai dari pengumpulan informasi awal hingga validasi hasil prediksi. Metodologi penelitian ini terdiri dari lima tahap utama:

I.5.1 Studi Literatur

Melakukan kajian pustaka terhadap konsep *digital twin*, pengelolaan penyakit diabetes, serta penelitian terdahulu terkait model simulatif dan prediktif. Sumber literatur berasal dari jurnal ilmiah bereputasi seperti IEEE Xplore, ScienceDirect, *Nature Digital Medicine*, dan *Journal of Personalized Medicine*. Pencarian literatur dilakukan dengan kata kunci “*digital twin diabetes*”, “*glucose prediction machine learning*”, “*diabetes simulation model*”, “*simplified digital twin framework*”, dan kombinasi kata kunci terkait.

Literatur yang dikumpulkan kemudian dikelompokkan berdasarkan tema: (a) konsep dan arsitektur *digital twin* dalam kesehatan, dengan fokus pada *framework state-of-the-art* seperti Rad dkk. (2024) dan Zhang dkk. (2024); (b) metode prediksi glukosa darah menggunakan *machine learning* dan *deep learning*; (c) dataset diabetes yang tersedia secara publik; (d) metrik evaluasi sistem prediktif kesehatan; dan (e)

tantangan implementasi teknologi kesehatan digital di negara berkembang.

I.5.2 Analisis Kebutuhan dan Perancangan Sistem

Menentukan kebutuhan fungsional sistem *digital twin* yang disederhanakan, dengan fokus pada:

- **Pengelolaan data simulatif:** Kemampuan untuk membaca, memproses, dan menyimpan data dari dataset publik dalam format yang konsisten.
- **Modul preprocessing:** Pembersihan data, normalisasi, dan *feature engineering* untuk persiapan *training* model.
- **Modul prediksi:** Implementasi model pembelajaran mesin untuk prediksi glukosa darah.
- **Modul evaluasi:** Perhitungan metrik akurasi dan visualisasi hasil prediksi.

Mendesain arsitektur sistem yang terdiri dari tiga komponen utama yang disederhanakan:

1. **Data Management Module:** Modul untuk *loading* dan *preprocessing* data dari dataset publik (OhioT1DM atau UVA/Padova), tanpa perlu integrasi dengan sistem EHR atau sensor *real-time*.
2. **Simplified Patient Digital Model:** Representasi pasien berbasis *feature vector* yang berisi variabel-variabel penting (*glucose history*, *carbohydrate intake*, *insulin dosage*, *physical activity*, dan *stress level*) tanpa menggunakan *knowledge graph*.
3. **Prediction Engine:** Model pembelajaran mesin (LSTM atau *Random Forest*) yang dilatih untuk memprediksi kadar glukosa darah berdasarkan data historis, dengan fokus pada efisiensi komputasi dan kemudahan *deployment*.

I.5.3 Implementasi Sistem

Mengembangkan sistem berbasis Python dengan menggunakan *framework* dan *library* berikut:

- **Data processing:** Pandas, NumPy untuk manipulasi data.
- **Machine learning:** Scikit-learn untuk model tradisional (*Random Forest*, SVM).
- **Deep learning:** TensorFlow atau PyTorch untuk model LSTM/GRU.
- **Visualisasi:** Matplotlib, Seaborn untuk visualisasi hasil prediksi.
- **Evaluasi:** Implementasi metrik RMSE, MAE, dan *Clarke Error Grid Analysis*.

Tahapan pengembangan model meliputi:

1. Eksplorasi dan analisis dataset untuk memahami distribusi dan karakteristik data.
2. *Feature engineering* untuk mengekstrak fitur-fitur yang relevan.
3. Pembagian data menjadi *training*, *validation*, dan *testing set*.
4. Pelatihan model dengan *hyperparameter tuning*.
5. Evaluasi performa model pada *test set*.

I.5.4 Validasi dan Evaluasi

Melakukan pengujian model dengan metrik evaluasi berikut:

- ***Root Mean Square Error (RMSE)***: Mengukur rata-rata deviasi prediksi dari nilai aktual.
- ***Mean Absolute Error (MAE)***: Mengukur rata-rata absolut *error*.
- ***Clarke Error Grid Analysis (EG)***: Mengukur *clinical accuracy* dengan meng-kategorikan *error* berdasarkan *risk*.

BAB II

STUDI LITERATUR

II.1 Konsep Digital Twin

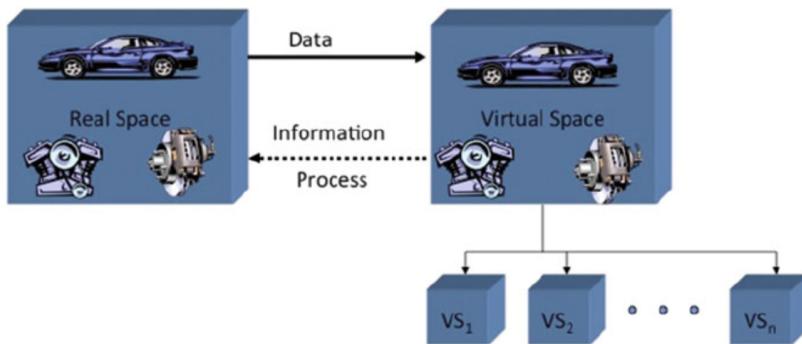
Konsep *Digital Twin* (DT) pertama kali diperkenalkan oleh Grieves dan Vickers (2017) sebagai bagian dari paradigma *Product Lifecycle Management* (PLM). DT didefinisikan sebagai representasi digital dari suatu entitas fisik yang secara dinamis diperbarui melalui aliran data dua arah antara dunia nyata (*real space*) dan dunia virtual (*virtual space*). Melalui keterhubungan tersebut, sistem DT dapat melakukan pemantauan, simulasi, serta prediksi terhadap perilaku dan kondisi objek fisik secara berkelanjutan.

Secara umum, arsitektur DT terdiri dari tiga komponen utama:

1. **Physical Entity**, yaitu objek nyata yang menjadi sumber data (contohnya mesin industri, kendaraan, atau pasien dalam konteks medis);
2. **Digital Representation**, yaitu model virtual yang merepresentasikan perilaku dan karakteristik objek fisik;
3. **Data Connection Layer**, yaitu lapisan penghubung yang mengintegrasikan aliran data dua arah antara model digital dan entitas fisik, baik untuk pembauran kondisi maupun umpan balik hasil simulasi.

Contoh arsitektur dasar DT dapat dilihat pada Gambar II.1. Diagram tersebut merupakan model konseptual awal yang dikembangkan oleh Grieves untuk menjelaskan hubungan dua ruang antara sistem fisik dan sistem virtual pada konteks PLM.

Gambar II.1 menampilkan dua ruang utama, yaitu *Real Space* dan *Virtual Space*. Pada bagian *Real Space*, terdapat entitas fisik yang menghasilkan data melalui sensor dan sistem pengukuran. Data tersebut dikirim ke *Virtual Space* untuk memperbaiki model digital secara berkelanjutan. Sebaliknya, hasil simulasi dan analisis dari model virtual dikirim kembali ke sistem fisik sebagai informasi atau proses kontrol.



Gambar II.1 Model konseptual *Digital Twin* yang menunjukkan keterhubungan antara ruang fisik dan ruang virtual. Diadaptasi dari Grieves dan Vickers (2017).

Siklus pertukaran data ini menciptakan hubungan dua arah yang memungkinkan DT berfungsi sebagai sistem adaptif dan prediktif (Grieves dan Vickers 2017).

Menurut Bruynseels, Santoni de Sio, dan Hoven (2018), keunggulan utama DT terletak pada kemampuannya untuk menghasilkan *living model*, yakni model yang tidak hanya merepresentasikan kondisi statis suatu sistem, tetapi juga mampu berevolusi mengikuti dinamika data aktual. Hal ini menjadikan DT sangat potensial dalam pengembangan sistem prediktif di berbagai bidang, termasuk manufaktur, pertahanan, energi, dan kesehatan.

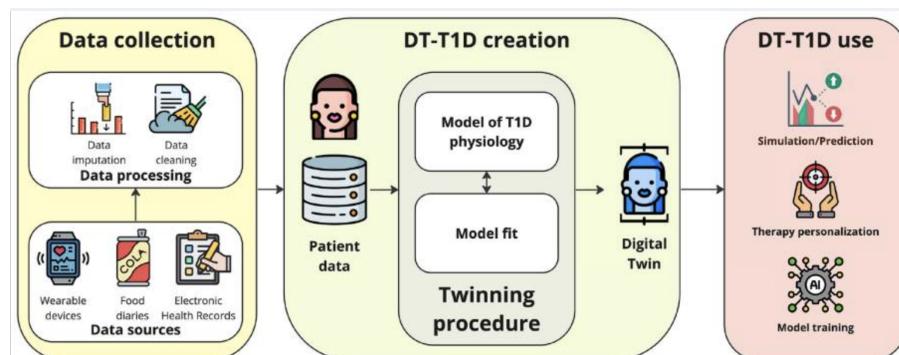
Lebih lanjut, Cappon, Facchinetti, dan Sparacino (2024) menjelaskan bahwa arsitektur DT modern telah berevolusi dari model PLM klasik menjadi sistem terintegrasi multi-sumber data. Model ini tidak hanya menerima input dari sensor fisik, tetapi juga dari basis pengetahuan eksternal seperti rekam medis elektronik, data *wearable devices*, dan sistem informasi klinis. Dengan kemampuan integrasi ini, DT berfungsi sebagai platform analitik cerdas yang mampu melakukan prediksi, optimasi, dan personalisasi secara simultan.

Dalam konteks penelitian ini, pemahaman terhadap konsep dan arsitektur dasar DT menjadi landasan untuk mengembangkan model *Digital Twin* yang dapat merepresentasikan kondisi fisiologis pasien diabetes tipe 2 secara virtual. Model digital tersebut akan digunakan untuk proses simulasi dan prediksi kadar glukosa darah berdasarkan data simulatif, sebelum nantinya dikembangkan lebih lanjut melalui pendekatan *Retrieval-Augmented Generation (RAG)* di bab berikutnya.

II.2 Digital Twin dalam Bidang Kesehatan

Konsep *Digital Twin* telah berkembang pesat dalam bidang kesehatan dan kedokteran presisi selama satu dekade terakhir. Menurut Bruynseels, Santoni de Sio, dan Hoven (2018), penerapan DT di bidang medis membuka peluang untuk mengembangkan model digital pasien yang mampu merepresentasikan kondisi fisiologis individu secara dinamis. Model tersebut dapat digunakan untuk melakukan prediksi hasil klinis, simulasi pengobatan, hingga personalisasi terapi berdasarkan karakteristik spesifik pasien.

Salah satu penerapan paling menonjol adalah pada bidang manajemen penyakit kronis seperti diabetes. Cappon, Facchinetti, dan Sparacino (2024) dalam tinjauan sistematisnya menunjukkan bahwa DT digunakan untuk mensimulasikan perilaku metabolismik tubuh dan memprediksi kadar glukosa darah berdasarkan data historis pasien. Sistem ini berfungsi sebagai *virtual replica* dari tubuh pasien yang beroperasi secara paralel dengan sistem nyata untuk memberikan wawasan tentang status kesehatan serta potensi respon terhadap terapi.



Gambar II.2 Arsitektur umum *Digital Twin* dalam bidang kesehatan yang mengintegrasikan data dari perangkat medis, sensor, dan catatan kesehatan elektronik. Diadaptasi dari Cappon, Facchinetti, dan Sparacino (2024).

Gambar II.2 menampilkan arsitektur umum *Digital Twin* dalam bidang kesehatan sebagaimana dijelaskan oleh Cappon, Facchinetti, dan Sparacino (2024). Diagram tersebut memperlihatkan bahwa DT medis terdiri atas beberapa lapisan integrasi data, meliputi:

1. **Sumber Data Fisik**, yang mencakup perangkat medis seperti *Continuous Glucose Monitoring* (CGM), sensor aktivitas, dan perangkat *wearable*;
2. **Lapisan Data dan Analitik**, tempat data klinis, fisiologis, dan perilaku pasien diproses serta diintegrasikan ke dalam model digital;
3. **Model Digital Pasien (Patient Twin)**, yaitu representasi virtual pasien yang

- digunakan untuk prediksi, simulasi, dan evaluasi terapi; serta
4. **Interface Klinik**, yang memungkinkan dokter atau sistem pendukung keputusan memanfaatkan hasil simulasi untuk tindakan medis.

Melalui arsitektur tersebut, sistem DT memungkinkan analisis prediktif yang lebih akurat karena dapat memperhitungkan variabilitas fisiologis antar individu. Rad dkk. (2024) bahkan mengusulkan framework *Patient-Centric Digital Twin* berbasis *Personal Health Knowledge Graph (PHKG)* yang mampu mengintegrasikan berbagai sumber data klinis dengan standar interoperabilitas HL7 FHIR. Framework tersebut terbukti mampu meningkatkan akurasi prediksi kadar glukosa dengan nilai *Root Mean Square Error (RMSE)* sebesar 19,83 mg/dL.

Zhang dkk. (2024) memperluas konsep ini dengan mengintegrasikan data multi-omics ke dalam model DT untuk memprediksi progresi penyakit *Type 2 Diabetes Mellitus* (T2DM). Pendekatan tersebut menunjukkan potensi besar DT dalam mendukung *personalized medicine* dengan memanfaatkan data fisiologis, genetik, dan perilaku secara holistik.

Meskipun hasilnya menjanjikan, sebagian besar penerapan DT di bidang kesehatan masih menghadapi kendala berupa kebutuhan akan infrastruktur teknologi tinggi, biaya perangkat medis, dan ketersediaan data real-time yang memadai (Cappon, Facchinetti, dan Sparacino 2024; Rad dkk. 2024). Tantangan ini semakin besar di negara berkembang, di mana infrastruktur digital dan rekam medis elektronik belum merata. Oleh karena itu, adaptasi konsep DT dengan pendekatan berbasis data simulatif dan kecerdasan buatan menjadi alternatif yang relevan untuk konteks sistem kesehatan seperti di Indonesia.

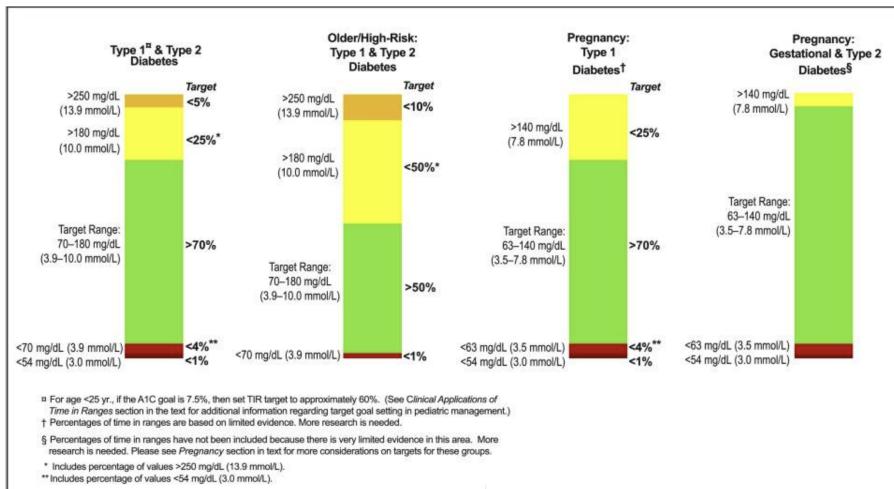
Selain pendekatan berbasis model fisiologis yang kompleks, perkembangan terkini juga menunjukkan tren positif pada pendekatan *Data-Driven Digital Twin*. Berbeda dengan model mekanistik yang memerlukan parameter biologis mendalam, pendekatan berbasis data memanfaatkan algoritma pembelajaran mesin untuk mempelajari pola dinamika sistem dari data historis (Woldaregay, Årsand, Walderhaug, dkk. 2019). Pendekatan ini dinilai lebih fleksibel dan *feasible* untuk diterapkan pada kondisi dengan keterbatasan infrastruktur sensor karena dapat beroperasi menggunakan data observasional tanpa mengurangi esensi kemampuan prediktif dan simulasi dari konsep *Digital Twin* itu sendiri.

II.3 Manajemen Diabetes dan Pendekatan Digital

Diabetes Mellitus (DM) merupakan penyakit metabolism kronis yang ditandai oleh meningkatnya kadar glukosa darah akibat gangguan pada sekresi atau kerja insulin. Bentuk yang paling umum adalah *Diabetes Mellitus Tipe 2* (T2DM) yang menyumbang lebih dari 90% kasus diabetes di dunia dan di Indonesia (World Health Organization 2023). Penyakit ini berhubungan erat dengan resistensi insulin serta penurunan sensitivitas sel terhadap glukosa, sehingga pengelolaan kadar glukosa menjadi aspek kunci dalam pencegahan komplikasi kronis seperti penyakit jantung, gagal ginjal, neuropati, dan kebutaan.

Pendekatan konvensional dalam manajemen T2DM melibatkan pemantauan kadar glukosa darah secara berkala, pengaturan pola makan, aktivitas fisik, serta pemberian terapi insulin atau obat oral. Namun, strategi ini seringkali bersifat reaktif, yaitu penyesuaian dilakukan setelah kadar glukosa menyimpang dari rentang normal. Pendekatan seperti ini belum sepenuhnya mampu mencegah fluktuasi glukosa ekstrem yang berisiko menimbulkan komplikasi jangka panjang (Alkaff dkk. 2021).

Untuk meningkatkan efektivitas pengelolaan diabetes, berbagai teknologi digital telah dikembangkan, antara lain *Continuous Glucose Monitoring* (CGM) dan *insulin pump* yang memungkinkan pemantauan dan penyesuaian terapi secara real-time (Battelino, Danne, Bergenstal, dkk. 2019). Sistem ini mengubah paradigma pengelolaan diabetes dari berbasis manual menjadi berbasis data (*data-driven management*). Selain itu, penggunaan aplikasi mobile dan perangkat *wearable* juga memungkinkan pasien untuk melacak pola makan, aktivitas fisik, serta kadar glukosa harian secara otomatis.



Gambar II.3 Contoh sistem pemantauan kadar glukosa darah berkelanjutan (*Continuous Glucose Monitoring*) yang digunakan dalam manajemen diabetes. Diadaptasi dari Battelino, Danne, Bergenstal, dkk. (2019).

Gambar II.3 memperlihatkan contoh sistem *Continuous Glucose Monitoring* (CGM) yang memungkinkan akuisisi data glukosa secara kontinu dari sensor subkutan. Data dari CGM dikirim ke perangkat penerima atau aplikasi seluler untuk analisis dan visualisasi pola glukosa pasien. Informasi ini dapat digunakan untuk menyesuaikan dosis insulin secara otomatis atau semi-otomatis, sehingga membantu menjaga kadar glukosa dalam rentang aman (Battelino, Danne, Bergenstal, dkk. 2019).

Selanjutnya, kemajuan dalam bidang *machine learning* memungkinkan analisis pola data glukosa dalam jangka panjang untuk tujuan prediktif. Woldaregay, Årsand, Walderhaug, dkk. (2019) mengembangkan model pembelajaran mesin yang mampu memprediksi fluktuasi glukosa darah jangka pendek berdasarkan data historis pasien. Pendekatan ini menunjukkan bahwa model berbasis data dapat membantu pasien mengantisipasi episode hipoglikemia atau hiperglikemia sebelum terjadi.

Meskipun teknologi tersebut memberikan kemajuan signifikan, penerapannya di Indonesia masih terbatas. Studi oleh Ramadaniati dkk. (2024) menunjukkan bahwa harga perangkat CGM di Indonesia relatif tinggi, dengan biaya yang dapat mencapai satu hingga dua bulan gaji rata-rata pasien. Kondisi ini menimbulkan tantangan dalam pemerataan akses terhadap teknologi pemantauan digital, terutama di fasilitas kesehatan primer.

Terlepas dari keunggulan data granularitas tinggi yang ditawarkan CGM, metode Pemantauan Gula Darah Mandiri (PGDM) atau *Self-Monitoring of Blood Glucose* (SMBG) tetap menjadi standar emas perawatan di banyak negara berkembang

karena faktor biaya dan ketersediaan (Ramadaniati dkk. 2024). Studi menunjukkan bahwa data SMBG yang dicatat secara terstruktur dan konsisten—metode yang dikenal sebagai *Ecological Momentary Assessment* (EMA)—tetap memiliki validitas klinis yang tinggi untuk memprediksi tren glikemik harian. Oleh karena itu, pengembangan sistem cerdas yang mampu mengoptimalkan data SMBG menjadi solusi yang lebih inklusif dan realistik untuk konteks demografi Indonesia dibandingkan ketergantungan penuh pada sensor CGM.

Berangkat dari kondisi tersebut, diperlukan pendekatan alternatif yang terjangkau namun tetap memiliki kemampuan prediktif tinggi. Salah satu solusi yang potensial adalah penggunaan model *Digital Twin* berbasis data simulatif, yang dapat menggantikan kebutuhan perangkat real-time melalui pemanfaatan data historis atau sintetis untuk pelatihan model prediksi glukosa. Pendekatan ini membuka peluang bagi pengembangan sistem prediktif adaptif yang relevan untuk konteks sumber daya terbatas seperti di Indonesia.

II.4 Faktor-Faktor yang Mempengaruhi Kadar Gula Darah

Kadar glukosa darah merupakan variabel fisiologis yang sangat dinamis dan dipengaruhi oleh interaksi kompleks berbagai faktor internal maupun eksternal. Pemahaman mendalam mengenai faktor-faktor ini menjadi landasan penting dalam pengembangan model prediksi yang akurat. Secara umum, terdapat tiga variabel utama yang berkontribusi signifikan terhadap fluktuasi glukosa harian, yaitu asupan nutrisi, aktivitas fisik, dan kondisi psikologis.

II.4.1 Asupan Nutrisi dan Karbohidrat

Asupan makanan, khususnya karbohidrat, memiliki dampak langsung dan paling signifikan terhadap kenaikan kadar glukosa darah pascamakan (*postprandial*). Karbohidrat yang dikonsumsi akan dihidrolisis menjadi glukosa dan diserap ke dalam aliran darah, menyebabkan lonjakan kadar gula darah dalam waktu singkat. Pada pasien T2DM, gangguan respons insulin menyebabkan tubuh gagal mengembalikan kadar glukosa ke rentang normal dengan cepat (American Diabetes Association 2023). Oleh karena itu, pencatatan jumlah asupan karbohidrat (*carbohydrate counting*) menjadi variabel input yang krusial dalam algoritma prediksi glukosa (Woldaregay, Årsand, Walderhaug, dkk. 2019).

II.4.2 Aktivitas Fisik

Aktivitas fisik berperan sebagai mekanisme regulasi alami yang membantu menurunkan kadar glukosa darah. Saat melakukan aktivitas fisik atau olahraga, otot rangka meningkatkan pengambilan glukosa dari darah untuk digunakan sebagai energi, bahkan tanpa memerlukan peningkatan insulin yang signifikan. Selain itu, aktivitas fisik rutin dapat meningkatkan sensitivitas insulin jangka panjang (Colberg, Sigal, Yardley, dkk. 2016). Dalam konteks pemodelan digital twin, data durasi dan intensitas aktivitas fisik digunakan untuk mensimulasikan laju penurunan glukosa (*glucose clearance rate*).

II.4.3 Faktor Psikologis dan Stres

Selain faktor fisik, kondisi psikologis seperti stres memiliki pengaruh yang sering diabaikan namun signifikan terhadap manajemen diabetes. Stres psikologis mengaktifkan sumbu *Hypothalamic-Pituitary-Adrenal* (HPA) dan sistem saraf simpatik, yang memicu pelepasan hormon stres seperti kortisol dan adrenalin (catekolamin) (Hackett dan Steptoe 2017).

Secara fisiologis, hormon-hormon ini bekerja antagonis terhadap insulin dengan cara:

- Merangsang glikogenolisis (pemecahan glikogen menjadi glukosa) di hati.
- Meningkatkan glukoneogenesis (pembentukan glukosa baru).
- Meningkatkan resistensi insulin pada jaringan perifer.

Akibatnya, episode stres yang tinggi dapat menyebabkan hiperglikemia meskipun pasien telah menjaga pola makan dan obat-obatan. Oleh karena itu, integrasi variabel tingkat stres ke dalam sistem prediksi sangat diperlukan untuk meningkatkan akurasi model pada kondisi dunia nyata.

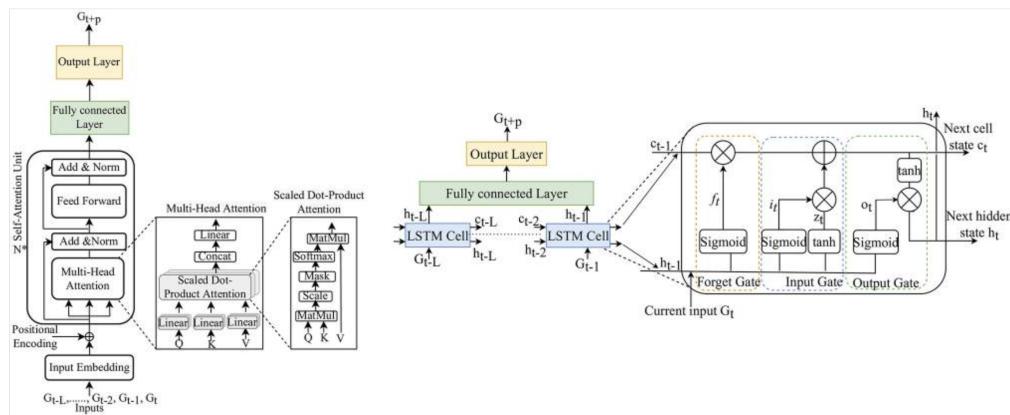
II.5 Metode Machine Learning untuk Prediksi Kadar Glukosa

Prediksi kadar glukosa darah merupakan salah satu tantangan utama dalam manajemen *Diabetes Mellitus*. Kompleksitas hubungan antara berbagai variabel fisiologis seperti asupan karbohidrat, dosis insulin, aktivitas fisik, dan stres membuat pendekatan konvensional berbasis model matematis sulit mencapai akurasi tinggi. Dalam konteks ini, pendekatan *machine learning* (ML) muncul sebagai solusi potensial untuk menangkap pola non-linear yang tidak dapat dimodelkan secara eksplisit.

Menurut Woldaregay, Årsand, Walderhaug, dkk. (2019), model pembelajaran mesin

dapat mempelajari hubungan kompleks antara variabel fisiologis dari data historis pasien. Pendekatan ini melibatkan pelatihan algoritma menggunakan dataset yang berisi pasangan masukan (misalnya kadar glukosa sebelumnya, dosis insulin, asupan makanan) dan keluaran (kadar glukosa berikutnya). Setelah dilatih, model dapat digunakan untuk memprediksi kadar glukosa masa depan berdasarkan pola yang telah dipelajari.

Beberapa algoritma yang umum digunakan dalam prediksi glukosa antara lain *Random Forest (RF)*, *Support Vector Regression (SVR)*, dan model berbasis jaringan saraf dalam seperti *Long Short-Term Memory (LSTM)* (Li, Zhang, dan Zhao 2022). Model LSTM populer karena kemampuannya memproses data deret waktu dan mempertahankan informasi jangka panjang melalui mekanisme *memory cell* dan *gating*.



Gambar II.4 Arsitektur model *Long Short-Term Memory (LSTM)* dengan mekanisme *attention* untuk prediksi kadar glukosa darah jangka pendek. Model ini mengombinasikan lapisan *self-attention*, unit *LSTM*, dan lapisan keluaran terhubung penuh untuk memproses deret waktu kadar glukosa. Diadaptasi dari Ghimire, Chen, Schenck, dkk. (2024).

Gambar II.4 menunjukkan arsitektur gabungan *LSTM-Attention* sebagaimana dijelaskan oleh Ghimire, Chen, Schenck, dkk. (2024). Model ini terdiri dari tiga bagian utama. Pertama, lapisan *input embedding* dan *self-attention* bertugas mengekstraksi fitur temporal penting dari data kadar glukosa historis. Kedua, lapisan *LSTM cell* menangkap dependensi jangka panjang dan hubungan non-linear antar nilai glukosa, sementara mekanisme gerbang—*forget gate*, *input gate*, dan *output gate*—mengatur aliran informasi antar langkah waktu. Ketiga, lapisan keluaran (*fully connected layer* dan *output layer*) menghasilkan prediksi kadar glukosa masa depan G_{t+p} berdasarkan masukan deret waktu $G_{t-L}, G_{t-L+1}, \dots, G_t$.

Kombinasi antara *attention mechanism* dan arsitektur LSTM terbukti meningkat-

an kemampuan model dalam menangkap hubungan temporal yang kompleks dibandingkan LSTM murni (Ghimire, Chen, Schenck, dkk. 2024). Pendekatan ini memungkinkan model untuk fokus pada segmen data yang paling relevan untuk prediksi, sehingga meningkatkan akurasi dan stabilitas hasil pada berbagai dataset pasien.

Untuk menilai kinerja model prediktif, digunakan berbagai metrik evaluasi kuantitatif. Dua metrik yang paling umum adalah *Root Mean Square Error (RMSE)* dan *Mean Absolute Error (MAE)*. RMSE mengukur akar rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi, sedangkan MAE mengukur rata-rata selisih absolut keduanya. Rumus matematis dari kedua metrik tersebut diberikan pada Persamaan II.1.

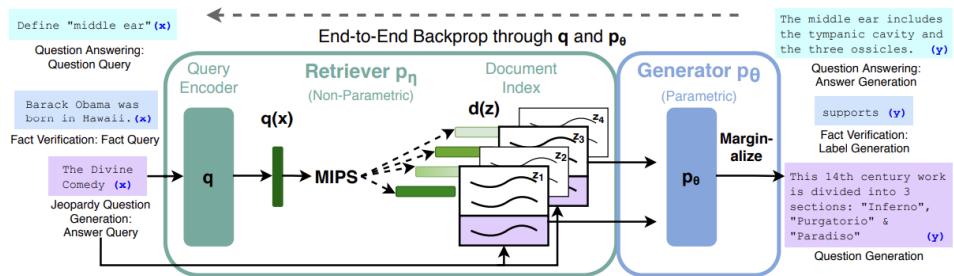
$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (\text{II.1})$$

Nilai RMSE dan MAE yang lebih kecil menunjukkan performa model yang lebih baik. Selain metrik statistik, beberapa penelitian juga menggunakan metrik berbasis klinis seperti *Clarke Error Grid (CEG)* untuk mengevaluasi implikasi klinis dari kesalahan prediksi (Battelino, Danne, Bergenstal, dkk. 2019). Dengan kombinasi evaluasi matematis dan klinis ini, model pembelajaran mesin dapat dinilai tidak hanya berdasarkan akurasi prediksi, tetapi juga keamanan penerapannya dalam konteks medis.

Pendekatan berbasis ML seperti LSTM memiliki potensi besar untuk diintegrasikan dengan konsep *Digital Twin*. Model DT dapat menggunakan hasil prediksi ML untuk memperbarui kondisi virtual pasien secara real-time, sementara data simulatif dari DT dapat digunakan kembali untuk melatih model ML, menciptakan sistem pembelajaran adaptif dua arah antara dunia nyata dan digital.

II.6 Retrieval-Augmented Generation (RAG) Framework

Retrieval-Augmented Generation (RAG) merupakan pendekatan dalam bidang *Natural Language Processing (NLP)* yang mengombinasikan dua proses utama, yaitu *retrieval* dan *generation*. Pendekatan ini pertama kali diperkenalkan oleh Lewis dkk. (2020) untuk meningkatkan kemampuan model generatif dalam menghasilkan keluaran yang faktual dan berbasis pengetahuan. Tidak seperti model generatif murni yang mengandalkan parameter internal untuk seluruh proses inferensi, RAG



Gambar II.5 Arsitektur *Retrieval-Augmented Generation (RAG)* yang terdiri atas dua komponen utama: *Retriever* untuk mengambil dokumen relevan dari basis pengetahuan eksternal dan *Generator* untuk menghasilkan keluaran berbasis konteks. Model dilatih secara end-to-end sehingga kedua komponen dapat dioptimalkan bersamaan. Diadaptasi dari Lewis dkk. (2020).

memungkinkan model mengakses basis pengetahuan eksternal secara dinamis.

Arsitektur RAG terdiri atas dua komponen utama:

1. **Retriever**, yaitu modul non-parametrik yang bertugas mencari potongan informasi atau dokumen yang relevan dari basis pengetahuan eksternal menggunakan metode pencarian berbasis vektor seperti *Maximum Inner Product Search (MIPS)*;
2. **Generator**, yaitu model bahasa besar berbasis *sequence-to-sequence transformer* yang menghasilkan keluaran akhir berdasarkan masukan dan konteks hasil *retrieval*.

Gambar II.5 memperlihatkan alur kerja RAG sebagaimana dijelaskan oleh Lewis dkk. (2020). Proses dimulai dengan kueri masukan (*query encoder*) yang diubah menjadi representasi vektor. Representasi ini digunakan oleh modul *retriever* untuk mencari dokumen relevan dari indeks pengetahuan eksternal. Dokumen yang di temukan kemudian diteruskan ke modul *generator*, yang memanfaatkan informasi tersebut untuk membentuk keluaran berbasis konteks. Proses pelatihan dilakukan secara end-to-end dengan pembaruan parameter bersama melalui mekanisme *backpropagation*, sebagaimana ditunjukkan oleh panah berlabel “End-to-End Backprop through q and $p\theta$ ”.

Pendekatan ini memberikan peningkatan signifikan dibandingkan model generatif murni karena mampu:

- Mengakses pengetahuan terkini tanpa perlu pelatihan ulang model besar;
- Menghasilkan keluaran yang lebih faktual, relevan, dan dapat ditelusuri sumbernya;
- Mengurangi fenomena *hallucination* dalam keluaran model bahasa besar.

Borgeaud dkk. (2022) memperluas konsep ini melalui integrasi retrieval skala besar, memungkinkan model mengakses triliunan token teks eksternal secara efisien untuk meningkatkan penalaran berbasis pengetahuan. Hasil penelitian tersebut menunjukkan bahwa RAG dapat berfungsi sebagai mekanisme penghubung antara model generatif dan sistem pencarian, menjadikannya salah satu pendekatan utama dalam pengembangan kecerdasan buatan berbasis pengetahuan.

Dalam konteks kesehatan digital, framework RAG berpotensi diintegrasikan dengan *Digital Twin*. Model DT yang biasanya bergantung pada data fisiologis pasien dapat diperluas dengan mengakses basis pengetahuan medis eksternal, seperti literatur ilmiah atau panduan klinis. Melalui integrasi ini, *RAG Digital Twin* dapat memanfaatkan data pasien internal bersama dengan informasi medis eksternal untuk menghasilkan rekomendasi yang lebih adaptif, berbasis bukti, dan kontekstual.

II.7 Penelitian Terkait

Berbagai penelitian telah dilakukan untuk mengembangkan model *Digital Twin* dan sistem prediktif berbasis *machine learning* dalam bidang kesehatan, khususnya manajemen *Diabetes Mellitus*. Beberapa studi juga mulai mengeksplorasi integrasi antara pembelajaran mesin, representasi pengetahuan, dan sistem generatif seperti *Retrieval-Augmented Generation (RAG)*. Tinjauan ini bertujuan untuk mengidentifikasi kemajuan terkini sekaligus menemukan celah penelitian yang relevan untuk konteks Indonesia.

Berdasarkan Tabel II.1, penelitian Rad dkk. (2024), Zhang dkk. (2024), dan Cappon, Facchinetto, dan Sparacino (2024) berfokus pada penerapan *Digital Twin* untuk manajemen diabetes dengan data real-time dari perangkat medis. Meskipun hasilnya menjanjikan, pendekatan tersebut masih memiliki keterbatasan pada aspek biaya, kompleksitas teknologi, dan ketergantungan terhadap infrastruktur *Electronic Health Records (EHR)* yang belum merata di negara berkembang seperti Indonesia.

Sementara itu, penelitian Woldaregay, Årsand, Walderhaug, dkk. (2019), Li, Zhang, dan Zhao (2022), dan Ghimire, Chen, Schenck, dkk. (2024) menunjukkan bahwa model *machine learning* berbasis deret waktu mampu memprediksi kadar glukosa dengan akurasi tinggi, bahkan menggunakan data simulatif atau publik. Namun, model tersebut masih terbatas pada konteks prediksi numerik dan belum mengintegrasikan pengetahuan klinis eksplisit.

Penelitian Lewis dkk. (2020) dan Borgeaud dkk. (2022) memperkenalkan paradi-

gma *Retrieval-Augmented Generation (RAG)*, yang menggabungkan pencarian informasi eksternal dengan keluaran generatif. Pendekatan ini potensial jika diadaptasi untuk domain medis, di mana sistem tidak hanya memprediksi nilai glukosa tetapi juga menjelaskan dasar fisiologis hasil prediksi tersebut.

Celah penelitian ini menjadi dasar pengembangan ***RAG Digital Twin Framework for Blood Glucose Prediction***, yang akan dibahas pada Bab III.

Tabel II.1 Ringkasan penelitian terkait *Digital Twin* dan prediksi kadar glukosa darah.

Peneliti (Tahun)	Pendekatan / Model	Konteks / Dataset	Hasil Utama / Temuan
Bruynseels, Santoni de Sio, dan Hoven (2018)	Konseptualisasi <i>Digital Twin</i> dalam etika kesehatan	Literatur konseptual	Menyoroti aspek etika dan tanggung jawab sosial dalam penerapan DT di kesehatan.
Cappon, Facchinetti, dan Sparacino (2024)	<i>Digital Twin</i> untuk T1DM	Dataset CGM	Arsitektur tiga tahap (data collection, twin creation, twin use); potensi tinggi namun infrastruktur mahal.
Rad dkk. (2024)	<i>Patient-Centric Digital Twin</i> berbasis PHKG	Data EHR dan <i>wearable</i> (HL7 FHIR)	RMSE 19.83 mg/dL; memberikan rekomendasi insulin dan diet personal.
Zhang dkk. (2024)	Integrasi DT dengan data multi-omics	Dataset simulatif T2DM	Prediksi progresi T2DM akurat; masih bergantung pada infrastruktur besar.
Woldaregay, Årsand, Walderhaug, dkk. (2019)	<i>Machine Learning</i> untuk prediksi glukosa	Dataset CGM (real patient)	Model prediksi jangka pendek berbasis regresi non-linear; baseline data-driven.

Bersambung ke halaman berikutnya

Tabel II.1 Ringkasan penelitian terkait *Digital Twin* dan prediksi kadar glukosa darah (*lanjutan*)

Peneliti (Tahun)	Pendekatan / Model	Konteks / Dataset	Hasil Utama / Temuan
Ghimire, Chen, Schenck, dkk. (2024)	<i>LSTM + Attention</i> untuk prediksi glukosa	Beberapa dataset publik	Model dengan <i>attention</i> menunjukkan generalisasi lintas dataset yang lebih baik.
Li, Zhang, dan Zhao (2022)	<i>Deep Learning (LSTM)</i> untuk prediksi glukosa	Dataset CGM individual	LSTM outperform model klasik dengan RMSE rata-rata \leq 22 mg/dL.
Lewis dkk. (2020)	<i>Retrieval-Augmented Generation (RAG)</i>	Tugas NLP berbasis pengetahuan	Framework retriever-generator meningkatkan akurasi dan relevansi keluaran generatif.
Borgeaud dkk. (2022)	RAG skala besar dengan <i>retrieval transformer</i>	Basis data 10 triliun token	Mengurangi <i>hallucination</i> dan meningkatkan efisiensi penalaran berbasis pengetahuan.

II.8 Tantangan Implementasi di Indonesia

Penerapan *Digital Twin* dalam konteks Indonesia menghadapi beberapa hambatan struktural. Pertama, tingkat kesiapan teknologi informasi dan komunikasi (TIK) antar fasilitas kesehatan masih bervariasi (Aisyah dkk. 2024). Kedua, perangkat medis pendukung seperti *Continuous Glucose Monitoring (CGM)* dan pompa insulin masih tergolong mahal dan belum tersedia secara luas (Ramadaniati dkk. 2024).

Selain itu, penelitian oleh Harahap, Handayani, dan Hidayanto (2023) menunjukkan bahwa integrasi data rekam medis elektronik masih terhambat oleh rendahnya adopsi sistem *Electronic Medical Record (EMR)*. Penelitian Abodunrin, Akande, dan Osagbemi (2020) di negara berkembang lain memperlihatkan bahwa kesadaran dan pelatihan tenaga medis terkait sistem digital kesehatan juga menjadi faktor penentu

keberhasilan implementasi.

Oleh karena itu, penerapan *Digital Twin* di Indonesia perlu dimulai dari model se-derhana berbasis data simulatif dan pembelajaran mesin yang ringan.

BAB III

ANALISIS MASALAH

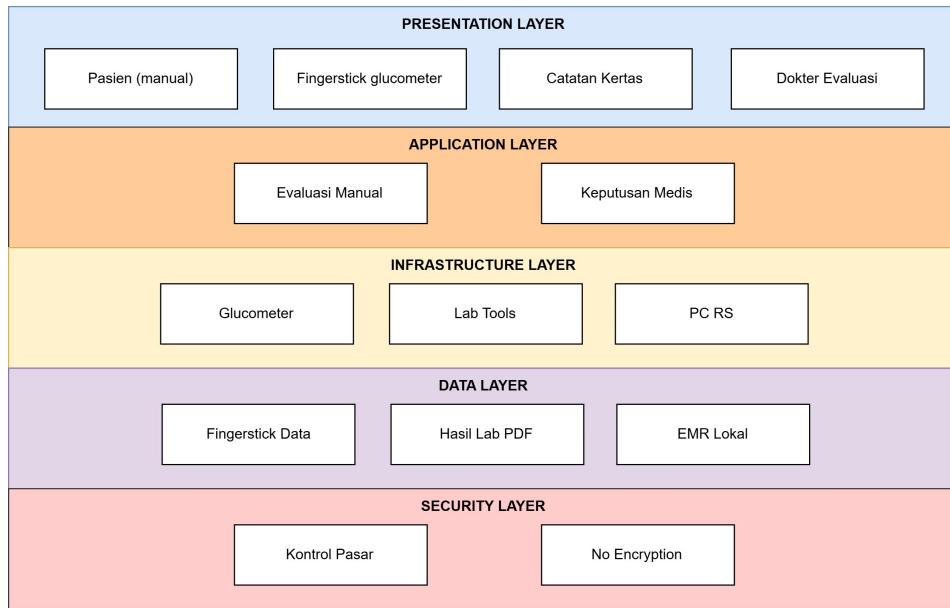
III.1 Analisis Kondisi Saat Ini

Analisis kondisi sistem saat ini dilakukan untuk memahami bagaimana sistem pengelolaan *Diabetes Mellitus* (DM) beroperasi, baik pada tataran global maupun nasional, sebelum dilakukan perancangan sistem baru. Pada konteks global, manajemen penyakit diabetes telah berkembang menuju sistem pemantauan *real-time* berbasis perangkat medis seperti *Continuous Glucose Monitoring* (CGM) dan *insulin pump*. Teknologi ini memungkinkan pasien dan tenaga medis untuk memperoleh data kadar glukosa darah secara berkelanjutan, yang selanjutnya dapat digunakan untuk menyesuaikan dosis insulin serta pola makan secara dinamis (Battelino, Danne, Bergenstal, dkk. 2019).

Namun demikian, sebagian besar sistem tersebut masih bersifat reaktif. Artinya, tindakan medis baru dilakukan setelah kadar glukosa pasien menunjukkan penyimpangan dari nilai normal. Selain itu, sistem pemantauan tersebut belum sepenuhnya memanfaatkan potensi analisis prediktif atau simulasi perilaku metabolismik pasien secara digital. Inovasi seperti *Digital Twin* mulai diterapkan di beberapa penelitian untuk menciptakan representasi virtual kondisi pasien yang dapat digunakan dalam simulasi terapi (Bruynseels, Santoni de Sio, dan Hoven 2018), tetapi implementasinya masih terbatas pada institusi dengan sumber daya dan infrastruktur digital yang tinggi.

Di Indonesia, sebagian besar pengelolaan data pasien diabetes masih dilakukan secara manual atau semi-digital. Pencatatan hasil pemeriksaan laboratorium, kadar glukosa darah, dan riwayat terapi umumnya dilakukan melalui sistem informasi rumah sakit yang belum terintegrasi antarfasilitas. Meskipun pemerintah telah mendorong adopsi *Electronic Medical Record* (EMR), tingkat interoperabilitas antar sistem masih rendah (Harahap, Handayani, dan Hidayanto 2023; Aisyah dkk. 2024). Kondisi

ini menyebabkan data pasien sering kali terfragmentasi, sehingga sulit digunakan untuk analisis longitudinal maupun pengembangan model prediktif.



Gambar III.1 Model konseptual sistem manajemen diabetes konvensional. Sistem saat ini terdiri atas subsistem klinis, pasien, dan perangkat medis dengan aliran data satu arah tanpa integrasi analitik cerdas.

Gambar III.1 memvisualisasikan arsitektur sistem manajemen diabetes konvensional (*as-is*) yang terbagi menjadi empat lapisan (*layer*) utama. Berdasarkan model tersebut, kondisi *as-is* saat ini memiliki karakteristik operasional sebagai berikut:

- 1. *Presentation Layer (Dominasi Manual)***

Interaksi pasien dengan data kesehatan masih didominasi oleh proses manual. Pengukuran gula darah dilakukan menggunakan *fingerstick glucometer*, namun pencatatannya sering kali masih mengandalkan **catatan kertas** atau aplikasi ponsel yang tidak terhubung ke sistem rumah sakit. Akibatnya, dokter hanya menerima informasi secara verbal atau fisik saat konsultasi tatap muka.

- 2. *Application Layer (Evaluasi Tanpa Bantuan Cerdas)***

Proses pengambilan keputusan medis sepenuhnya bergantung pada **evaluasi manual** dokter. Tidak ada sistem komputasi di lapisan aplikasi yang berjalan secara otomatis untuk memantau tren atau mendeteksi anomali di antara jadwal kunjungan (*in-between visits*). Keputusan medis murni didasarkan pada intuisi dan analisis sesaat dokter terhadap data yang dibawa pasien.

- 3. *Data Layer (Penyimpanan Terfragmentasi)***

Data kesehatan tersimpan secara terpisah-pisah (*silo*). Data pengukuran ha-

rian ada di tangan pasien (kertas), sementara riwayat pengobatan dan hasil laboratorium tersimpan di **EMR Lokal** rumah sakit atau dalam format dokument statis (PDF). Ketiadaan repositori data terpusat menyebabkan data historis sulit diakses untuk analisis longitudinal.

4. **Security Layer (Rentan)**

Aspek keamanan data belum terstandarisasi, yang ditandai dengan status "**No Encryption**" pada jalur komunikasi. Pertukaran informasi sering terjadi melalui saluran tidak aman, yang berisiko terhadap privasi data medis pasien.

Kondisi infrastruktur yang digambarkan di atas menciptakan aliran data yang bersifat satu arah dan memiliki latensi tinggi. Akibatnya, sistem saat ini menghadapi masalah kritis:

- **Latensi Keputusan:** Tindakan medis bersifat reaktif karena dokter sering kali baru mengetahui adanya pemburukan kondisi gula darah berminggu-minggu setelah kejadian (saat jadwal kontrol berikutnya).
- **Data Dark Silo:** Data pengukuran harian yang berharga terkunci dalam format kertas, sehingga tidak dapat dimanfaatkan (*mined*) oleh algoritma prediktif.
- **Absennya Personalisasi:** Tanpa integrasi data historis yang lengkap, rekomendasi terapi menjadi bersifat general dan kurang adaptif terhadap gaya hidup spesifik pasien.

Oleh karena itu, diperlukan transformasi dari sistem berbasis pencatatan manual dan evaluasi episodik ini menjadi sistem berbasis *Digital Twin* yang mampu melakukan akuisisi data digital secara kontinu dan memberikan prediksi otomatis.

III.2 Analisis Kebutuhan

Analisis kebutuhan dilakukan untuk mengidentifikasi permasalahan utama yang dihadapi pengguna dan menentukan kebutuhan sistem baru yang akan dikembangkan. Analisis ini mencakup dua aspek, yaitu kebutuhan fungsional dan kebutuhan nonfungsional. Tujuannya adalah untuk memastikan bahwa sistem yang dirancang mampu menjawab kebutuhan nyata pengguna sekaligus sesuai dengan batasan teknis dan operasional di lapangan.

III.2.1 Identifikasi Masalah Pengguna

Berdasarkan analisis kondisi eksisting, dapat diidentifikasi beberapa permasalahan yang dihadapi oleh para pemangku kepentingan utama (*stakeholder*) dalam sistem manajemen diabetes, yaitu pasien, tenaga medis, dan peneliti di bidang kesehatan

digital:

1. **Pasien**: sebagian besar pasien belum memiliki akses terhadap perangkat pemantauan *real-time* seperti *Continuous Glucose Monitoring (CGM)* karena harganya yang relatif mahal (Ramadaniati dkk. 2024). Pasien juga kesulitan memahami hubungan antara aktivitas harian, pola makan, dan fluktuasi kadar glukosa karena kurangnya alat bantu prediktif yang mudah digunakan.
2. **Tenaga Medis**: dokter dan tenaga kesehatan masih mengandalkan data hasil pemeriksaan laboratorium atau catatan pasien untuk menentukan terapi, sehingga keputusan bersifat retrospektif. Minimnya dukungan sistem prediktif membuat tenaga medis sulit melakukan intervensi dini terhadap risiko hipoglikemia atau hiperglikemia (Aisyah dkk. 2024).
3. **Peneliti dan Pengembang Sistem Kesehatan Digital**: sulit mendapatkan data medis terintegrasi yang konsisten karena rendahnya interoperabilitas antar sistem informasi kesehatan (Harahap, Handayani, dan Hidayanto 2023). Kondisi ini menghambat pengembangan model analitik yang dapat digeneralisasi.

Permasalahan-permasalahan tersebut menunjukkan perlunya sistem yang mampu memanfaatkan data simulatif sebagai alternatif sumber data pasien. Sistem tersebut diharapkan dapat melakukan prediksi kadar glukosa darah serta menyediakan simulasi perilaku metabolismik pasien dengan biaya rendah dan tanpa ketergantungan pada perangkat medis *real-time*.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional menggambarkan perilaku sistem yang diharapkan dari perspektif pengguna. Berdasarkan permasalahan yang diidentifikasi, kebutuhan fungsional dari sistem yang diusulkan meliputi:

Tabel III.1 Kebutuhan Fungsional Sistem

Kode	Deskripsi Kebutuhan
FR-01	Sistem mampu menerima input data harian mandiri (<i>logbook</i>) yang mencakup variabel kadar glukosa, asupan karbohidrat, dosis insulin, aktivitas fisik, dan tingkat stres.
FR-02	Sistem mampu melakukan <i>preprocessing</i> untuk menangani ketidakteraturan waktu input (<i>irregular time-steps</i>) dari data manual pasien.

Bersambung ke halaman berikutnya

Tabel III.1 – *Lanjutan dari halaman sebelumnya*

Kode	Deskripsi Kebutuhan
FR-03	Sistem memprediksi kadar glukosa darah jangka pendek menggunakan model <i>Machine Learning</i> (LSTM dengan Attention) berdasarkan pola data historis.
FR-04	Sistem menyediakan fitur simulasi skenario (<i>What-If Analysis</i>) yang memungkinkan pengguna mengubah variabel input (misal: mengurangi stres, menambah olahraga) untuk melihat prediksi dampaknya.
FR-05	Sistem mengintegrasikan modul <i>Retrieval-Augmented Generation</i> (RAG) untuk memberikan penjelasan klinis dan rekomendasi aksi yang relevan berdasarkan konteks prediksi.
FR-06	Sistem menampilkan visualisasi grafik tren glukosa aktual vs prediksi serta hasil simulasi pada antarmuka pengguna.

Kebutuhan fungsional ini menjadi dasar dalam perancangan arsitektur sistem *RAG Digital Twin*, di mana setiap modul berfungsi untuk menangani satu proses utama dari pipeline prediksi dan pembelajaran adaptif berbasis data.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional berkaitan dengan aspek kualitas dan batasan teknis yang harus dipenuhi agar sistem dapat berjalan secara optimal. Beberapa kebutuhan non-fungsional yang diidentifikasi adalah sebagai berikut:

Tabel III.2 Kebutuhan Nonfungsional Sistem

Kode	Deskripsi
NFR-01	Sistem mampu melakukan pelatihan dan prediksi secara efisien pada komputer dengan sumber daya terbatas (GPU menengah).
NFR-02	Sistem menghasilkan nilai RMSE ≤ 25 mg/dL, mendekati standar <i>state-of-the-art</i> .
NFR-03	Sistem menggunakan dataset simulatif publik tanpa biaya lisensi atau perangkat medis khusus.
NFR-04	Sistem mampu menangani data hilang melalui <i>data imputation</i> dan validasi sebelum pelatihan model.
NFR-05	Antarmuka sistem sederhana dan intuitif sehingga mudah digunakan tanpa keahlian teknis mendalam.
NFR-06	Sistem mematuhi prinsip keamanan data dan privasi, terutama jika integrasi data klinis nyata dilakukan di masa depan.

Kebutuhan fungsional dan nonfungsional tersebut menjadi acuan dalam perancangan sistem yang akan dijelaskan lebih lanjut pada Bab IV. Sistem ini diharapkan mampu mengisi kesenjangan antara kebutuhan prediksi glukosa yang akurat dan ketertinggalan infrastruktur digital di Indonesia melalui penerapan konsep *RAG Digital Twin* berbasis data simulatif.

III.3 Analisis Pemilihan Solusi

Untuk menjawab kebutuhan pengguna dan mengatasi kendala infrastruktur yang telah diidentifikasi, dilakukan analisis perbandingan terhadap lima pendekatan solusi potensial. Kelima solusi ini mewakili spektrum teknologi mulai dari pendekatan konvensional hingga pendekatan berbasis kecerdasan buatan tingkat lanjut.

III.3.1 Alternatif Solusi

Berikut adalah lima alternatif solusi yang dievaluasi:

1. Sistem Pakar Berbasis Aturan (*Rule-Based Expert System*)

Pendekatan ini menggunakan logika statis *"If-Then"* yang didefinisikan oleh dokter (misal: "Jika glukosa > 200 mg/dL, sarankan tambah insulin 2 unit").

- *Kelebihan:* Sangat sederhana, murah, dan transparan.
- *Kekurangan:* Kaku dan tidak mampu menangkap hubungan non-linear

yang kompleks (misalnya interaksi antara stres tinggi dan olahraga ringan). Tidak adaptif terhadap perubahan fisiologis pasien.

2. Model *Machine Learning Black-Box* (LSTM Standar)

Menggunakan algoritma *Deep Learning* (LSTM) murni untuk memprediksi angka glukosa masa depan berdasarkan data historis.

- *Kelebihan:* Akurasi prediksi numerik sangat tinggi untuk data deret waktu.
- *Kekurangan:* Bersifat *Black Box*; sistem hanya mengeluarkan angka prediksi tanpa memberikan penjelasan penyebabnya atau saran aksi. Pasien sering bingung harus berbuat apa dengan angka tersebut.

3. *Generative AI Chatbot* (RAG Tanpa Prediksi)

Menggunakan LLM (seperti GPT/Mistral) yang terhubung dengan buku medis (RAG) untuk menjawab pertanyaan pasien (misal: "Bagaimana cara menurunkan gula darah?").

- *Kelebihan:* Memberikan edukasi dan penjelasan yang sangat natural dan mudah dipahami.
- *Kekurangan:* Tidak memprediksi kondisi masa depan pasien. Saran bersifat umum (edukatif) dan tidak didasarkan pada data tren glukosa pasien yang spesifik (*non-personalized*).

4. *Physiological Digital Twin* (Full-Scale)

Membangun replika virtual organ tubuh yang sangat detail secara biologis (model mekanistik), biasanya membutuhkan input dari sensor *Continuous Glucose Monitoring* (CGM) secara *real-time*.

- *Kelebihan:* Kemampuan simulasi paling akurat dan ilmiah.
- *Kekurangan:* Biaya sangat tinggi (memerlukan sensor mahal) dan infrastruktur komputasi berat. Tidak sesuai untuk konteks negara berkembang dengan sumber daya terbatas (Ramadaniati dkk. 2024).

5. *Simplified RAG Digital Twin Framework* (Solusi Usulan)

Pendekatan hibrida yang menggabungkan model prediksi *Machine Learning* (sebagai representasi *Digital Twin* sederhana) dengan mekanisme RAG untuk penjelasan.

- *Kelebihan:* Menggabungkan akurasi prediksi (dari ML), personalisasi data (dari input logbook), dan penjelasan semantik yang mudah dimengerti (dari RAG).
- *Kekurangan:* Arsitektur sistem lebih kompleks daripada sekadar sistem pakar atau ML biasa, namun masih dapat dijalankan pada perangkat standar.

III.3.2 Analisis Penentuan Solusi

Untuk menentukan solusi terbaik, kelima alternatif dibandingkan berdasarkan lima kriteria utama: (1) Akurasi Prediksi, (2) Kemampuan Simulasi (*What-If*), (3) Kemampuan Penjelasan (*Explainability*), (4) Fleksibilitas Input Data (Tanpa Sensor Mahal), dan (5) Biaya Implementasi.

Perbandingan karakteristik kelima alternatif solusi dirangkum pada Tabel III.3.

Tabel III.3 Matriks Perbandingan Lima Alternatif Solusi

Kriteria	1. Rule-Based	2. ML (Blackbox)	3. Chatbot (RAG)	4. DT Fisiologis	5. RAG DT
Prediksi Numerik	Rendah	Tinggi	Tidak Ada	Sangat Tinggi	Tinggi
Simulasi <i>What-If</i>	Tidak Ada	Terbatas	Tidak Ada	Sangat Baik	Baik
Penjelasan/Saran	Kaku	Tidak Ada	Sangat Baik	Terbatas	Sangat Baik
Input Data (Hemat)	Ya	Ya	Ya	Tidak (Wajib CGM)	Ya (Logbook)
Biaya Sistem	Sangat Murah	Murah	Sedang	Mahal	Sedang

Kesimpulan Pemilihan Solusi:

Berdasarkan Tabel III.3, **Solusi 5 (*Simplified RAG Digital Twin Framework*)** dipilih karena menawarkan keseimbangan terbaik (*trade-off*) untuk konteks permasalahan di Indonesia:

1. Unggul dibandingkan **Solusi 1 dan 3** karena memiliki kemampuan prediksi numerik personal yang akurat.
2. Unggul dibandingkan **Solusi 2** karena tidak bersifat "kotak hitam", melainkan mampu memberikan penjelasan dan saran aksi yang dimengerti pasien.
3. Unggul dibandingkan **Solusi 4** dari sisi biaya dan kelayakan implementasi, karena tidak mewajibkan penggunaan sensor CGM yang mahal, namun tetap menyediakan fitur simulasi skenario yang cukup handal untuk kebutuhan harian.

BAB IV

Desain Konsep Solusi

IV.1 Sistem Saat Ini (Before)

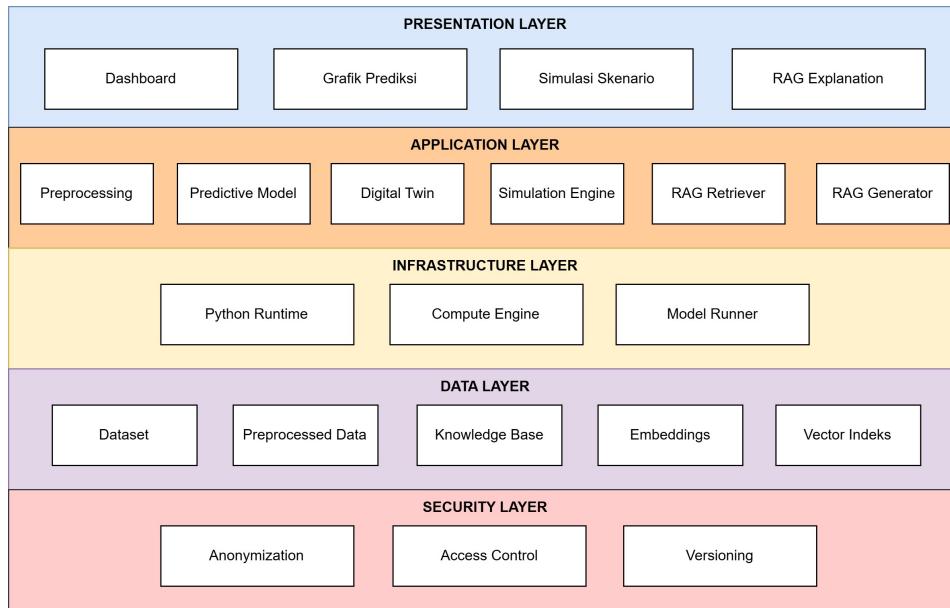
Model sistem saat ini telah ditampilkan pada Gambar III.1 pada Bab III. Sistem tersebut menggambarkan alur pengelolaan diabetes yang masih bersifat reaktif: data diperoleh melalui pemeriksaan manual atau berkala, kemudian tenaga medis meng-evaluasi kondisi pasien berdasarkan informasi yang terbatas. Beberapa keterbatasan sistem saat ini antara lain:

- aliran data satu arah dan tidak *real-time*;
- pemantauan berbasis *fingerstick* yang bersifat episodik;
- tidak adanya mekanisme prediksi kadar glukosa;
- tidak adanya representasi digital pasien atau *digital twin*;
- tidak adanya penjelasan berbasis pengetahuan atau analitik cerdas.

Keterbatasan tersebut memberikan dasar perlunya perancangan solusi yang lebih adaptif, prediktif, dan mampu menyediakan konteks klinis yang dapat diinterpretasikan.

IV.2 Model Konseptual Solusi (To-Be)

Berdasarkan analisis kebutuhan, dirancang model konseptual sistem usulan yang mengintegrasikan kemampuan prediksi, simulasi, dan penjelasan cerdas. Gambar IV.1 memperlihatkan arsitektur sistem yang terbagi menjadi lima lapisan (*layer*) utama untuk menjamin modularitas dan skalabilitas.



Gambar IV.1 Model konseptual sistem usulan berbasis *Digital Twin* dan *Retrieval-Augmented Generation*.

Rincian komponen pada setiap lapisan adalah sebagai berikut:

1. ***Presentation Layer***: Lapisan antarmuka yang berinteraksi langsung dengan pengguna.
 - **Dashboard**: Pusat informasi utama yang menampilkan ringkasan status kesehatan pasien.
 - **Grafik Prediksi**: Visualisasi tren glukosa darah historis dan hasil prediksi masa depan.
 - **Simulasi Skenario**: Antarmuka interaktif untuk fitur *what-if analysis*, memungkinkan pengguna mengubah variabel input (misal: porsi makan) untuk melihat dampaknya.
 - **RAG Explanation**: Modul yang menampilkan teks penjelasan klinis dan rekomendasi aksi yang dihasilkan oleh AI.
2. ***Application Layer***: Lapisan logika bisnis yang memproses data dan menjalankan algoritma cerdas.
 - **Preprocessing**: Membersihkan data log harian dan menangani nilai yang hilang.
 - **Predictive Model**: Menjalankan algoritma LSTM untuk menghasilkan prediksi numerik.
 - **Digital Twin**: Komponen perangkat lunak yang menyimpan *state* digital pasien untuk keperluan simulasi.
 - **Simulation Engine**: Mesin yang mengkalkulasi dampak perubahan va-

riabel input terhadap model *Digital Twin*.

- **RAG Retriever:** Bertugas mencari dokumen medis relevan berdasarkan konteks pasien.
- **RAG Generator:** Menggunakan LLM untuk menyusun narasi jawaban berdasarkan dokumen yang ditemukan.

3. ***Infrastructure Layer:*** Lapisan pendukung komputasi.

- **Python Runtime:** Lingkungan eksekusi utama untuk skrip backend.
- **Compute Engine:** Sumber daya komputasi (CPU/GPU) untuk pelatihan dan inferensi model.
- **Model Runner:** Layanan yang mengelola siklus hidup model ML saat dijalankan (*deployment*).

4. ***Data Layer:*** Lapisan manajemen penyimpanan data.

- **Dataset:** Data mentah dari logbook pasien dan dataset publik untuk pelatihan.
- **Preprocessed Data:** Data bersih yang siap digunakan oleh model.
- **Knowledge Base:** Basis pengetahuan eksternal berisi literatur medis dan panduan klinis.
- **Embeddings:** Representasi vektor dari data teks untuk pencarian semantik.
- **Vector Indeks:** Struktur data (seperti FAISS) untuk mempercepat pencarian dokumen di RAG.

5. ***Security Layer:*** Lapisan keamanan untuk melindungi privasi data medis.

- **Anonymization:** Mekanisme penghapusan identitas pasien (*PII*) sebelum data diproses oleh model eksternal.
- **Access Control:** Pengaturan hak akses berbasis peran (*Role-Based Access Control*) untuk pasien dan dokter.
- **Versioning:** Manajemen versi untuk model ML dan data guna memastikan keterlacakkan (*traceability*).

IV.3 Perbandingan Sistem Before dan After

Tabel IV.1 merangkum perbedaan utama antara sistem saat ini (*before*) dan sistem usulan (*after*).

Tabel IV.1 Perbandingan Karakteristik Sistem Saat Ini dan Sistem Usulan

Aspek Pembanding	Sistem Saat Ini (<i>As-Is</i>)	Sistem Usulan (<i>To-Be</i>)
Paradigma	Reaktif: Tindakan diambil setelah terjadi masalah atau saat jadwal kontrol.	Proaktif & Preventif: Sistem memprediksi risiko di masa depan dan memberikan peringatan dini.
Sumber Data	Pencatatan manual di kertas/buku log yang rentan hilang dan sulit di-analisis (<i>dark data</i>).	Input digital terpusat melalui <i>Logbook Harian</i> yang terstruktur dan tersimpan di database.
Variabel Pantauan	Terbatas pada kadar glukosa dan obat-obatan. Faktor gaya hidup sering terlewat.	Komprehensif mencakup glukosa, nutrisi, aktivitas fisik, dan tingkat stres harian.
Metode Evaluasi	Evaluasi manual oleh dokter berdasarkan data sesaat (<i>snapshot</i>) saat kunjungan.	Analisis otomatis berbasis <i>Machine Learning</i> (LSTM) yang mempelajari pola tren jangka panjang.
Simulasi Keputusan	Tidak tersedia. Pasien hanya menebak-nebak dampak dari tindakannya.	Tersedia fitur What-If Analysis untuk mensimulasikan dampak perubahan perilaku (misal: diet/stres).
Bentuk Luaran	Diagnosis lisan atau catatan rekam medis statis.	Visualisasi grafik tren interaktif dan teks rekomendasi aksi berbasis RAG yang personal.

Perbedaan mendasar terletak pada paradigma sistem: dari reaktif menjadi prediktif-adaptif. Sistem usulan tidak hanya mencatat dan menampilkan data historis, tetapi juga mampu memprediksi kondisi masa depan dan memberikan penjelasan kontekstual berbasis pengetahuan medis.

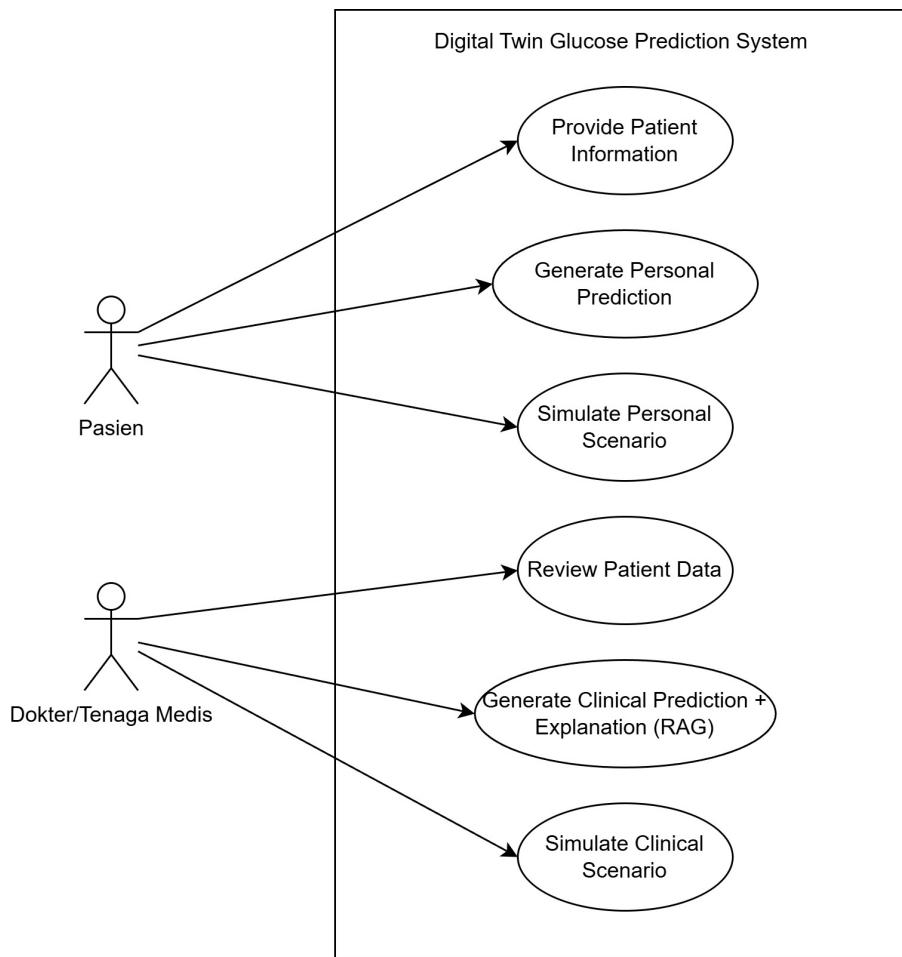
IV.4 Diagram Use Case

Diagram *use case* digunakan untuk menggambarkan keterlibatan aktor dan fungsi utama sistem. Sistem usulan memiliki dua aktor utama: **Pasien** dan **Dokter/Tenaga Medis**, dengan enam *use case* inti yang mencakup seluruh fungsionalitas sistem.

Gambar IV.2 memperlihatkan interaksi antara aktor dengan sistem. Deskripsi masing-masing *use case* adalah sebagai berikut:

IV.4.1 Use Case Aktor Pasien

1. **UC1 - Provide Patient Information:** Pasien melakukan pencatatan mandiri (*self-monitoring*) ke dalam logbook digital sistem. Data yang dimasukkan mencakup kadar glukosa darah saat ini, estimasi karbohidrat, dosis insulin, durasi aktivitas fisik, dan **tingkat stres subjektif**. *Use case* ini memenuhi



Gambar IV.2 Diagram *use case* sistem usulan.

kebutuhan FR-01.

2. **UC2 - Generate Personal Prediction:** Sistem menghasilkan prediksi kadar glukosa darah jangka pendek secara otomatis setelah pasien memperbarui data log harian mereka. *Use case* ini memenuhi FR-02 (preprocessing) dan FR-03 (prediksi menggunakan *machine learning*).
3. **UC3 - Simulate Personal Scenario:** Pasien melakukan simulasi "what-if" untuk melihat dampak perubahan gaya hidup. Contoh skenario: "Bagaimana prediksi gula darah saya jika saya mengurangi porsi makan atau menurunkan tingkat stres?". *Use case* ini memenuhi FR-04.

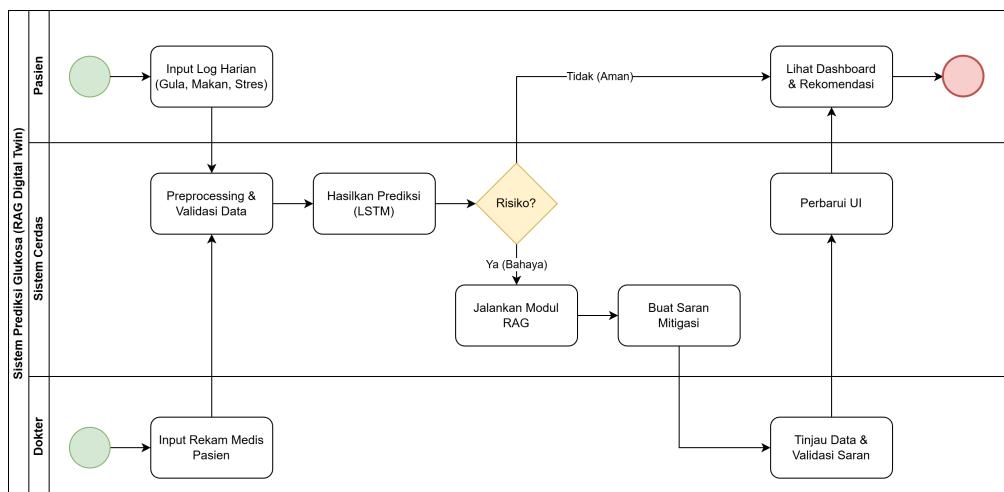
IV.4.2 Use Case Aktor Dokter/Tenaga Medis

1. **UC4 - Review Patient Data:** Tenaga medis dapat mengakses dasbor untuk meninjau grafik tren historis glukosa pasien, pola makan, dan fluktuasi tingkat stres untuk evaluasi kondisi yang lebih komprehensif. *Use case* ini mendukung FR-06.

2. **UC5 - Generate Clinical Prediction + Explanation (RAG):** Sistem menyajikan prediksi klinis yang disertai dengan teks penjelasan kausalitas (misal: "Lonjakan diprediksi akibat kombinasi stres tinggi dan kurang aktivitas") menggunakan mekanisme RAG. *Use case* ini memenuhi FR-05.
3. **UC6 - Simulate Clinical Scenario:** Tenaga medis dapat menjalankan simulasi skenario terapi yang lebih kompleks (misalnya penyesuaian dosis insulin) untuk merencanakan intervensi medis yang paling optimal dan aman bagi pasien.

IV.5 Alur Proses Sistem (BPMN)

Untuk menggambarkan alur kerja sistem secara prosedural dari sisi pengguna dan sistem, digunakan notasi *Business Process Model and Notation* (BPMN). Diagram ini memetakan urutan aktivitas mulai dari input data mandiri hingga dihasilkannya rekomendasi keputusan yang tervalidasi.



Gambar IV.3 Diagram BPMN sistem usulan yang mencakup proses input data, prediksi, deteksi risiko, dan validasi medis.

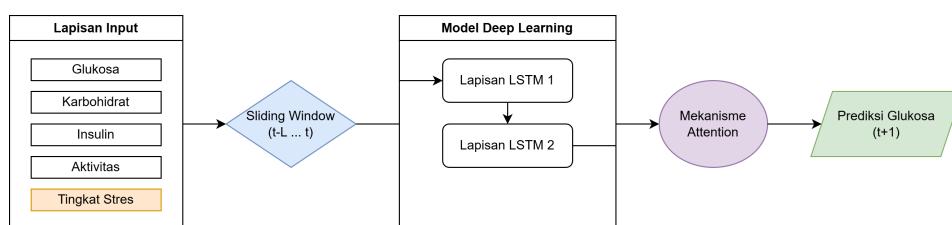
Gambar IV.3 menunjukkan alur proses yang terbagi menjadi tiga lajur (*swimlanes*) dengan rincian sebagai berikut:

1. **Lane Pasien:** Proses dimulai oleh pasien dengan aktivitas "**Input Log Harian**" yang mencakup variabel gula darah, makanan, dan tingkat stres. Di akhir proses, pasien akan menerima luaran berupa "**Lihat Dashboard & Rekomendasi**" yang menampilkan status kesehatan terkini.
2. **Lane Sistem Cerdas:** Lane ini menangani pemrosesan data otomatis:

- **Preprocessing & Validasi Data:** Menyiapkan data mentah dari logbook.
 - **Hasilkan Prediksi (LSTM):** Menjalankan model untuk memprediksi kadar glukosa.
 - **Gateway Risiko?:** Mengevaluasi hasil prediksi.
 - Jalur **”Tidak (Aman)”**: Jika prediksi normal, sistem langsung mengarahkan alur ke dashboard pasien tanpa intervensi lanjutan.
 - Jalur **”Ya (Bahaya)”**: Jika terdeteksi risiko (hipo/hiperglikemia), sistem mengaktifkan **”Jalankan Modul RAG”** dan **”Buat Saran Mitigasi”** sebelum meneruskannya ke dokter.
 - **Perbarui UI:** Aktivitas akhir sistem untuk memutakhirkan tampilan aplikasi setelah mendapatkan validasi dari dokter.
3. **Lane Dokter:** Dokter dapat memulai aktivitas memasukkan rekam data medis pasien. Lalu dokter juga berperan dalam pengawasan kritis pada aktivitas **”Tinjau Data & Validasi Saran”**. Dalam alur ini, saran mitigasi yang dihasilkan oleh AI tidak langsung dikirim ke pasien, melainkan diverifikasi terlebih dahulu oleh tenaga medis untuk memastikan keamanan dan akurasi rekomendasi sebelum sistem memperbarui antarmuka pengguna (*User Interface*).

IV.6 Arsitektur Model Machine Learning

Inti dari kemampuan prediktif sistem terletak pada *Predictive Modeling Layer*. Sistem ini menggunakan arsitektur *Deep Learning* berbasis *Long Short-Term Memory* (LSTM) yang diperkuat dengan mekanisme *Attention*. Pilihan ini didasarkan pada kemampuan LSTM dalam menangani data deret waktu jangka panjang dan keunggulan *Attention* dalam membobot variabel yang paling berpengaruh (misalnya: lonjakan stres tiba-tiba) terhadap prediksi akhir.



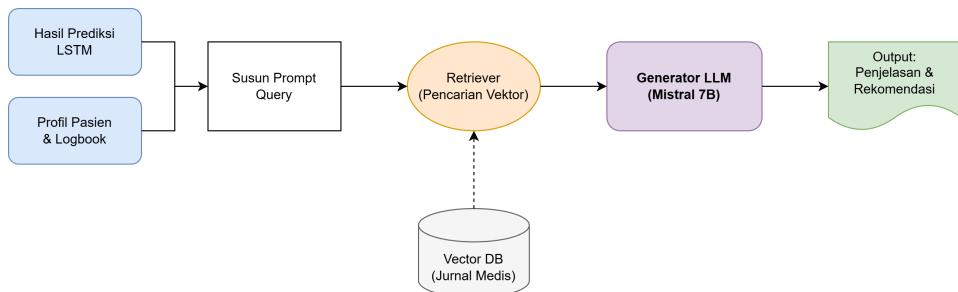
Gambar IV.4 Pipeline arsitektur model LSTM dengan mekanisme *Attention* untuk prediksi glukosa.

Gambar IV.4 mendetailkan alur pemrosesan data pada modul prediksi:

- Input Layer (Sliding Window):** Data logbook harian diubah menjadi sekuen waktu (*time-steps*) dengan metode *sliding window*. Input vektor X_t terdiri dari fitur: $X_t = [\text{Glukosa}, \text{Karbohidrat}, \text{Insulin}, \text{Aktivitas}, \text{Stres}]$.
- LSTM Layers:** Terdiri dari beberapa unit LSTM bertumpuk (*stacked LSTM*) yang bertugas mempelajari dependensi temporal dari riwayat data pasien.
- Attention Layer:** Mekanisme ini memberikan bobot kepentingan (α) yang berbeda pada setiap langkah waktu, memungkinkan model untuk "fokus" pada kejadian masa lalu yang paling relevan (misalnya: makan besar 2 jam lalu) saat memprediksi G_{t+1} .
- Output Layer:** Sebuah *Dense Layer* yang menghasilkan nilai skalar tunggal yaitu prediksi kadar glukosa darah di masa depan (misal: 30 atau 60 menit ke depan).

IV.7 Arsitektur Retrieval-Augmented Generation (RAG)

Untuk memberikan fitur penjelasan (*explainability*) dan rekomendasi keputusan, sistem menerapkan kerangka kerja RAG. Modul ini menghubungkan hasil prediksi numerik dari LSTM dengan basis pengetahuan medis untuk menghasilkan narasi yang dapat dimengerti manusia.



Gambar IV.5 Pipeline arsitektur RAG yang menghubungkan hasil prediksi dengan basis pengetahuan medis.

Gambar IV.5 memperlihatkan mekanisme kerja RAG dalam sistem:

- Query Construction:** Sistem menggabungkan data kondisi pasien saat ini (Input), hasil prediksi LSTM (Output), dan profil pasien menjadi satu *query prompt*.
- Retriever (Vector Search):** *Query* tersebut dikonversi menjadi vektor (*embedding*) untuk mencari dokumen yang paling relevan dalam basis pengetahuan medis (berisi panduan klinis PERKENI/ADA dan literatur diabetes). Pencairan dilakukan menggunakan algoritma kesamaan vektor (*cosine similarity*).

3. **Generator (LLM):** Dokumen medis yang ditemukan digabungkan dengan hasil prediksi sebagai konteks (*context window*) bagi *Large Language Model* (LLM).
4. **Response:** LLM menghasilkan teks penjelasan kausalitas (misal: "Gula darah diprediksi naik karena asupan karbohidrat tinggi dan tingkat stres level 8") serta rekomendasi aksi mitigasi yang spesifik.

IV.8 Pemetaan Use Case terhadap FR dan NFR

Bagian ini memberikan keterkaitan antara *use case* yang telah dirancang dan *functional requirements* (FR) serta *non-functional requirements* (NFR).

Tabel IV.2 Pemetaan Use Case terhadap Functional Requirements (FR) dan Non-Functional Requirements (NFR).

Use Case	Functional Requirements (FR)	Non-Functional Requirements (NFR)
UC1	FR-01	NFR-03, NFR-04
UC2	FR-02, FR-03	NFR-01, NFR-02
UC3	FR-05	NFR-01, NFR-05
UC4	FR-04	NFR-05, NFR-06
UC5	FR-02, FR-06	NFR-02, NFR-05
UC6	FR-05	NFR-01, NFR-06

Tabel IV.2 menunjukkan bahwa seluruh kebutuhan fungsional dan nonfungsional telah dipetakan ke dalam use case yang dirancang.

BAB V

Rencana Selanjutnya

V.1 Rencana Implementasi

Rencana implementasi mencakup tahapan teknis yang diperlukan untuk membangun prototipe sistem prediksi glukosa berbasis *Digital Twin* dan *Retrieval-Augmented Generation* (RAG). Mengingat batasan sumber daya komputasi, strategi implementasi akan difokuskan pada efisiensi model.

V.1.1 Persiapan Lingkungan dan Perangkat Pengembangan

Pengembangan sistem dilakukan menggunakan perangkat keras laptop ASUS VivoBook (M3400QA) dengan spesifikasi sebagai berikut:

- **Prosesor:** AMD Ryzen™ 5 5600H (6 Cores, 12 Threads, up to 4.2 GHz)
- **Grafis:** AMD Radeon™ Graphics (Integrated)
- **Memori (RAM):** 16 GB DDR4
- **Penyimpanan:** 512 GB SSD NVMe
- **Sistem Operasi:** Windows 11 Home Single Language 64-bit

Perangkat lunak dan alat pengembangan yang digunakan meliputi:

- **IDE:** Visual Studio Code (VS Code) dengan ekstensi Python dan Jupyter.
- **Bahasa Pemrograman:** Python 3.10+.
- **Version Control:** Git dan GitHub untuk manajemen kode sumber dan kolaborasi.
- **Environment Manager:** Anaconda atau Python *venv* untuk isolasi dependensi.

Mengingat perangkat tidak memiliki akselerator grafis diskrit (GPU NVIDIA CUDA), strategi komputasi akan disesuaikan:

1. **Pelatihan LSTM:** Dilakukan menggunakan komputasi CPU (Ryzen 5) yang sangat memadai untuk dataset numerik berukuran sedang.

2. **Inferensi RAG:** Menggunakan model bahasa yang telah dikompresi (*Quantized Model* format GGUF 4-bit) agar dapat berjalan efisien di RAM sistem, atau memanfaatkan layanan *Cloud API* (seperti Groq/HuggingFace) untuk menghindari beban berlebih pada perangkat lokal.

V.1.2 Persiapan Data

Tahap ini mencakup:

- Penyiapan repositori data di GitHub.
- Penentuan skema data untuk *Logbook* Harian (variabel: glukosa, karbohidrat, insulin, aktivitas, stres).
- Pembersihan (*cleaning*) dataset publik (OhioT1DM) untuk keperluan *pre-training* model.
- Implementasi teknik *sliding window* untuk mengubah data runtun waktu menjadi format *supervised learning*.

V.1.3 Pengembangan Model Prediksi

Tahap pemodelan mencakup:

1. Pembuatan model *baseline* (Random Forest) untuk tolok ukur performa.
2. Pengembangan model *Deep Learning* arsitektur LSTM dengan mekanisme *Attention*.
3. *Hyperparameter tuning* untuk mengoptimalkan *learning rate* dan jumlah *layer*.
4. Evaluasi model menggunakan data uji untuk memastikan target $\text{RMSE} \leq 25 \text{ mg/dL}$ tercapai.

V.1.4 Pembangunan Digital Twin

Digital Twin dibangun sebagai modul perangkat lunak yang mereplikasi logika metabolisme pasien. Kegiatan meliputi:

- Perancangan struktur data *JSON* untuk menyimpan *state* digital pasien.
- Implementasi logika pembaruan *state* otomatis berdasarkan output prediksi LSTM.
- Pengembangan algoritma simulasi untuk fitur *What-If Analysis* (misal: kalkulasi dampak jika variabel stres diturunkan 20%).

V.1.5 Integrasi Retrieval-Augmented Generation (RAG)

Tahapan ini meliputi:

- Penyusunan basis pengetahuan (*Knowledge Base*) dari panduan klinis diabetes terpercaya.
- Implementasi *vector database* lokal (menggunakan FAISS atau ChromaDB) untuk penyimpanan dokumen.
- Pengembangan fungsi *Retriever* untuk pencarian semantik.
- Integrasi dengan LLM (Mistral-7B versi GGUF atau API) untuk menghasilkan narasi penjelasan.

V.1.6 Pengembangan Antarmuka dan Visualisasi

Antarmuka pengguna (*User Interface*) sederhana berbasis web (menggunakan Streamlit atau Flask) akan dikembangkan untuk menampilkan:

- Formulir input log harian.
- Grafik tren glukosa aktual vs prediksi.
- Panel simulasi interaktif.
- Kotak penjelasan rekomendasi dari RAG.

V.1.7 Dokumentasi dan Penyusunan Laporan

Seluruh kode program akan didokumentasikan di GitHub, dan hasil eksperimen akan disusun menjadi laporan Tugas Akhir.

V.2 Desain Pengujian dan Evaluasi

Pengujian sistem dilakukan melalui beberapa tahap:

V.2.1 Verifikasi Sistem

Verifikasi memastikan komponen berjalan sesuai desain:

- **Unit Testing:** Menguji fungsi preprocessing dan kalkulasi metrik.
- **Integration Testing:** Memastikan data mengalir lancar dari Input Log → LSTM → RAG.

V.2.2 Validasi Model Prediksi

Evaluasi akurasi model kuantitatif menggunakan metrik:

- *Root Mean Square Error* (RMSE).
- *Mean Absolute Error* (MAE).
- *Clarke Error Grid Analysis* (untuk validasi keamanan klinis).

V.2.3 Evaluasi Integrasi Digital Twin dan RAG

Evaluasi kualitatif dilakukan terhadap:

- Kecepatan respons simulasi skenario.
- Relevansi dokumen medis yang diambil oleh *Retriever*.
- Keterbacaan dan kejelasan rekomendasi teks yang dihasilkan oleh RAG.

V.3 Analisis Risiko dan Mitigasi

Tabel V.1 merangkum risiko teknis yang mungkin terjadi dan strategi mitigasinya.

Tabel V.1 Analisis Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Keterbatasan komputasi lokal (Tanpa GPU Diskrit)	Inferensi LLM lokal berjalan lambat atau membebani memori sistem (RAM).	<ol style="list-style-type: none">1. Menggunakan model terkuantisasi (4-bit GGUF) yang ringan untuk CPU.2. Menggunakan layanan Cloud API untuk modul Generator.
Data input manual tidak konsisten (bolong-bolong)	Akurasi prediksi LSTM menurun karena <i>missing values</i> .	Implementasi teknik imputasi data (interpolasi) pada tahap <i>preprocessing</i> .
<i>Overfitting</i> pada data latih yang kecil	Model gagal memprediksi data baru dengan baik.	Penerapan teknik regularisasi (<i>Dropout</i>) dan validasi silang (<i>Cross-validation</i>).
Halusinasi pada RAG	Sistem memberikan saran medis yang salah atau tidak relevan.	Membatasi konteks dokumen hanya pada sumber terpercaya (Panduan PERKENI/ADA) dan menurunkan parameter <i>temperature</i> LLM.

V.4 Timeline Pengerjaan

Timeline disusun berdasarkan periode Januari-Mei 2026. Jadwal rinci disajikan pada Gambar V.1.

Aktivitas	Bulan																			
	Januari				Februari				Maret				April				Mei			
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
1. PERSIAPAN & DATA																				
Studi Literatur Lanjutan	■	■																		
Pengumpulan Data (Dataset Publik & Logbook)	■	■	■																	
Finalisasi Desain Arsitektur Sistem		■	■																	
Desain Skema Database Logbook			■	■	■															
Preprocessing & Data Cleaning					■	■	■													
2. PENGEMBANGAN MODEL ML								■	■	■										
Pelatihan Model LSTM (CPU)								■	■	■										
Evaluasi & Tuning Model ML									■	■										
3. PENGEMBANGAN DT & RAG											■	■								
Implementasi Logika Simulasi											■	■								
Setup Knowledge Base & Vector DB											■		■							
Integrasi LLM (RAG Generator)											■		■							
4. INTEGRASI & ANTARMUKA													■	■	■					
Pembuatan Dashboard UI													■							
Integrasi Backend ke Frontend													■	■	■					
5. PENGUJIAN & LAPORAN																				
Pengujian Fungsional Sistem														■	■					
Evaluasi Akurasi Akhir																	■	■		
Penulisan Laporan Tugas Akhir																		■	■	

Gambar V.1 Timeline Pelaksanaan Tugas Akhir (Januari-Mei 2026).

DAFTAR PUSTAKA

- Abodunrin, O., T. Akande, dan G. Osagbemi. 2020. “Awareness and Perception Toward Electronic Health Records Among Healthcare Professionals in a Developing Country”. *Health Information Management Journal* 49 (2-3): 98–107. <https://doi.org/10.1177/1833358319887257>.
- Aisyah, D. N., A. H. Setiawan, A. F. Lokopessy, N. Faradiba, S. Setiaji, L. Manikam, dan Z. Kozlakidis. 2024. “The Information and Communication Technology Maturity Assessment at Primary Health Care Services Across 9 Provinces in Indonesia: Evaluation Study”. *JMIR Medical Informatics* 12:e55959. <https://doi.org/10.2196/55959>.
- Alkaff, F. F., A. A. Suwantika, R. Abdulah, dan K. Lestari. 2021. “Challenges and Opportunities in the Management of Diabetes Mellitus in Indonesia: A Systematic Review”. *Journal of Global Health Science* 3 (2): e25. <https://doi.org/10.35500/jghs.2021.3.e25>.
- American Diabetes Association. 2023. “Standards of Care in Diabetes—2023”. *Diabetes Care* 46 (Supplement 1): S1–S291. https://diabetesjournals.org/care/issue/46/Supplement_1.
- Battelino, T., T. Danne, R. M. Bergenstal, dkk. 2019. “Clinical Targets for Continuous Glucose Monitoring Data Interpretation: Recommendations From the International Consensus on Time in Range”. *Diabetes Care* 42 (8): 1593–1603. <https://doi.org/10.2337/dci19-0028>.
- Borgeaud, Sebastian, Arthur Mensch, Jordan Hoffmann, Trevor Cai, dkk. 2022. “Improving language models by retrieving from trillions of tokens”. *Nature* 603 (7902): 587–593. <https://doi.org/10.1038/s41586-022-04587-z>.
- Bruynseels, K., F. Santoni de Sio, dan J. van den Hoven. 2018. “Digital Twins in Health Care: Ethical Implications of an Emerging Engineering Paradigm”. *Frontiers in Genetics* 9:31. <https://doi.org/10.3389/fgene.2018.00066>.

- Cappon, G., A. Facchinetti, dan G. Sparacino. 2024. “Digital Twins in Type 1 Diabetes: A Systematic Review”. *IEEE Reviews in Biomedical Engineering* 17:166–180. <https://doi.org/10.1109/RBME.2023.3296229>.
- Colberg, Sheri R, Ronald J Sigal, Jane E Yardley, dkk. 2016. “Physical activity/exercise and diabetes: a position statement of the American Diabetes Association”. *Diabetes Care* 39 (11): 2065–2079. <https://doi.org/10.2337/dc16-1728>.
- Ghimire, Saurav, Xuefeng Chen, Helene Schenck, dkk. 2024. “Deep learning for blood glucose level prediction: How well do models generalize across different data sets?” *npj Digital Medicine* 7 (1): 166. <https://doi.org/10.1038/s41746-024-01021-0>.
- Grieves, Michael, dan John Vickers. 2017. “Digital Twin: Mitigating Unpredictable, Undesirable Emergent Behavior in Complex Systems”. Dalam *Transdisciplinary Perspectives on Complex Systems*, 85–113. Cham, Switzerland: Springer. https://doi.org/10.1007/978-3-319-38756-7_4.
- Hackett, Ruth A, dan Andrew Steptoe. 2017. “Psychosocial stress and type 2 diabetes: current knowledge and future concepts”. *Nature Reviews Endocrinology* 13 (10): 547–560. <https://doi.org/10.1038/nrendo.2017.87>.
- Harahap, N. C., P. W. Handayani, dan A. N. Hidayanto. 2023. “Integrated Personal Health Record in Indonesia: Design Science Research Study”. *JMIR Medical Informatics* 11:e44784. <https://doi.org/10.2196/44784>.
- Harahap, N. C., P. W. Handayani, A. N. Hidayanto, dan I. Budi. 2024. “An Exploratory Study of Electronic Medical Record Implementation and Record-keeping Culture: The Case of Hospitals in Indonesia”. *BMC Health Services Research* 24:199. <https://doi.org/10.1186/s12913-024-10694-y>.
- International Diabetes Federation. 2024. *IDF Diabetes Atlas 11th Edition*. Technical report. Brussels: International Diabetes Federation. <https://diabetesatlas.org/>.
- Kementerian Kesehatan Republik Indonesia. 2019. *Laporan Nasional Riset Kesehatan Dasar (Riskesdas) 2018*. Menunjukkan sebagian besar kasus diabetes di Indonesia belum terdiagnosis. Jakarta, Indonesia: Badan Penelitian dan Pengembangan Kesehatan, Kementerian Kesehatan RI. <https://repository.badankejika kan.kemkes.go.id/id/eprint/3514/>.

- Knowledge Sourcing Intelligence. 2020. *Indonesia Diabetes Devices (SMBG & POCT, CGM, Insulin Pens & Pumps) Market Outlook to 2023*. Technical report. <https://www.knowledge-sourcing.com/report/indonesia-diabetes-devices-market>.
- Lewis, Patrick, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, dkk. 2020. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems (NeurIPS)* 33:9459–9474. <https://arxiv.org/abs/2005.11401>.
- Li, Xiaoyu, Yifan Zhang, dan Qiang Zhao. 2022. “Time-Series Deep Learning Models for Glucose Prediction: A Comparative Study”. *IEEE Journal of Biomedical and Health Informatics* 26 (8): 4150–4162. <https://doi.org/10.1109/JBHI.2022.3181751>.
- Rad, F. S., R. Hendawi, X. Yang, dan J. Li. 2024. “Personalized Diabetes Management with Digital Twins: A Patient-Centric Knowledge Graph Approach”. *Journal of Personalized Medicine* 14 (4): 359. <https://doi.org/10.3390/jpm14040359>.
- Ramadaniati, H. U., Y. Anggriani, M. Lepeska, D. Beran, dan M. Ewen. 2024. “Availability, Price and Affordability of Insulin, Delivery Devices and Self-Monitoring Blood Glucose Devices in Indonesia”. *PLOS ONE* 19 (10): e0309350. <https://doi.org/10.1371/journal.pone.0309350>.
- Woldaregay, A. Z., E. Årsand, S. Walderhaug, dkk. 2019. “Data-Driven Modeling and Prediction of Blood Glucose Dynamics: Machine Learning Applications in Type 1 Diabetes”. *Artificial Intelligence in Medicine* 98:109–134. <https://doi.org/10.1016/j.artmed.2019.07.004>.
- World Health Organization. 2023. *Global Report on Diabetes*. Technical report. Geneva: World Health Organization. <https://www.who.int/health-topics/diabetes>.
- Zhang, X., dkk. 2024. “A Framework Towards Digital Twins for Type 2 Diabetes”. *Frontiers in Digital Health* 6:1336050. <https://doi.org/10.3389/fdgth.2024.1336050>.