

**PENERAPAN RAG DIGITAL TWIN  
FRAMEWORK UNTUK PREDIKSI KADAR  
GLUKOSA DARAH PADA PASIEN DIABETES  
TIPE 2**

**Proposal Tugas Akhir**

Oleh

**Daffari Adiyatma  
18222003**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI  
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA  
INSTITUT TEKNOLOGI BANDUNG  
Desember 2025**

## **LEMBAR PENGESAHAN**

# **PENERAPAN RAG DIGITAL TWIN FRAMEWORK UNTUK PREDIKSI KADAR GLUKOSA DARAH PADA PASIEN DIABETES TIPE 2**

### **Proposal Tugas Akhir**

Oleh

**Daffari Adiyatma  
18222003**

Program Studi Sistem dan Teknologi Informasi  
Sekolah Teknik Elektro dan Informatika  
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan  
di Bandung, pada tanggal 5 Desember 2025

Pembimbing 1

Pembimbing 2

Prof. Dr. Ir. Suhono Harso Supangkat, Ir. Devi Willieam Anggara S.T., M.Phil.,  
M. Eng. Ph.D  
NIP. 196212031988111001 No Peg. 124110055

## DAFTAR ISI

<b>DAFTAR GAMBAR . . . . .</b>	<b>v</b>
<b>DAFTAR TABEL . . . . .</b>	<b>vi</b>
<b>DAFTAR KODE . . . . .</b>	<b>vii</b>
<b>I PENDAHULUAN . . . . .</b>	<b>1</b>
I.1 Latar Belakang . . . . .	1
I.2 Rumusan Masalah . . . . .	3
I.3 Tujuan . . . . .	4
I.4 Batasan Masalah . . . . .	5
I.5 Metodologi . . . . .	5
I.5.1 Studi Literatur . . . . .	5
I.5.2 Analisis Kebutuhan dan Perancangan Sistem . . . . .	6
I.5.3 Implementasi Sistem . . . . .	6
I.5.4 Validasi dan Evaluasi . . . . .	7
<b>II STUDI LITERATUR . . . . .</b>	<b>8</b>
II.1 Konsep Digital Twin . . . . .	8
II.2 Digital Twin dalam Bidang Kesehatan . . . . .	10
II.3 Manajemen Diabetes dan Pendekatan Digital . . . . .	11
II.4 Metode Machine Learning untuk Prediksi Kadar Glukosa . . . . .	13
II.5 Retrieval-Augmented Generation (RAG) Framework . . . . .	15
II.6 Penelitian Terkait . . . . .	17
II.7 Tantangan Implementasi di Indonesia . . . . .	19
<b>III ANALISIS MASALAH . . . . .</b>	<b>20</b>
III.1 Analisis Kondisi Saat Ini . . . . .	20
III.2 Analisis Kebutuhan . . . . .	22
III.2.1 Identifikasi Masalah Pengguna . . . . .	22
III.2.2 Kebutuhan Fungsional . . . . .	23
III.2.3 Kebutuhan Nonfungsional . . . . .	24
III.3 Analisis Pemilihan Solusi . . . . .	24
III.3.1 Alternatif Solusi . . . . .	25
III.3.2 Analisis Penentuan Solusi . . . . .	26

<b>IV Desain Konsep Solusi</b>	<b>28</b>
IV.1 Sistem Saat Ini (Before)	28
IV.2 Model Konseptual Solusi (After)	28
IV.3 Perbandingan Sistem Before dan After	30
IV.4 Diagram Use Case	30
IV.4.1 Use Case Aktor Pasien	31
IV.4.2 Use Case Aktor Dokter/Tenaga Medis	32
IV.5 Communication Diagram	32
IV.6 Pemetaan Use Case terhadap FR dan NFR	33
<b>V Rencana Selanjutnya</b>	<b>35</b>
V.1 Rencana Implementasi	35
V.1.1 Persiapan Lingkungan dan Perangkat Pengembangan	35
V.1.2 Persiapan Data	35
V.1.3 Pengembangan Model Prediksi	36
V.1.4 Pembangunan Digital Twin	36
V.1.5 Integrasi Retrieval-Augmented Generation (RAG)	36
V.1.6 Pengembangan Antarmuka dan Visualisasi	36
V.1.7 Dokumentasi dan Penyusunan Laporan	36
V.2 Desain Pengujian dan Evaluasi	37
V.2.1 Verifikasi Sistem	37
V.2.2 Validasi Model Prediksi	37
V.2.3 Evaluasi Integrasi Digital Twin dan RAG	37
V.3 Analisis Risiko dan Mitigasi	38
V.4 Timeline Penggerjaan	38

## DAFTAR GAMBAR

II.1	Model konseptual <i>Digital Twin</i> yang menunjukkan keterhubungan antara ruang fisik dan ruang virtual. Diadaptasi dari Grieves dan Vickers (2017). . . . .	9
II.2	Arsitektur umum <i>Digital Twin</i> dalam bidang kesehatan yang mengintegrasikan data dari perangkat medis, sensor, dan catatan kesehatan elektronik. Diadaptasi dari Cappon, Facchinetti, dan Sparacino (2024). . . . .	10
II.3	Contoh sistem pemantauan kadar glukosa darah berkelanjutan ( <i>Continuous Glucose Monitoring</i> ) yang digunakan dalam manajemen diabetes. Diadaptasi dari Battelino, Danne, Bergenstal, dkk. (2019). . . . .	12
II.4	Arsitektur model <i>Long Short-Term Memory (LSTM)</i> dengan mekanisme <i>attention</i> untuk prediksi kadar glukosa darah jangka pendek. Model ini mengombinasikan lapisan <i>self-attention</i> , unit <i>LSTM</i> , dan lapisan keluaran terhubung penuh untuk memproses deret waktu kadar glukosa. Diadaptasi dari Ghimire, Chen, Schenck, dkk. (2024). . . . .	14
II.5	Arsitektur <i>Retrieval-Augmented Generation (RAG)</i> yang terdiri atas dua komponen utama: <i>Retriever</i> untuk mengambil dokumen relevan dari basis pengetahuan eksternal dan <i>Generator</i> untuk menghasilkan keluaran berbasis konteks. Model dilatih secara end-to-end sehingga kedua komponen dapat dioptimalkan bersamaan. Diadaptasi dari Lewis dkk. (2020). . . . .	16
III.1	Model konseptual sistem manajemen diabetes konvensional. Sistem saat ini terdiri atas subsistem klinis, pasien, dan perangkat medis dengan aliran data satu arah tanpa integrasi analitik cerdas. . . . .	21
IV.1	Model konseptual sistem usulan berbasis <i>Digital Twin</i> dan <i>Retrieval-Augmented Generation</i> . . . . .	29
IV.2	Diagram <i>use case</i> sistem usulan. . . . .	31
IV.3	<i>Communication diagram</i> sistem prediksi glukosa berbasis <i>Digital Twin</i> . . . . .	32

V.1 Timeline Pelaksanaan Tugas Akhir (Januari–Mei 2026) . . . . .	38
---	----

## **DAFTAR TABEL**

II.1 Ringkasan penelitian terkait <i>Digital Twin</i> dan prediksi kadar glukosa darah. . . . .	18
III.1 Kebutuhan Fungsional Sistem . . . . .	23
III.2 Kebutuhan Nonfungsional Sistem . . . . .	24
III.3 Perbandingan alternatif solusi untuk prediksi kadar glukosa darah. . . . .	26
IV.1 Perbandingan sistem saat ini dan sistem usulan. . . . .	30
IV.2 Pemetaan Use Case terhadap Functional Requirements (FR) dan Non-Functional Requirements (NFR). . . . .	34
V.1 Analisis Risiko dan Mitigasi . . . . .	38

## **DAFTAR KODE**

# **BAB I**

## **PENDAHULUAN**

### **I.1 Latar Belakang**

Penyakit diabetes melitus (DM) merupakan salah satu masalah kesehatan global yang paling serius pada abad ke-21. Menurut laporan International Diabetes Federation (IDF) tahun 2024, jumlah penderita diabetes di Indonesia mencapai lebih dari 19 juta orang dan diperkirakan terus meningkat seiring dengan perubahan gaya hidup dan urbanisasi cepat di kawasan Asia Tenggara (International Diabetes Federation 2024). Dari seluruh kasus tersebut, sekitar 90–95% tergolong Diabetes Melitus Tipe 2 (T2DM), yang ditandai dengan resistensi insulin dan penurunan sensitivitas sel terhadap glukosa (World Health Organization 2023). Kondisi ini meningkatkan risiko komplikasi kronis seperti penyakit jantung, gagal ginjal, neuropati, dan kebutaan apabila tidak ditangani dengan manajemen glukosa darah yang baik.

Sebagian besar sistem pengelolaan diabetes di Indonesia masih bersifat reaktif. Data dari Kementerian Kesehatan Republik Indonesia (2019) dan Knowledge Sourcing Intelligence (2020) menunjukkan bahwa sebagian besar kasus diabetes di Indonesia tidak terdiagnosis, dengan hanya sekitar 26% penderita yang mengetahui status penyakitnya. Hal ini sejalan dengan tinjauan sistematis oleh Alkaff dkk. (2021) yang menyimpulkan bahwa sistem kesehatan di Indonesia masih berfokus pada pendekatan kuratif dibandingkan pencegahan. Penggunaan continuous glucose monitoring (CGM) dan insulin pump telah terbukti membantu pasien dalam memantau kadar glukosa secara real-time dan menyesuaikan dosis insulin secara lebih presisi (Battelino, Danne, Bergenstal, dkk. 2019). Selain itu, pendekatan berbasis machine learning mulai digunakan untuk memprediksi fluktuasi glukosa darah berdasarkan data historis pasien Woldaregay, Årsand, Walderhaug, dkk. (2019). Teknologi digital twin, yang merupakan replika virtual dari kondisi fisiologis pasien, mulai di terapkan dalam manajemen diabetes untuk mensimulasikan respons metabolik pasi-

en terhadap berbagai skenario pengobatan (Bruynseels, Santoni de Sio, dan Hoven 2018).

Penelitian terkini oleh Rad dkk. (2024) mengusulkan framework digital twin komprehensif berbasis Personal Health Knowledge Graph (PHKG) yang mampu mengintegrasikan data dari Electronic Health Records (EHR), wearable devices, dan mobile health applications dengan standar HL7 FHIR. Framework ini telah terbukti efektif dalam prediksi glukosa dengan Root Mean Square Error (RMSE) 19,83 mg/dL dan mampu memberikan rekomendasi insulin personal serta saran diet yang disesuaikan. Penelitian serupa oleh Zhang dkk. (2024) mengintegrasikan machine learning dengan data multiomic untuk memprediksi progresi diabetes tipe 2, menunjukkan potensi digital twin dalam personalized medicine. Cappon, Facchinetti, dan Sparacino (2024) dalam systematic review mereka menemukan bahwa meskipun pendekatan digital twin menjanjikan, sebagian besar implementasinya masih mengandalkan infrastruktur teknologi yang kompleks dan perangkat medis yang mahal.

Meskipun framework-framework tersebut menunjukkan hasil yang menjanjikan, implementasinya menghadapi hambatan signifikan di konteks Indonesia. Pertama, dari sisi infrastruktur digital kesehatan, meskipun pemerintah Indonesia mewajibkan adopsi rekam medis elektronik (EMR) pada akhir 2023, transisi ini masih menghadapi berbagai tantangan teknologi, budaya, dan infrastruktur Harahap dkk. (2024). Studi yang melibatkan 9 provinsi di Indonesia menunjukkan variasi signifikan dalam kesiapan teknologi informasi dan komunikasi (TIK) antarfasilitas kesehatan, dengan perlunya peningkatan sumber daya manusia (SDM), infrastruktur, perangkat keras, dan optimalisasi sistem informasi untuk mencapai kemajuan TIK (Aisyah dkk. 2024). Sebagian besar fasilitas kesehatan belum menyediakan akses terintegrasi ke rekam kesehatan pasien dengan pertukaran informasi yang masih bersifat satu arah, dari fasilitas kesehatan ke pasien (Harahap, Handayani, dan Hidayanto 2023).

Kedua, dari sisi keterjangkauan perangkat monitoring, framework Rad dkk. (2024) mengasumsikan ketersediaan Continuous Glucose Monitoring (CGM) untuk data real-time. Namun, studi Ramadaniati dkk. (2024) menunjukkan bahwa CGM memerlukan biaya setara satu bulan gaji untuk membeli reader dan dua bulan gaji untuk pasokan sensor bulanan, dengan upah minimum harian di Indonesia sekitar US\$3,50. Hal ini menyebabkan CGM tidak terjangkau bagi mayoritas pasien diabetes di Indonesia, terutama mengingat bahwa untuk membeli pasokan pengobatan selama 30 hari (insulin pen, jarum pen, dan monitoring mandiri berdasarkan 5 kali tes per hari), pasien perlu menghabiskan hampir seluruh gaji bulanan mereka.

Ketiga, kompleksitas teknis framework Rad dkk. (2024) yang memerlukan pengembangan ontology berbasis HL7 FHIR, implementasi GLAV (Global-Local as View) framework untuk integrasi data, dan penggunaan Conditional Random Fields untuk mapping data, membutuhkan expertise spesialis yang belum banyak tersedia di Indonesia. Penelitian menunjukkan bahwa di negara berkembang, adopsi EMR berbeda karena beberapa faktor termasuk infrastruktur sistem kesehatan, tingkat pendidikan dan pelatihan tenaga kesehatan, pendanaan, dan penerimaan budaya terhadap EMR, sehingga di banyak negara berkembang, penggunaan EMR belum sepenuhnya diterapkan (Abodunrin, Akande, dan Osagbemi 2020).

Dari uraian tersebut, tampak bahwa pengelolaan diabetes di Indonesia masih menghadapi hambatan dalam pemanfaatan teknologi prediktif yang efisien dan terjangkau. Kondisi ini menunjukkan adanya kesenjangan antara potensi teknologi digital twin yang telah terbukti efektif di negara maju dengan kemampuan implementasinya di Indonesia. Diperlukan studi lebih lanjut untuk memahami bagaimana konsep digital twin dapat disesuaikan dengan keterbatasan infrastruktur, biaya, serta sumber daya lokal sehingga mampu memberikan manfaat nyata dalam konteks sistem kesehatan nasional.

## I.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, permasalahan utama dalam tugas akhir ini adalah kesenjangan antara framework digital twin yang canggih (seperti yang dikembangkan oleh Rad dkk. (2024)) dengan kemampuan implementasi di Indonesia yang terkendala oleh keterbatasan infrastruktur EHR, tingginya biaya perangkat monitoring real-time, dan kompleksitas teknis yang memerlukan expertise spesialis. Kesenjangan ini penting untuk diatasi karena mayoritas penderita diabetes di Indonesia (74%) belum terdiagnosis dan memerlukan sistem prediktif yang terjangkau untuk deteksi dini dan manajemen yang lebih baik.

Berdasarkan permasalahan tersebut, penelitian ini difokuskan untuk menelusuri bagaimana konsep digital twin dapat disederhanakan dan diterapkan secara kontekstual di Indonesia, khususnya dalam mendukung prediksi kadar glukosa darah pasien diabetes tipe 2.

Secara khusus, rumusan masalah dalam tugas akhir ini adalah sebagai berikut:

1. Bagaimana menganalisis dan memformulasikan kebutuhan arsitektur sistem digital twin yang disederhanakan untuk prediksi kadar glukosa darah tanpa ketergantungan pada Personal Health Knowledge Graph dan infrastruktur HL7

FHIR?

2. Bagaimana mengembangkan model prediktif kadar glukosa darah menggunakan pendekatan pembelajaran mesin?
3. Bagaimana metode validasi yang tepat untuk memastikan hasil prediksi sistem digital twin yang disederhanakan memiliki akurasi yang sebanding dengan pendekatan state-of-the-art?
4. Bagaimana sistem digital twin yang disederhanakan ini dapat digunakan sebagai alat bantu prediksi yang feasible untuk implementasi di fasilitas kesehatan dengan keterbatasan infrastruktur?

### I.3 Tujuan

Tujuan umum penelitian ini adalah mengeksplorasi dan mengembangkan pendekatan digital twin berbasis data simulatif untuk prediksi kadar glukosa darah pada pasien diabetes, yang dapat diimplementasikan di Indonesia tanpa memerlukan infrastruktur kompleks dan perangkat monitoring real-time yang mahal.

Secara khusus, tujuan penelitian ini meliputi:

1. Merumuskan kebutuhan dan desain konseptual sistem digital twin yang disederhanakan dengan pendekatan pembelajaran mesin langsung, tanpa memerlukan pengembangan knowledge graph dan integrasi HL7 FHIR.
2. Mengembangkan modul prediktif kadar glukosa berbasis pembelajaran mesin (LSTM atau Random Forest) yang dapat beroperasi menggunakan data minimal.
3. Melakukan validasi terhadap hasil prediksi sistem menggunakan dataset terbuka (OhioT1DM Dataset atau UVA/Padova Simulator) dengan metrik evaluasi standar seperti RMSE, MAE, dan Clarke Error Grid Analysis.
4. Mengevaluasi akurasi dan reliabilitas sistem dalam memprediksi perubahan kadar glukosa darah dan membandingkannya dengan baseline pendekatan yang ada.

Kriteria keberhasilan tugas akhir ini adalah terciptanya prototipe sistem yang mampu menghasilkan prediksi kadar glukosa dengan akurasi yang sebanding dengan state-of-the-art (target  $\text{RMSE} \leq 25 \text{ mg/dL}$ ) namun dengan kompleksitas implementasi yang lebih rendah, sehingga dapat menjadi *proof-of-concept* untuk implementasi di fasilitas kesehatan dengan infrastruktur terbatas.

## I.4 Batasan Masalah

Penelitian ini dibatasi oleh hal-hal berikut:

1. Sistem tidak melibatkan perangkat keras, sensor IoT, atau integrasi dengan sistem EHR yang ada.
2. Fokus penelitian adalah pada pengembangan dan pengujian sistem digital twin berbasis perangkat lunak dengan pendekatan pembelajaran mesin langsung, tanpa implementasi Personal Health Knowledge Graph.
3. Model hanya mencakup prediksi kadar glukosa berdasarkan variabel pendukung yang tersedia dalam dataset (asupan karbohidrat, dosis insulin, aktivitas fisik), tanpa melibatkan faktor genetik, psikologis, atau data multiomic.
4. Evaluasi dilakukan terhadap performa sistem dalam skenario simulatif sebagai *proof-of-concept*, bukan pada uji klinis langsung dengan pasien nyata.
5. Sistem yang dikembangkan berfokus pada satu *use case* utama yaitu prediksi glukosa darah, tidak mencakup optimasi insulin atau rekomendasi *meal planning*.

## I.5 Metodologi

Tahapan metodologi dirancang untuk memastikan proses penelitian berjalan secara sistematis, mulai dari pengumpulan informasi awal hingga validasi hasil prediksi. Metodologi penelitian ini terdiri dari lima tahap utama:

### I.5.1 Studi Literatur

Melakukan kajian pustaka terhadap konsep digital twin, pengelolaan penyakit diabetes, serta penelitian terdahulu terkait model simulatif dan prediktif. Sumber literatur berasal dari jurnal ilmiah bereputasi seperti IEEE Xplore, ScienceDirect, Nature Digital Medicine, dan Journal of Personalized Medicine. Pencarian literatur dilakukan dengan kata kunci “digital twin diabetes”, “glucose prediction machine learning”, “diabetes simulation model”, “simplified digital twin framework”, dan kombinasi kata kunci terkait.

Literatur yang dikumpulkan kemudian dikelompokkan berdasarkan tema: (a) konsep dan arsitektur digital twin dalam kesehatan, dengan fokus pada framework state-of-the-art seperti Rad dkk. (2024) dan Zhang dkk. (2024); (b) metode prediksi glukosa darah menggunakan machine learning dan deep learning; (c) dataset diabetes yang tersedia secara publik; (d) metrik evaluasi sistem prediktif kesehatan; dan (e) tantangan implementasi teknologi kesehatan digital di negara berkembang.

### I.5.2 Analisis Kebutuhan dan Perancangan Sistem

Menentukan kebutuhan fungsional sistem digital twin yang disederhanakan, dengan fokus pada:

- **Pengelolaan data simulatif:** Kemampuan untuk membaca, memproses, dan menyimpan data dari dataset publik dalam format yang konsisten.
- **Modul preprocessing:** Pembersihan data, normalisasi, dan feature engineering untuk persiapan training model.
- **Modul prediksi:** Implementasi model pembelajaran mesin untuk prediksi glukosa darah.
- **Modul evaluasi:** Perhitungan metrik akurasi dan visualisasi hasil prediksi.

Mendesain arsitektur sistem yang terdiri dari tiga komponen utama yang disederhanakan:

1. **Data Management Module:** Modul untuk loading dan preprocessing data dari dataset publik (OhioT1DM atau UVA/Padova), tanpa perlu integrasi dengan sistem EHR atau sensor real-time.
2. **Simplified Patient Digital Model:** Representasi pasien berbasis feature vector yang berisi variabel-variabel penting (glucose history, carbohydrate intake, insulin dosage, physical activity) tanpa menggunakan knowledge graph.
3. **Prediction Engine:** Model pembelajaran mesin (LSTM atau Random Forest) yang dilatih untuk memprediksi kadar glukosa darah berdasarkan data historis, dengan fokus pada efisiensi komputasi dan kemudahan deployment.

### I.5.3 Implementasi Sistem

Mengembangkan sistem berbasis Python dengan menggunakan framework dan library berikut:

- **Data processing:** Pandas, NumPy untuk manipulasi data.
- **Machine learning:** Scikit-learn untuk model tradisional (Random Forest, SVM).
- **Deep learning:** TensorFlow atau PyTorch untuk model LSTM/GRU.
- **Visualisasi:** Matplotlib, Seaborn untuk visualisasi hasil prediksi.
- **Evaluasi:** Implementasi metrik RMSE, MAE, dan Clarke Error Grid Analysis.

Tahapan pengembangan model meliputi:

1. Eksplorasi dan analisis dataset untuk memahami distribusi dan karakteristik data.
2. Feature engineering untuk mengekstrak fitur-fitur yang relevan.

3. Pembagian data menjadi training, validation, dan testing set.
4. Pelatihan model dengan hyperparameter tuning.
5. Evaluasi performa model pada test set.

#### I.5.4 Validasi dan Evaluasi

Melakukan pengujian model dengan metrik evaluasi berikut:

- **Root Mean Square Error (RMSE)**: Mengukur rata-rata deviasi prediksi dari nilai aktual.
- **Mean Absolute Error (MAE)**: Mengukur rata-rata absolut error.
- **Clarke Error Grid Analysis (EG)**: Mengukur clinical accuracy dengan meng-kategorikan error berdasarkan risk.

## BAB II

### STUDI LITERATUR

#### II.1 Konsep Digital Twin

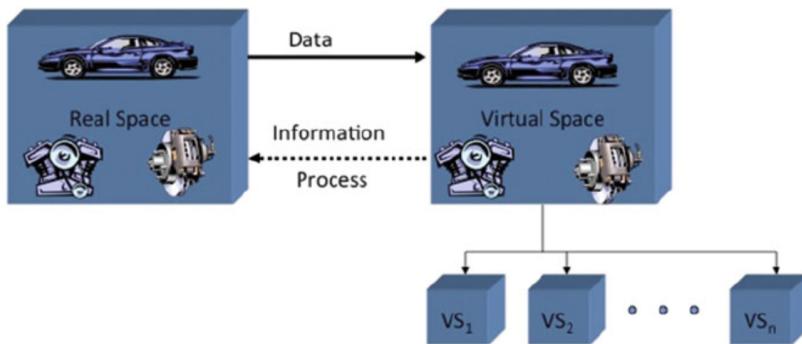
Konsep *Digital Twin* (DT) pertama kali diperkenalkan oleh Grieves dan Vickers (2017) sebagai bagian dari paradigma *Product Lifecycle Management* (PLM). DT didefinisikan sebagai representasi digital dari suatu entitas fisik yang secara dinamis diperbarui melalui aliran data dua arah antara dunia nyata (*real space*) dan dunia virtual (*virtual space*). Melalui keterhubungan tersebut, sistem DT dapat melakukan pemantauan, simulasi, serta prediksi terhadap perilaku dan kondisi objek fisik secara berkelanjutan.

Secara umum, arsitektur DT terdiri dari tiga komponen utama:

1. **Physical Entity**, yaitu objek nyata yang menjadi sumber data (contohnya mesin industri, kendaraan, atau pasien dalam konteks medis);
2. **Digital Representation**, yaitu model virtual yang merepresentasikan perilaku dan karakteristik objek fisik;
3. **Data Connection Layer**, yaitu lapisan penghubung yang mengintegrasikan aliran data dua arah antara model digital dan entitas fisik, baik untuk pembauran kondisi maupun umpan balik hasil simulasi.

Contoh arsitektur dasar DT dapat dilihat pada Gambar II.1. Diagram tersebut merupakan model konseptual awal yang dikembangkan oleh Grieves untuk menjelaskan hubungan dua ruang antara sistem fisik dan sistem virtual pada konteks PLM.

Gambar II.1 menampilkan dua ruang utama, yaitu *Real Space* dan *Virtual Space*. Pada bagian *Real Space*, terdapat entitas fisik yang menghasilkan data melalui sensor dan sistem pengukuran. Data tersebut dikirim ke *Virtual Space* untuk memperbaiki model digital secara berkelanjutan. Sebaliknya, hasil simulasi dan analisis dari model virtual dikirim kembali ke sistem fisik sebagai informasi atau proses kontrol.



Gambar II.1 Model konseptual *Digital Twin* yang menunjukkan keterhubungan antara ruang fisik dan ruang virtual. Diadaptasi dari Grieves dan Vickers (2017).

Siklus pertukaran data ini menciptakan hubungan dua arah yang memungkinkan DT berfungsi sebagai sistem adaptif dan prediktif (Grieves dan Vickers 2017).

Menurut Bruynseels, Santoni de Sio, dan Hoven (2018), keunggulan utama DT terletak pada kemampuannya untuk menghasilkan *living model*, yakni model yang tidak hanya merepresentasikan kondisi statis suatu sistem, tetapi juga mampu berevolusi mengikuti dinamika data aktual. Hal ini menjadikan DT sangat potensial dalam pengembangan sistem prediktif di berbagai bidang, termasuk manufaktur, pertahanan, energi, dan kesehatan.

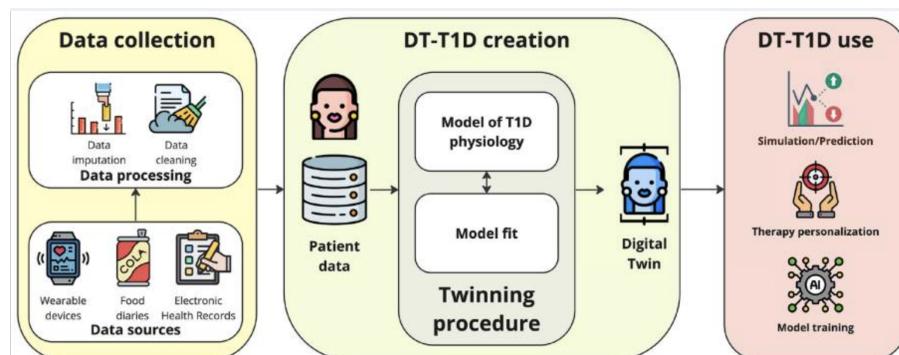
Lebih lanjut, Cappon, Facchinetti, dan Sparacino (2024) menjelaskan bahwa arsitektur DT modern telah berevolusi dari model PLM klasik menjadi sistem terintegrasi multi-sumber data. Model ini tidak hanya menerima input dari sensor fisik, tetapi juga dari basis pengetahuan eksternal seperti rekam medis elektronik, data *wearable devices*, dan sistem informasi klinis. Dengan kemampuan integrasi ini, DT berfungsi sebagai platform analitik cerdas yang mampu melakukan prediksi, optimasi, dan personalisasi secara simultan.

Dalam konteks penelitian ini, pemahaman terhadap konsep dan arsitektur dasar DT menjadi landasan untuk mengembangkan model *Digital Twin* yang dapat merepresentasikan kondisi fisiologis pasien diabetes tipe 2 secara virtual. Model digital tersebut akan digunakan untuk proses simulasi dan prediksi kadar glukosa darah berdasarkan data simulatif, sebelum nantinya dikembangkan lebih lanjut melalui pendekatan *Retrieval-Augmented Generation (RAG)* di bab berikutnya.

## II.2 Digital Twin dalam Bidang Kesehatan

Konsep *Digital Twin* telah berkembang pesat dalam bidang kesehatan dan kedokteran presisi selama satu dekade terakhir. Menurut Bruynseels, Santoni de Sio, dan Hoven (2018), penerapan DT di bidang medis membuka peluang untuk mengembangkan model digital pasien yang mampu merepresentasikan kondisi fisiologis individu secara dinamis. Model tersebut dapat digunakan untuk melakukan prediksi hasil klinis, simulasi pengobatan, hingga personalisasi terapi berdasarkan karakteristik spesifik pasien.

Salah satu penerapan paling menonjol adalah pada bidang manajemen penyakit kronis seperti diabetes. Cappon, Facchinetti, dan Sparacino (2024) dalam tinjauan sistematisnya menunjukkan bahwa DT digunakan untuk mensimulasikan perilaku metabolismik tubuh dan memprediksi kadar glukosa darah berdasarkan data historis pasien. Sistem ini berfungsi sebagai *virtual replica* dari tubuh pasien yang beroperasi secara paralel dengan sistem nyata untuk memberikan wawasan tentang status kesehatan serta potensi respon terhadap terapi.



Gambar II.2 Arsitektur umum *Digital Twin* dalam bidang kesehatan yang mengintegrasikan data dari perangkat medis, sensor, dan catatan kesehatan elektronik. Diadaptasi dari Cappon, Facchinetti, dan Sparacino (2024).

Gambar II.2 menampilkan arsitektur umum *Digital Twin* dalam bidang kesehatan sebagaimana dijelaskan oleh Cappon, Facchinetti, dan Sparacino (2024). Diagram tersebut memperlihatkan bahwa DT medis terdiri atas beberapa lapisan integrasi data, meliputi:

1. **Sumber Data Fisik**, yang mencakup perangkat medis seperti *Continuous Glucose Monitoring* (CGM), sensor aktivitas, dan perangkat *wearable*;
2. **Lapisan Data dan Analitik**, tempat data klinis, fisiologis, dan perilaku pasien diproses serta diintegrasikan ke dalam model digital;
3. **Model Digital Pasien (Patient Twin)**, yaitu representasi virtual pasien yang

- digunakan untuk prediksi, simulasi, dan evaluasi terapi; serta
4. **Interface Klinik**, yang memungkinkan dokter atau sistem pendukung keputusan memanfaatkan hasil simulasi untuk tindakan medis.

Melalui arsitektur tersebut, sistem DT memungkinkan analisis prediktif yang lebih akurat karena dapat memperhitungkan variabilitas fisiologis antar individu. Rad dkk. (2024) bahkan mengusulkan framework *Patient-Centric Digital Twin* berbasis *Personal Health Knowledge Graph (PHKG)* yang mampu mengintegrasikan berbagai sumber data klinis dengan standar interoperabilitas HL7 FHIR. Framework tersebut terbukti mampu meningkatkan akurasi prediksi kadar glukosa dengan nilai *Root Mean Square Error (RMSE)* sebesar 19,83 mg/dL.

Zhang dkk. (2024) memperluas konsep ini dengan mengintegrasikan data multi-omics ke dalam model DT untuk memprediksi progresi penyakit *Type 2 Diabetes Mellitus* (T2DM). Pendekatan tersebut menunjukkan potensi besar DT dalam mendukung *personalized medicine* dengan memanfaatkan data fisiologis, genetik, dan perilaku secara holistik.

Meskipun hasilnya menjanjikan, sebagian besar penerapan DT di bidang kesehatan masih menghadapi kendala berupa kebutuhan akan infrastruktur teknologi tinggi, biaya perangkat medis, dan ketersediaan data real-time yang memadai (Cappon, Facchinetti, dan Sparacino 2024; Rad dkk. 2024). Tantangan ini semakin besar di negara berkembang, di mana infrastruktur digital dan rekam medis elektronik belum merata. Oleh karena itu, adaptasi konsep DT dengan pendekatan berbasis data simulatif dan kecerdasan buatan menjadi alternatif yang relevan untuk konteks sistem kesehatan seperti di Indonesia.

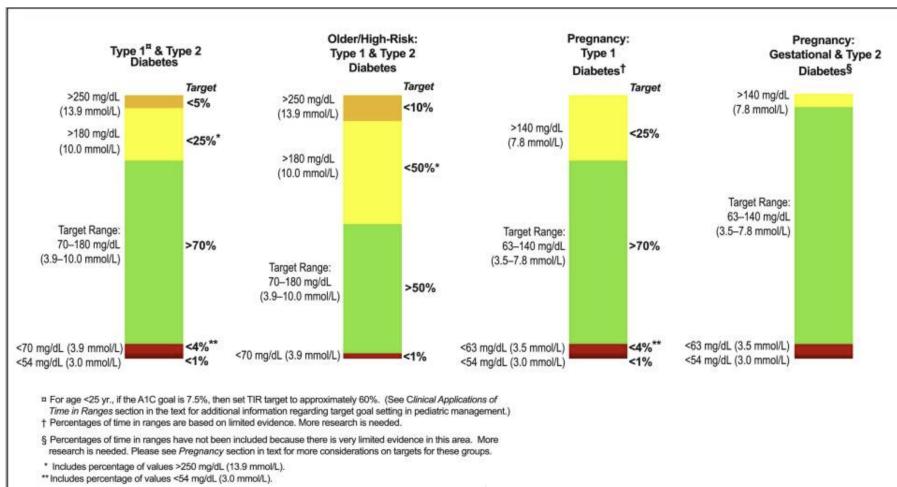
### **II.3 Manajemen Diabetes dan Pendekatan Digital**

*Diabetes Mellitus* (DM) merupakan penyakit metabolismik kronis yang ditandai oleh meningkatnya kadar glukosa darah akibat gangguan pada sekresi atau kerja insulin. Bentuk yang paling umum adalah *Diabetes Mellitus Tipe 2* (T2DM) yang menyumbang lebih dari 90% kasus diabetes di dunia dan di Indonesia (World Health Organization 2023). Penyakit ini berhubungan erat dengan resistensi insulin serta penurunan sensitivitas sel terhadap glukosa, sehingga pengelolaan kadar glukosa menjadi aspek kunci dalam pencegahan komplikasi kronis seperti penyakit jantung, gagal ginjal, neuropati, dan kebutaan.

Pendekatan konvensional dalam manajemen T2DM melibatkan pemantauan kadar glukosa darah secara berkala, pengaturan pola makan, aktivitas fisik, serta pem-

berian terapi insulin atau obat oral. Namun, strategi ini seringkali bersifat reaktif, yaitu penyesuaian dilakukan setelah kadar glukosa menyimpang dari rentang normal. Pendekatan seperti ini belum sepenuhnya mampu mencegah fluktuasi glukosa ekstrem yang berisiko menimbulkan komplikasi jangka panjang (Alkaff dkk. 2021).

Untuk meningkatkan efektivitas pengelolaan diabetes, berbagai teknologi digital telah dikembangkan, antara lain *Continuous Glucose Monitoring* (CGM) dan *insulin pump* yang memungkinkan pemantauan dan penyesuaian terapi secara real-time (Battelino, Danne, Bergenstal, dkk. 2019). Sistem ini mengubah paradigma pengelolaan diabetes dari berbasis manual menjadi berbasis data (*data-driven management*). Selain itu, penggunaan aplikasi mobile dan perangkat *wearable* juga memungkinkan pasien untuk melacak pola makan, aktivitas fisik, serta kadar glukosa harian secara otomatis.



Gambar II.3 Contoh sistem pemantauan kadar glukosa darah berkelanjutan (*Continuous Glucose Monitoring*) yang digunakan dalam manajemen diabetes. Diadaptasi dari Battelino, Danne, Bergenstal, dkk. (2019).

Gambar II.3 memperlihatkan contoh sistem *Continuous Glucose Monitoring* (CGM) yang memungkinkan akuisisi data glukosa secara kontinu dari sensor subkutan. Data dari CGM dikirim ke perangkat penerima atau aplikasi seluler untuk analisis dan visualisasi pola glukosa pasien. Informasi ini dapat digunakan untuk menyesuaikan dosis insulin secara otomatis atau semi-otomatis, sehingga membantu menjaga kadar glukosa dalam rentang aman (Battelino, Danne, Bergenstal, dkk. 2019).

Selanjutnya, kemajuan dalam bidang *machine learning* memungkinkan analisis pola data glukosa dalam jangka panjang untuk tujuan prediktif. Woldaregay, Årsand, Walderhaug, dkk. (2019) mengembangkan model pembelajaran mesin yang mampu memprediksi fluktuasi glukosa darah jangka pendek berdasarkan data historis

pasien. Pendekatan ini menunjukkan bahwa model berbasis data dapat membantu pasien mengantisipasi episode hipoglikemia atau hiperglikemia sebelum terjadi.

Meskipun teknologi tersebut memberikan kemajuan signifikan, penerapannya di Indonesia masih terbatas. Studi oleh Ramadaniati dkk. (2024) menunjukkan bahwa harga perangkat CGM di Indonesia relatif tinggi, dengan biaya yang dapat mencapai satu hingga dua bulan gaji rata-rata pasien. Kondisi ini menimbulkan tantangan dalam pemerataan akses terhadap teknologi pemantauan digital, terutama di fasilitas kesehatan primer.

Oleh karena itu, diperlukan pendekatan alternatif yang lebih terjangkau namun tetap memiliki kemampuan prediktif tinggi. Salah satu solusi yang potensial adalah penggunaan model *Digital Twin* berbasis data simulatif, yang dapat menggantikan kebutuhan perangkat real-time melalui pemanfaatan data historis atau sintetis untuk pelatihan model prediksi glukosa. Pendekatan ini membuka peluang bagi pengembangan sistem prediktif adaptif yang relevan untuk konteks sumber daya terbatas seperti di Indonesia.

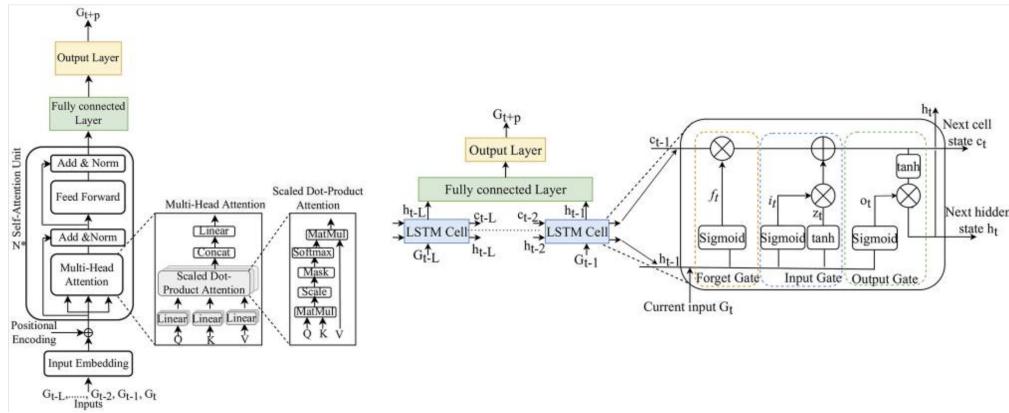
#### **II.4 Metode Machine Learning untuk Prediksi Kadar Glukosa**

Prediksi kadar glukosa darah merupakan salah satu tantangan utama dalam manajemen *Diabetes Mellitus*. Kompleksitas hubungan antara berbagai variabel fisiologis seperti asupan karbohidrat, dosis insulin, aktivitas fisik, dan stres membuat pendekatan konvensional berbasis model matematis sulit mencapai akurasi tinggi. Dalam konteks ini, pendekatan *machine learning* (ML) muncul sebagai solusi potensial untuk menangkap pola non-linear yang tidak dapat dimodelkan secara eksplisit.

Menurut Woldaregay, Årsand, Walderhaug, dkk. (2019), model pembelajaran mesin dapat mempelajari hubungan kompleks antara variabel fisiologis dari data historis pasien. Pendekatan ini melibatkan pelatihan algoritma menggunakan dataset yang berisi pasangan masukan (misalnya kadar glukosa sebelumnya, dosis insulin, asupan makanan) dan keluaran (kadar glukosa berikutnya). Setelah dilatih, model dapat digunakan untuk memprediksi kadar glukosa masa depan berdasarkan pola yang telah dipelajari.

Beberapa algoritma yang umum digunakan dalam prediksi glukosa antara lain *Random Forest (RF)*, *Support Vector Regression (SVR)*, dan model berbasis jaringan saraf dalam seperti *Long Short-Term Memory (LSTM)* (Li, Zhang, dan Zhao 2022). Model LSTM populer karena kemampuannya memproses data deret waktu dan mem-

pertahankan informasi jangka panjang melalui mekanisme *memory cell* dan *gating*.



Gambar II.4 Arsitektur model *Long Short-Term Memory (LSTM)* dengan mekanisme *attention* untuk prediksi kadar glukosa darah jangka pendek. Model ini mengombinasikan lapisan *self-attention*, unit *LSTM*, dan lapisan keluaran terhubung penuh untuk memproses deret waktu kadar glukosa. Diadaptasi dari Ghimire, Chen, Schenck, dkk. (2024).

Gambar II.4 menunjukkan arsitektur gabungan *LSTM-Attention* sebagaimana dijelaskan oleh Ghimire, Chen, Schenck, dkk. (2024). Model ini terdiri dari tiga bagian utama. Pertama, lapisan *input embedding* dan *self-attention* bertugas mengekstraksi fitur temporal penting dari data kadar glukosa historis. Kedua, lapisan *LSTM cell* menangkap dependensi jangka panjang dan hubungan non-linear antar nilai glukosa, sementara mekanisme gerbang—*forget gate*, *input gate*, dan *output gate*—mengatur aliran informasi antar langkah waktu. Ketiga, lapisan keluaran (*fully connected layer* dan *output layer*) menghasilkan prediksi kadar glukosa masa depan  $G_{t+p}$  berdasarkan masukan deret waktu  $G_{t-L}, G_{t-L+1}, \dots, G_t$ .

Kombinasi antara *attention mechanism* dan arsitektur LSTM terbukti meningkatkan kemampuan model dalam menangkap hubungan temporal yang kompleks dibandingkan LSTM murni (Ghimire, Chen, Schenck, dkk. 2024). Pendekatan ini memungkinkan model untuk fokus pada segmen data yang paling relevan untuk prediksi, sehingga meningkatkan akurasi dan stabilitas hasil pada berbagai dataset pasien.

Untuk menilai kinerja model prediktif, digunakan berbagai metrik evaluasi kuantitatif. Dua metrik yang paling umum adalah *Root Mean Square Error (RMSE)* dan *Mean Absolute Error (MAE)*. RMSE mengukur akar rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi, sedangkan MAE mengukur rata-rata selisih absolut keduanya. Rumus matematis dari kedua metrik tersebut diberikan pada Persamaan II.1.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (\text{II.1})$$

Nilai RMSE dan MAE yang lebih kecil menunjukkan performa model yang lebih baik. Selain metrik statistik, beberapa penelitian juga menggunakan metrik berbasis klinis seperti *Clarke Error Grid (CEG)* untuk mengevaluasi implikasi klinis dari kesalahan prediksi (Battelino, Danne, Bergenstal, dkk. 2019). Dengan kombinasi evaluasi matematis dan klinis ini, model pembelajaran mesin dapat dinilai tidak hanya berdasarkan akurasi prediksi, tetapi juga keamanan penerapannya dalam konteks medis.

Pendekatan berbasis ML seperti LSTM memiliki potensi besar untuk diintegrasikan dengan konsep *Digital Twin*. Model DT dapat menggunakan hasil prediksi ML untuk memperbarui kondisi virtual pasien secara real-time, sementara data simulatif dari DT dapat digunakan kembali untuk melatih model ML, menciptakan sistem pembelajaran adaptif dua arah antara dunia nyata dan digital.

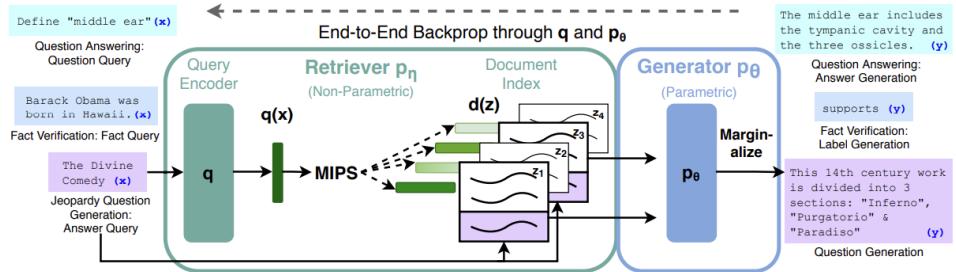
## II.5 Retrieval-Augmented Generation (RAG) Framework

*Retrieval-Augmented Generation (RAG)* merupakan pendekatan dalam bidang *Natural Language Processing (NLP)* yang mengombinasikan dua proses utama, yaitu *retrieval* dan *generation*. Pendekatan ini pertama kali diperkenalkan oleh Lewis dkk. (2020) untuk meningkatkan kemampuan model generatif dalam menghasilkan keluaran yang faktual dan berbasis pengetahuan. Tidak seperti model generatif murni yang mengandalkan parameter internal untuk seluruh proses inferensi, RAG memungkinkan model mengakses basis pengetahuan eksternal secara dinamis.

Arsitektur RAG terdiri atas dua komponen utama:

1. **Retriever**, yaitu modul non-parametrik yang bertugas mencari potongan informasi atau dokumen yang relevan dari basis pengetahuan eksternal menggunakan metode pencarian berbasis vektor seperti *Maximum Inner Product Search (MIPS)*;
2. **Generator**, yaitu model bahasa besar berbasis *sequence-to-sequence transformer* yang menghasilkan keluaran akhir berdasarkan masukan dan konteks hasil *retrieval*.

Gambar II.5 memperlihatkan alur kerja RAG sebagaimana dijelaskan oleh Lewis dkk. (2020). Proses dimulai dengan kueri masukan (*query encoder*) yang diubah



Gambar II.5 Arsitektur *Retrieval-Augmented Generation (RAG)* yang terdiri atas dua komponen utama: *Retriever* untuk mengambil dokumen relevan dari basis pengetahuan eksternal dan *Generator* untuk menghasilkan keluaran berbasis konteks. Model dilatih secara end-to-end sehingga kedua komponen dapat dioptimalkan bersamaan. Diadaptasi dari Lewis dkk. (2020).

menjadi representasi vektor. Representasi ini digunakan oleh modul *retriever* untuk mencari dokumen relevan dari indeks pengetahuan eksternal. Dokumen yang di temukan kemudian diteruskan ke modul *generator*, yang memanfaatkan informasi tersebut untuk membentuk keluaran berbasis konteks. Proses pelatihan dilakukan secara end-to-end dengan pembaruan parameter bersama melalui mekanisme *backpropagation*, sebagaimana ditunjukkan oleh panah berlabel “End-to-End Backprop through q and  $p_\theta$ ”.

Pendekatan ini memberikan peningkatan signifikan dibandingkan model generatif murni karena mampu:

- Mengakses pengetahuan terkini tanpa perlu pelatihan ulang model besar;
- Menghasilkan keluaran yang lebih faktual, relevan, dan dapat ditelusuri sumbernya;
- Mengurangi fenomena *hallucination* dalam keluaran model bahasa besar.

Borgeaud dkk. (2022) memperluas konsep ini melalui integrasi retrieval skala besar, memungkinkan model mengakses triliunan token teks eksternal secara efisien untuk meningkatkan penalaran berbasis pengetahuan. Hasil penelitian tersebut menunjukkan bahwa RAG dapat berfungsi sebagai mekanisme penghubung antara model generatif dan sistem pencarian, menjadikannya salah satu pendekatan utama dalam pengembangan kecerdasan buatan berbasis pengetahuan.

Dalam konteks kesehatan digital, framework RAG berpotensi diintegrasikan dengan *Digital Twin*. Model DT yang biasanya bergantung pada data fisiologis pasien dapat diperluas dengan mengakses basis pengetahuan medis eksternal, seperti literatur ilmiah atau panduan klinis. Melalui integrasi ini, *RAG Digital Twin* dapat memanfaatkan data pasien internal bersama dengan informasi medis eksternal untuk meng-

hasilkan rekomendasi yang lebih adaptif, berbasis bukti, dan kontekstual.

## II.6 Penelitian Terkait

Berbagai penelitian telah dilakukan untuk mengembangkan model *Digital Twin* dan sistem prediktif berbasis *machine learning* dalam bidang kesehatan, khususnya manajemen *Diabetes Mellitus*. Beberapa studi juga mulai mengeksplorasi integrasi antara pembelajaran mesin, representasi pengetahuan, dan sistem generatif seperti *Retrieval-Augmented Generation (RAG)*. Tinjauan ini bertujuan untuk mengidentifikasi kemajuan terkini sekaligus menemukan celah penelitian yang relevan untuk konteks Indonesia.

Berdasarkan Tabel II.1, penelitian Rad dkk. (2024), Zhang dkk. (2024), dan Cappon, Facchinetti, dan Sparacino (2024) berfokus pada penerapan *Digital Twin* untuk manajemen diabetes dengan data real-time dari perangkat medis. Meskipun hasilnya menjanjikan, pendekatan tersebut masih memiliki keterbatasan pada aspek biaya, kompleksitas teknologi, dan ketergantungan terhadap infrastruktur *Electronic Health Records (EHR)* yang belum merata di negara berkembang seperti Indonesia.

Sementara itu, penelitian Woldaregay, Årsand, Walderhaug, dkk. (2019), Li, Zhang, dan Zhao (2022), dan Ghimire, Chen, Schenck, dkk. (2024) menunjukkan bahwa model *machine learning* berbasis deret waktu mampu memprediksi kadar glukosa dengan akurasi tinggi, bahkan menggunakan data simulatif atau publik. Namun, model tersebut masih terbatas pada konteks prediksi numerik dan belum mengintegrasikan pengetahuan klinis eksplisit.

Penelitian Lewis dkk. (2020) dan Borgeaud dkk. (2022) memperkenalkan paradigma *Retrieval-Augmented Generation (RAG)*, yang menggabungkan pencarian informasi eksternal dengan keluaran generatif. Pendekatan ini potensial jika diadaptasi untuk domain medis, di mana sistem tidak hanya memprediksi nilai glukosa tetapi juga menjelaskan dasar fisiologis hasil prediksi tersebut.

Celah penelitian ini menjadi dasar pengembangan ***RAG Digital Twin Framework for Blood Glucose Prediction***, yang akan dibahas pada Bab III.

Tabel II.1 Ringkasan penelitian terkait *Digital Twin* dan prediksi kadar glukosa darah.

<b>Peneliti (Tahun)</b>	<b>Pendekatan / Model</b>	<b>Konteks / Dataset</b>	<b>Hasil Utama / Temuan</b>
Bruynseels, Santoni de Sio, dan Hoven (2018)	Konseptualisasi <i>Digital Twin</i> dalam etika kesehatan	Literatur konseptual	Menyoroti aspek etika dan tanggung jawab sosial dalam penerapan DT di kesehatan.
Cappon, Facchinetti, dan Sparacino (2024)	<i>Digital Twin</i> untuk T1DM	Dataset CGM	Arsitektur tiga tahap (data collection, twin creation, twin use); potensi tinggi namun infrastruktur mahal.
Rad dkk. (2024)	<i>Patient-Centric Digital Twin</i> berbasis PHKG	Data EHR dan <i>wearable</i> (HL7 FHIR)	RMSE 19.83 mg/dL; memberikan rekomendasi insulin dan diet personal.
Zhang dkk. (2024)	Integrasi DT dengan data multi-omics	Dataset simulatif T2DM	Prediksi progresi T2DM akurat; masih bergantung pada infrastruktur besar.
Woldaregay, Årsand, Walderhaug, dkk. (2019)	<i>Machine Learning</i> untuk prediksi glukosa	Dataset CGM (real patient)	Model prediksi jangka pendek berbasis regresi non-linear; baseline data-driven.
Ghimire, Chen, Schenck, dkk. (2024)	<i>LSTM + Attention</i> untuk prediksi glukosa	Beberapa dataset publik	Model dengan <i>attention</i> menunjukkan generalisasi lintas dataset yang lebih baik.
Li, Zhang, dan Zhao (2022)	<i>Deep Learning (LSTM)</i> untuk prediksi glukosa	Dataset CGM individual	LSTM outperform model klasik dengan RMSE rata-rata $\leq$ 22 mg/dL.

*Bersambung ke halaman berikutnya*

Tabel II.1 Ringkasan penelitian terkait *Digital Twin* dan prediksi kadar glukosa darah (*lanjutan*)

<b>Peneliti (Tahun)</b>	<b>Pendekatan / Mo- del</b>	<b>Konteks / Dataset</b>	<b>Hasil Utama / Te- muan</b>
Lewis dkk. (2020)	<i>Retrieval-Augmented Generation (RAG)</i>	Tugas NLP berbasis pengetahuan	Framework retriever-generator meningkatkan akurasi dan relevansi keluaran generatif.
Borgeaud dkk. (2022)	RAG skala besar dengan <i>retrieval transformer</i>	Basis data 10 triliun token	Mengurangi <i>hallucination</i> dan meningkatkan efisiensi pelajaran berbasis pengetahuan.

## II.7 Tantangan Implementasi di Indonesia

Penerapan *Digital Twin* dalam konteks Indonesia menghadapi beberapa hambatan struktural. Pertama, tingkat kesiapan teknologi informasi dan komunikasi (TIK) antar fasilitas kesehatan masih bervariasi (Aisyah dkk. 2024). Kedua, perangkat medis pendukung seperti *Continuous Glucose Monitoring (CGM)* dan pompa insulin masih tergolong mahal dan belum tersedia secara luas (Ramadaniati dkk. 2024).

Selain itu, penelitian oleh Harahap, Handayani, dan Hidayanto (2023) menunjukkan bahwa integrasi data rekam medis elektronik masih terhambat oleh rendahnya adopsi sistem *Electronic Medical Record (EMR)*. Penelitian Abodunrin, Akande, dan Osagbemi (2020) di negara berkembang lain memperlihatkan bahwa kesadaran dan pelatihan tenaga medis terkait sistem digital kesehatan juga menjadi faktor penentu keberhasilan implementasi.

Oleh karena itu, penerapan *Digital Twin* di Indonesia perlu dimulai dari model sederhana berbasis data simulatif dan pembelajaran mesin yang ringan.

## **BAB III**

### **ANALISIS MASALAH**

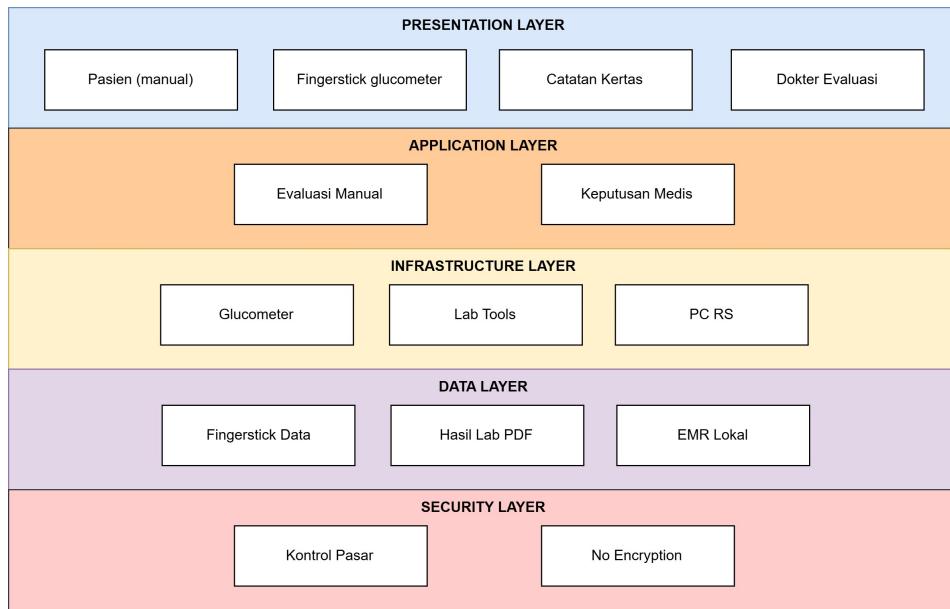
#### **III.1 Analisis Kondisi Saat Ini**

Analisis kondisi sistem saat ini dilakukan untuk memahami bagaimana sistem pengelolaan *Diabetes Mellitus* (DM) beroperasi, baik pada tataran global maupun nasional, sebelum dilakukan perancangan sistem baru. Pada konteks global, manajemen penyakit diabetes telah berkembang menuju sistem pemantauan real-time berbasis perangkat medis seperti *Continuous Glucose Monitoring* (CGM) dan *insulin pump*. Teknologi ini memungkinkan pasien dan tenaga medis untuk memperoleh data kadar glukosa darah secara berkelanjutan, yang selanjutnya dapat digunakan untuk menyesuaikan dosis insulin serta pola makan secara dinamis (Battelino, Danne, Bergenstal, dkk. 2019).

Namun demikian, sebagian besar sistem tersebut masih bersifat reaktif. Artinya, tindakan medis baru dilakukan setelah kadar glukosa pasien menunjukkan penyimpangan dari nilai normal. Selain itu, sistem pemantauan tersebut belum sepenuhnya memanfaatkan potensi analisis prediktif atau simulasi perilaku metabolismik pasien secara digital. Inovasi seperti *Digital Twin* mulai diterapkan di beberapa penelitian untuk menciptakan representasi virtual kondisi pasien yang dapat digunakan dalam simulasi terapi (Bruynseels, Santoni de Sio, dan Hoven 2018), tetapi implementasinya masih terbatas pada institusi dengan sumber daya dan infrastruktur digital yang tinggi.

Di Indonesia, sebagian besar pengelolaan data pasien diabetes masih dilakukan secara manual atau semi-digital. Pencatatan hasil pemeriksaan laboratorium, kadar glukosa darah, dan riwayat terapi umumnya dilakukan melalui sistem informasi rumah sakit yang belum terintegrasi antarfasilitas. Meskipun pemerintah telah mendorong adopsi *Electronic Medical Record* (EMR), tingkat interoperabilitas antar sistem masih rendah (Harahap, Handayani, dan Hidayanto 2023; Aisyah dkk. 2024). Kondisi

ini menyebabkan data pasien sering kali terfragmentasi, sehingga sulit digunakan untuk analisis longitudinal maupun pengembangan model prediktif.



Gambar III.1 Model konseptual sistem manajemen diabetes konvensional. Sistem saat ini terdiri atas subsistem klinis, pasien, dan perangkat medis dengan aliran data satu arah tanpa integrasi analitik cerdas.

Gambar III.1 memperlihatkan model konseptual sistem manajemen diabetes konvensional. Sistem ini umumnya terdiri atas tiga subsistem utama:

1. **Subsistem Klinis**, yang mencakup dokter, tenaga medis, dan sistem EMR untuk pencatatan diagnosis, terapi, dan tindak lanjut pasien;
2. **Subsistem Pasien**, yang menjadi sumber data fisiologis seperti hasil pemeriksaan laboratorium, kadar glukosa mandiri, dan data dari perangkat CGM;
3. **Subsistem Perangkat Medis**, yang mengumpulkan data sensorik dari tubuh pasien seperti kadar glukosa, dosis insulin, dan aktivitas fisik.

Ketiga subsistem tersebut berinteraksi melalui proses manual atau semi-digital. Data dari pasien dikirim ke tenaga medis untuk evaluasi, namun umumnya tidak dilakukan sinkronisasi otomatis ke sistem analitik yang mampu melakukan prediksi. Aliran data bersifat satu arah — dari pasien ke tenaga medis — tanpa umpan balik cerdas dari sistem untuk memberikan rekomendasi personal. Akibatnya, proses pengambilan keputusan medis masih bersifat *reactive* dan bergantung pada intervensi manual.

Kondisi ini menimbulkan sejumlah masalah utama:

- **Fragmentasi data pasien**: informasi kesehatan tersebar di berbagai sistem

tanpa integrasi yang memadai;

- **Keterbatasan analitik prediktif:** sistem eksisting hanya mendukung pencatatan dan pemantauan, belum melakukan prediksi perubahan kadar glukosa secara otomatis;
- **Keterbatasan perangkat:** perangkat CGM dan *insulin pump* masih tergolong mahal dan belum terjangkau oleh sebagian besar pasien di Indonesia (Ramadaniati dkk. 2024);
- **Kurangnya personalisasi terapi:** rekomendasi dosis insulin dan diet masih berbasis panduan umum, belum menyesuaikan kondisi fisiologis individu.

Dengan berbagai keterbatasan tersebut, sistem manajemen diabetes saat ini belum mampu memberikan dukungan pengambilan keputusan yang bersifat proaktif, adaptif, dan personal. Diperlukan pendekatan baru yang dapat mengintegrasikan data pasien, pengetahuan medis, serta kemampuan analitik berbasis *machine learning* untuk membangun sistem prediktif dan simulatif yang lebih efisien serta sesuai dengan kondisi infrastruktur kesehatan di Indonesia.

### III.2 Analisis Kebutuhan

Analisis kebutuhan dilakukan untuk mengidentifikasi permasalahan utama yang dihadapi pengguna dan menentukan kebutuhan sistem baru yang akan dikembangkan. Analisis ini mencakup dua aspek, yaitu kebutuhan fungsional dan kebutuhan nonfungsional. Tujuannya adalah untuk memastikan bahwa sistem yang dirancang mampu menjawab kebutuhan nyata pengguna sekaligus sesuai dengan batasan teknis dan operasional di lapangan.

#### III.2.1 Identifikasi Masalah Pengguna

Berdasarkan analisis kondisi eksisting, dapat diidentifikasi beberapa permasalahan yang dihadapi oleh para pemangku kepentingan utama (*stakeholder*) dalam sistem manajemen diabetes, yaitu pasien, tenaga medis, dan peneliti di bidang kesehatan digital:

1. **Pasien:** sebagian besar pasien belum memiliki akses terhadap perangkat pemantauan real-time seperti *Continuous Glucose Monitoring (CGM)* karena harganya yang relatif mahal (Ramadaniati dkk. 2024). Pasien juga kesulitan memahami hubungan antara aktivitas harian, pola makan, dan fluktuasi kadar glukosa karena kurangnya alat bantu prediktif yang mudah digunakan.
2. **Tenaga Medis:** dokter dan tenaga kesehatan masih mengandalkan data hasil pemeriksaan laboratorium atau catatan pasien untuk menentukan terapi, se-

hingga keputusan bersifat retrospektif. Minimnya dukungan sistem prediktif membuat tenaga medis sulit melakukan intervensi dini terhadap risiko hipoglikemia atau hiperglikemia (Aisyah dkk. 2024).

3. **Peneliti dan Pengembang Sistem Kesehatan Digital:** sulit mendapatkan data medis terintegrasi yang konsisten karena rendahnya interoperabilitas antar sistem informasi kesehatan (Harahap, Handayani, dan Hidayanto 2023). Kondisi ini menghambat pengembangan model analitik yang dapat digeneralisasi.

Permasalahan-permasalahan tersebut menunjukkan perlunya sistem yang mampu memanfaatkan data simulatif sebagai alternatif sumber data pasien. Sistem tersebut diharapkan dapat melakukan prediksi kadar glukosa darah serta menyediakan simulasi perilaku metabolisme pasien dengan biaya rendah dan tanpa ketergantungan pada perangkat medis real-time.

### III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional menggambarkan perilaku sistem yang diharapkan dari perspektif pengguna. Berdasarkan permasalahan yang diidentifikasi, kebutuhan fungsional dari sistem yang diusulkan meliputi:

Tabel III.1 Kebutuhan Fungsional Sistem

Kode	Deskripsi
FR-01	Sistem mampu membaca dan mengelola dataset simulatif seperti <i>OhioT1DM Dataset</i> atau <i>UVA/Padova Simulator</i> .
FR-02	Sistem mampu melakukan prediksi kadar glukosa darah jangka pendek menggunakan algoritma <i>machine learning</i> seperti LSTM atau model lain yang sesuai.
FR-03	Sistem menghitung metrik evaluasi seperti <i>RMSE</i> , <i>MAE</i> , dan <i>Clarke Error Grid</i> .
FR-04	Sistem menyediakan visualisasi grafik perubahan kadar glukosa aktual dan prediksi.
FR-05	Sistem mampu mensimulasikan perubahan kadar glukosa berdasarkan variasi input (insulin, karbohidrat, aktivitas) sebagai representasi <i>digital twin</i> .
FR-06	Sistem memiliki modul <i>Retrieval-Augmented Generation (RAG)</i> untuk mencari informasi medis relevan dari basis pengetahuan eksternal.

Kebutuhan fungsional ini menjadi dasar dalam perancangan arsitektur sistem *RAG Digital Twin*, di mana setiap modul berfungsi untuk menangani satu proses utama dari pipeline prediksi dan pembelajaran adaptif berbasis data.

### III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional berkaitan dengan aspek kualitas dan batasan teknis yang harus dipenuhi agar sistem dapat berjalan secara optimal. Beberapa kebutuhan non-fungsional yang diidentifikasi adalah sebagai berikut:

Tabel III.2 Kebutuhan Nonfungsional Sistem

Kode	Deskripsi
NFR-01	Sistem mampu melakukan pelatihan dan prediksi secara efisien pada komputer dengan sumber daya terbatas (GPU menengah).
NFR-02	Sistem menghasilkan nilai RMSE $\leq 25 \text{ mg/dL}$ , mendekati standar <i>state-of-the-art</i> .
NFR-03	Sistem menggunakan dataset simulatif publik tanpa biaya lisensi atau perangkat medis khusus.
NFR-04	Sistem mampu menangani data hilang melalui <i>data imputation</i> dan validasi sebelum pelatihan model.
NFR-05	Antarmuka sistem sederhana dan intuitif sehingga mudah digunakan tanpa keahlian teknis mendalam.
NFR-06	Sistem mematuhi prinsip keamanan data dan privasi, terutama jika integrasi data klinis nyata dilakukan di masa depan.

Kebutuhan fungsional dan nonfungsional tersebut menjadi acuan dalam perancangan sistem yang akan dijelaskan lebih lanjut pada Bab IV. Sistem ini diharapkan mampu mengisi kesenjangan antara kebutuhan prediksi glukosa yang akurat dan keterbatasan infrastruktur digital di Indonesia melalui penerapan konsep *RAG Digital Twin* berbasis data simulatif.

### III.3 Analisis Pemilihan Solusi

Berdasarkan hasil identifikasi masalah dan kebutuhan yang telah dijelaskan pada bagian sebelumnya, tahap ini bertujuan untuk menentukan pendekatan solusi yang paling sesuai dalam mengatasi keterbatasan sistem manajemen diabetes saat ini. Analisis dilakukan dengan membandingkan beberapa alternatif solusi yang secara teoritis

dapat diimplementasikan, kemudian memilih pendekatan yang paling tepat berdasarkan aspek akurasi, kompleksitas teknis, keterjangkauan, dan kesesuaian konteks infrastruktur di Indonesia.

### III.3.1 Alternatif Solusi

Berdasarkan tinjauan pustaka dan analisis kebutuhan, terdapat beberapa pendekatan yang dapat dijadikan alternatif solusi dalam pengembangan sistem prediksi kadar glukosa darah, yaitu:

1. **Sistem Berbasis Aturan (Rule-Based System)** Pendekatan ini menggunakan seperangkat aturan logika yang ditentukan oleh ahli medis untuk memprediksi atau memberikan saran terkait kadar glukosa darah. Sistem semacam ini relatif sederhana dan tidak membutuhkan data besar, namun memiliki keterbatasan dalam menangkap hubungan non-linear antar variabel fisiologis dan tidak adaptif terhadap perubahan perilaku pasien.
2. **Model Prediktif Berbasis Machine Learning** Pendekatan ini memanfaatkan model pembelajaran mesin seperti *Random Forest*, *Support Vector Regression (SVR)*, atau *Long Short-Term Memory (LSTM)* untuk memprediksi kadar glukosa berdasarkan data historis. Pendekatan ini telah terbukti meningkatkan akurasi prediksi dibandingkan metode berbasis aturan (Woldaregay, Årsand, Walderhaug, dkk. 2019; Ghimire, Chen, Schenck, dkk. 2024). Namun, model ini hanya berfokus pada pemrosesan data dan belum mampu memberikan konteks atau penjelasan medis dari hasil prediksi.
3. **Digital Twin Berbasis Simulasi Fisiologis** Pendekatan ini membangun replika virtual pasien (*digital twin*) berdasarkan model metabolismik fisiologis seperti *UVA/Padova T1D Simulator*. Digital twin ini mampu mensimulasikan respons pasien terhadap dosis insulin, asupan karbohidrat, dan aktivitas fisik (Cappon, Facchinetto, dan Sparacino 2024; Rad dkk. 2024). Walaupun akurat, pendekatan ini memerlukan data medis real-time dan infrastruktur perangkat keras mahal seperti *Continuous Glucose Monitoring (CGM)* serta sistem EMR terintegrasi, sehingga sulit diterapkan secara luas di Indonesia.
4. **RAG Digital Twin Framework (Retrieval-Augmented Generation)** Pendekatan ini menggabungkan kemampuan prediksi *machine learning* dengan sistem pencarian pengetahuan eksternal berbasis *Retrieval-Augmented Generation (RAG)*. Framework ini tidak hanya melakukan prediksi kadar glukosa, tetapi juga dapat memberikan justifikasi berbasis data medis atau literatur ilmiah (Lewis dkk. 2020; Borgeaud dkk. 2022). Dengan menggunakan data simulatif publik, framework ini dapat diimplementasikan tanpa perangkat me-

dis khusus, sekaligus menyediakan kemampuan pembelajaran adaptif yang menyerupai *digital twin* klinis.

Tabel III.3 Perbandingan alternatif solusi untuk prediksi kadar glukosa darah.

Pendekatan	Akurasi Prediksi	Kompleksitas Implementasi	Kebutuhan Infrastruktur	Kesesuaian Konteks Indonesia
Sistem Berbasis Aturan	Rendah (karena statis)	Rendah	Rendah	Sedang
Model <i>Machine Learning</i>	Sedang– Tinggi	Sedang	Sedang	Tinggi
<i>Digital Twin</i> Fisiologis	Tinggi	Sangat Tinggi	Sangat Tinggi (perlu CGM, EMR)	Rendah
<i>RAG Digital Twin Framework</i>	Tinggi	Sedang	Rendah (berbasis data simulatif)	Sangat Tinggi

### III.3.2 Analisis Penentuan Solusi

Berdasarkan perbandingan pada Tabel III.3, pendekatan *RAG Digital Twin Framework* dipilih sebagai solusi utama dalam penelitian ini. Pemilihan ini didasarkan pada beberapa pertimbangan berikut:

- Akurasi dan Fleksibilitas:** kombinasi antara model prediktif *machine learning* dan mekanisme retrieval memungkinkan sistem untuk menghasilkan prediksi yang akurat sekaligus memperkaya konteks klinis hasil prediksi dengan informasi ilmiah relevan.
- Keterjangkauan Implementasi:** framework ini dapat dikembangkan menggunakan data simulatif terbuka seperti *OhioT1DM Dataset* tanpa memerlukan perangkat medis real-time, sehingga sesuai untuk riset dan pembelajaran di lingkungan dengan keterbatasan sumber daya.
- Adaptabilitas dan Skalabilitas:** arsitektur RAG bersifat modular, sehingga dapat diintegrasikan dengan data klinis nyata di masa depan atau diperluas ke domain penyakit kronis lain.
- Kesesuaian Konteks Nasional:** pendekatan ini menjawab tantangan utama di Indonesia berupa keterbatasan infrastruktur digital kesehatan, biaya perangkat, dan rendahnya interoperabilitas antar sistem (Harahap, Handayani,

dan Hidayanto 2023; Aisyah dkk. 2024; Ramadaniati dkk. 2024).

Dengan mempertimbangkan faktor-faktor tersebut, pendekatan *RAG Digital Twin* dinilai paling sesuai untuk dikembangkan dalam penelitian ini. Framework ini diharapkan mampu menjadi dasar pengembangan sistem prediktif cerdas yang menggabungkan kemampuan analitik simulatif dan pengetahuan medis adaptif tanpa memerlukan infrastruktur kompleks.

Rancangan arsitektur, komponen utama, dan mekanisme integrasi sistem ini akan dijelaskan secara rinci pada Bab IV.

## BAB IV

### Desain Konsep Solusi

#### IV.1 Sistem Saat Ini (Before)

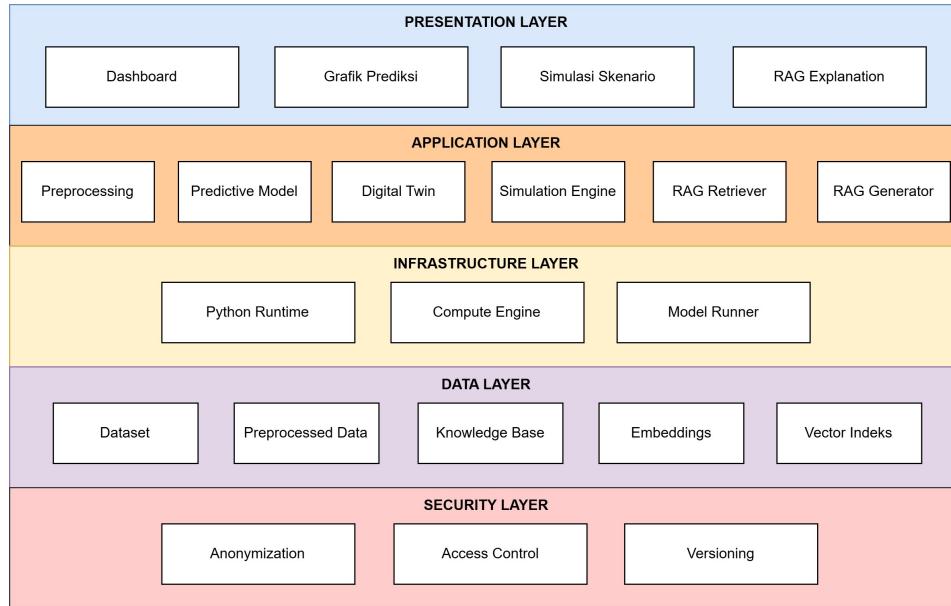
Model sistem saat ini telah ditampilkan pada Gambar III.1 pada Bab III. Sistem tersebut menggambarkan alur pengelolaan diabetes yang masih bersifat reaktif: data diperoleh melalui pemeriksaan manual atau berkala, kemudian tenaga medis meng-evaluasi kondisi pasien berdasarkan informasi yang terbatas. Beberapa keterbatasan sistem saat ini antara lain:

- aliran data satu arah dan tidak *real-time*;
- pemantauan berbasis *fingerstick* yang bersifat episodik;
- tidak adanya mekanisme prediksi kadar glukosa;
- tidak adanya representasi digital pasien atau *digital twin*;
- tidak adanya penjelasan berbasis pengetahuan atau analitik cerdas.

Keterbatasan tersebut memberikan dasar perlunya perancangan solusi yang lebih adaptif, prediktif, dan mampu menyediakan konteks klinis yang dapat diinterpretasikan.

#### IV.2 Model Konseptual Solusi (After)

Solusi yang diusulkan terdiri dari enam komponen utama yang bekerja secara terpadu: *Data Source Layer*, *Preprocessing Layer*, *Predictive Modeling Layer*, *Digital Twin Layer*, *RAG Knowledge Layer*, dan *Output & Visualization Layer*. Aliran data dalam sistem usulan bersifat dua arah, di mana model prediktif memperbarui *digital twin*, dan *digital twin* menyediakan konteks fisiologis bagi penjelasan berbasis RAG.



Gambar IV.1 Model konseptual sistem usulan berbasis *Digital Twin* dan *Retrieval-Augmented Generation*.

Gambar IV.1 memperlihatkan arsitektur sistem yang terdiri dari beberapa lapisan utama:

- Data Source Layer:** Lapisan paling bawah yang menyediakan data simulatif dari dataset publik seperti OhioT1DM atau UVA/Padova Simulator. Data mencakup riwayat glukosa darah, asupan karbohidrat, dosis insulin, dan aktivitas fisik.
- Preprocessing Layer:** Modul yang bertanggung jawab untuk pembersihan data, normalisasi, imputasi nilai yang hilang, dan ekstraksi fitur temporal. Proses ini mempersiapkan data agar siap digunakan oleh model prediktif.
- Predictive Modeling Layer:** Inti dari sistem prediksi yang menggunakan algoritma *machine learning* (seperti LSTM atau *Random Forest*) untuk memprediksi kadar glukosa darah jangka pendek berdasarkan pola historis.
- Digital Twin Layer:** Representasi virtual pasien yang diperbarui secara dinamis berdasarkan hasil prediksi. *Digital twin* ini dapat digunakan untuk simulasi skenario intervensi seperti perubahan dosis insulin atau pola makan.
- RAG Knowledge Layer:** Modul yang mengintegrasikan *Retrieval-Augmented Generation* untuk memberikan penjelasan klinis berbasis literatur medis dan panduan klinis. Modul ini mengakses basis pengetahuan eksternal untuk memberikan konteks pada hasil prediksi.
- Output & Visualization Layer:** Lapisan antarmuka yang menyajikan hasil prediksi, visualisasi tren glukosa, hasil simulasi, dan penjelasan klinis kepada

pengguna (pasien atau tenaga medis).

Secara keseluruhan, sistem memungkinkan prediksi kadar glukosa jangka pendek, pembaruan status fisiologis virtual, simulasi skenario intervensi, dan penyediaan penjelasan berbasis bukti. Hal ini menjadikan sistem lebih adaptif dan informatif dibandingkan dengan pendekatan konvensional yang bersifat reaktif.

#### IV.3 Perbandingan Sistem Before dan After

Tabel IV.1 merangkum perbedaan utama antara sistem saat ini (*before*) dan sistem usulan (*after*).

Tabel IV.1 Perbandingan sistem saat ini dan sistem usulan.

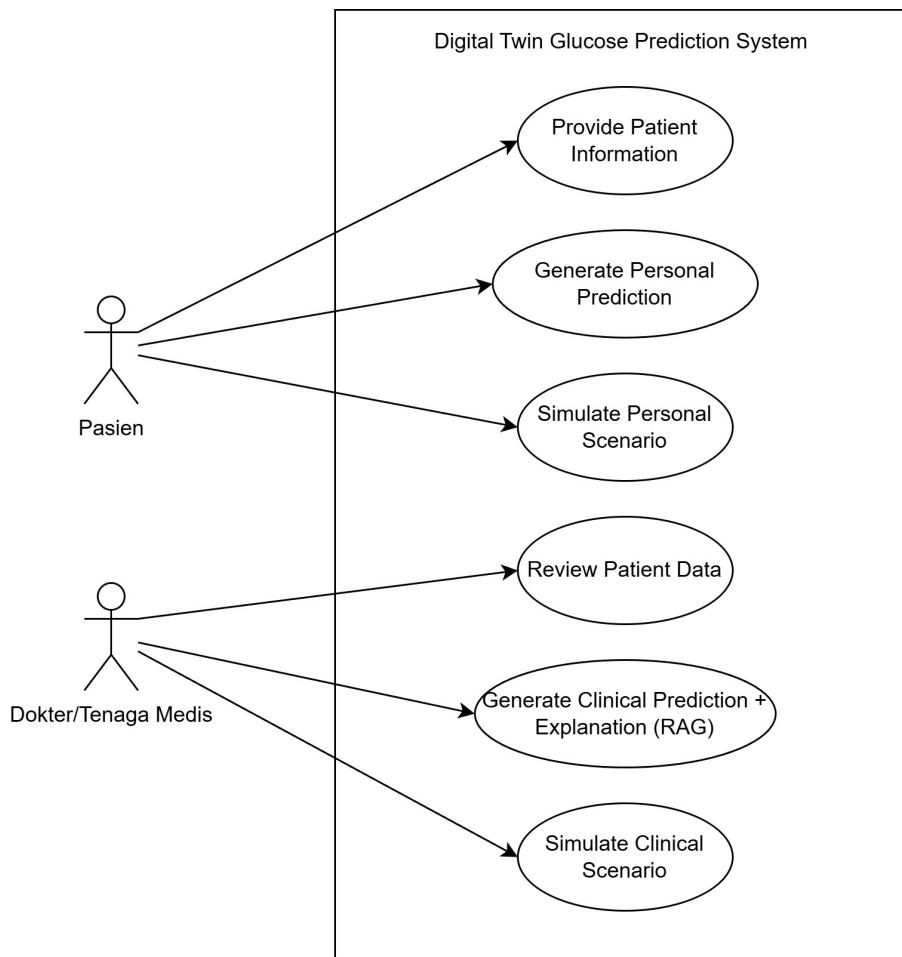
Aspek	Sistem Saat Ini	Sistem Usulan
Aliran data	Satu arah; reaktif	Dua arah; prediktif & adaptif
Representasi pasien	Tidak ada; hanya data episodik	<i>Digital twin</i> sederhana berbasis pola data
Prediksi glukosa	Tidak tersedia	Model ML/DL memprediksi kadar glukosa jangka pendek
Penjelasan	Tidak ada	RAG menyediakan penjelasan berbasis dokumen klinis
Sumber data	Pemeriksaan manual	Dataset simulatif / historis

Perbedaan mendasar terletak pada paradigma sistem: dari reaktif menjadi prediktif-adaptif. Sistem usulan tidak hanya mencatat dan menampilkan data historis, tetapi juga mampu memprediksi kondisi masa depan dan memberikan penjelasan kontekstual berbasis pengetahuan medis.

#### IV.4 Diagram Use Case

Diagram *use case* digunakan untuk menggambarkan keterlibatan aktor dan fungsi utama sistem. Sistem usulan memiliki dua aktor utama: **Pasien** dan **Dokter/Tenaga Medis**, dengan enam *use case* inti yang mencakup seluruh fungsionalitas sistem.

Gambar IV.2 memperlihatkan interaksi antara aktor dengan sistem. Deskripsi masing-masing *use case* adalah sebagai berikut:



Gambar IV.2 Diagram *use case* sistem usulan.

#### IV.4.1 Use Case Aktor Pasien

- UC1 - Provide Patient Information:** Pasien memasukkan data fisiologis seperti riwayat glukosa darah, asupan karbohidrat, dosis insulin, dan aktivitas fisik ke dalam sistem. *Use case* ini memenuhi kebutuhan FR-01 (pengelolaan dataset simulatif) dengan memungkinkan input data yang akan diproses oleh sistem.
- UC2 - Generate Personal Prediction:** Sistem menghasilkan prediksi kadar glukosa darah jangka pendek berdasarkan data yang dimasukkan dan pola historis pasien. *Use case* ini memenuhi FR-02 (prediksi kadar glukosa menggunakan algoritma *machine learning*) dan NFR-02 (akurasi prediksi dengan target RMSE  $\leq 25$  mg/dL).
- UC3 - Simulate Personal Scenario:** Pasien dapat melakukan simulasi "what-if" untuk melihat dampak perubahan pola makan, dosis insulin, atau aktivitas fisik terhadap kadar glukosa prediksi. *Use case* ini memenuhi FR-05 (simulasi

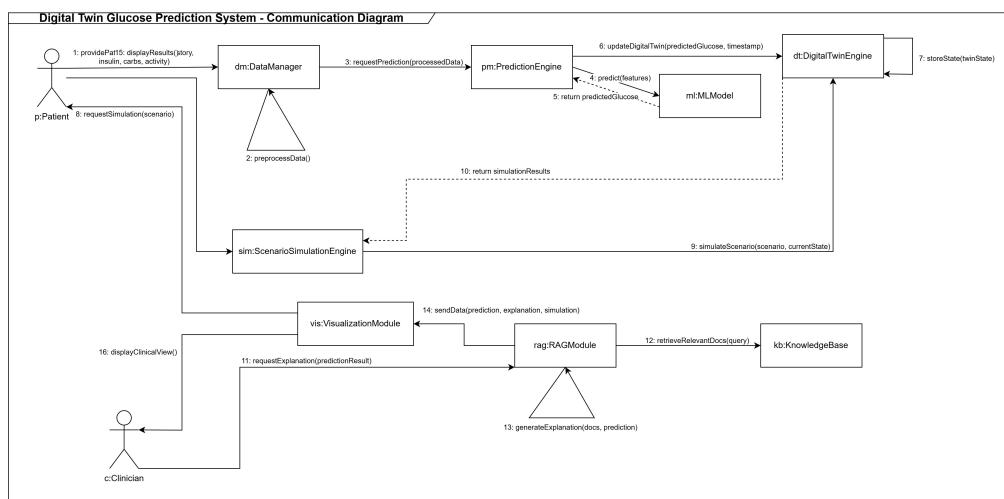
perubahan kadar glukosa sebagai representasi *digital twin*).

#### IV.4.2 Use Case Aktor Dokter/Tenaga Medis

1. **UC4 - Review Patient Data:** Tenaga medis dapat mengakses dan meninjau data historis serta status *digital twin* pasien untuk evaluasi kondisi. *Use case* ini mendukung FR-04 (visualisasi grafik perubahan kadar glukosa) dan memfasilitasi pengambilan keputusan klinis.
2. **UC5 - Generate Clinical Prediction + Explanation (RAG):** Sistem menghasilkan prediksi klinis disertai penjelasan berbasis literatur medis menggunakan mekanisme RAG. *Use case* ini memenuhi FR-06 (modul RAG untuk mencari informasi medis relevan) dan memberikan konteks interpretatif yang mendukung NFR-05 (antarmuka intuitif dengan penjelasan yang mudah dipahami).
3. **UC6 - Simulate Clinical Scenario:** Tenaga medis dapat melakukan simulasi skenario terapi untuk merencanakan intervensi yang optimal bagi pasien. *Use case* ini melengkapi FR-05 dengan memberikan perspektif klinis pada simulasi *digital twin*.

#### IV.5 Communication Diagram

*Communication diagram* menggambarkan interaksi dinamis antara komponen-komponen sistem dalam bentuk pesan yang saling bertukar. Diagram ini menunjukkan alur eksusi dari perspektif kolaborasi objek dan melengkapi pemahaman yang diberikan oleh diagram *use case*.



Gambar IV.3 *Communication diagram* sistem prediksi glukosa berbasis *Digital Twin*.

Gambar IV.3 memperlihatkan 16 pesan yang saling bertukar antara komponen sistem. Alur utama dapat dijelaskan sebagai berikut:

1. **Data Input Flow (Message 1-2):** Pasien memasukkan data fisiologis ke "DataManager", yang kemudian melakukan preprocessing data. Alur ini mengimplementasikan FR-01 dengan memastikan data terbaca dan tervalidasi dengan baik.
2. **Prediction Flow (Message 3-6):** Data yang telah diproses dikirim ke "PredictionEngine", yang memanggil "MLModel" untuk menghasilkan prediksi. Hasil prediksi kemudian digunakan untuk memperbarui "DigitalTwinEngine". Alur ini mengimplementasikan FR-02 dan mendukung pencapaian NFR-02 (akurasi prediksi).
3. **State Management (Message 7):** "DigitalTwinEngine" menyimpan status terkini dari representasi virtual pasien, memastikan konsistensi data untuk simulasi dan prediksi berikutnya.
4. **Simulation Flow (Message 8-10):** Pasien dapat meminta simulasi skenario melalui "ScenarioSimulationEngine", yang berkomunikasi dengan "DigitalTwinEngine" untuk menghasilkan hasil simulasi. Alur ini mengimplementasikan FR-05.
5. **Explanation Flow (Message 11-13):** Tenaga medis dapat meminta penjelasan klinis melalui "RAGModule", yang mengambil dokumen relevan dari "KnowledgeBase" dan menghasilkan penjelasan berbasis konteks. Alur ini mengimplementasikan FR-06 dan mendukung NFR-05 (antarmuka yang mudah dipahami).
6. **Visualization Flow (Message 14-16):** "VisualizationModule" mengintegrasikan hasil prediksi, simulasi, dan penjelasan untuk ditampilkan kepada pasien dan tenaga medis. Alur ini mengimplementasikan FR-04 dengan menyediakan visualisasi grafis yang informatif.

Diagram ini menunjukkan bahwa sistem beroperasi secara modular, di mana setiap komponen memiliki tanggung jawab yang jelas namun tetap terintegrasi melalui pertukaran pesan yang terstruktur. Modularitas ini mendukung NFR-01 (efisiensi komputasi pada sumber daya terbatas) dan NFR-03 (penggunaan dataset simulatif tanpa biaya lisensi).

#### IV.6 Pemetaan Use Case terhadap FR dan NFR

Bagian ini memberikan keterkaitan antara *use case* yang telah dirancang dan *functional requirements* (FR) serta *non-functional requirements* (NFR) dari sistem. Pe-

metaan ini memastikan bahwa setiap kebutuhan sistem tercakup dalam desain *use case*.

Tabel IV.2 Pemetaan Use Case terhadap Functional Requirements (FR) dan Non-Functional Requirements (NFR).

<b>Use Case</b>	<b>Functional Requirements (FR)</b>	<b>Non-Functional Requirements (NFR)</b>
UC1	FR-01	NFR-03, NFR-04
UC2	FR-02, FR-03	NFR-01, NFR-02
UC3	FR-05	NFR-01, NFR-05
UC4	FR-04	NFR-05, NFR-06
UC5	FR-02, FR-06	NFR-02, NFR-05
UC6	FR-05	NFR-01, NFR-06

Tabel IV.2 menunjukkan bahwa seluruh kebutuhan fungsional dan nonfungsional telah dipetakan ke dalam *use case* yang dirancang.

## BAB V

### Rencana Selanjutnya

#### V.1 Rencana Implementasi

Rencana implementasi mencakup tahapan teknis yang diperlukan untuk membangun prototipe sistem prediksi glukosa berbasis Digital Twin dan Retrieval-Augmented Generation (RAG). Secara umum, tahapan implementasi meliputi:

##### V.1.1 Persiapan Lingkungan dan Perangkat Pengembangan

Lingkungan pengembangan menggunakan perangkat keras utama berupa **Asus Vivobook Pro 14 OLED** dengan spesifikasi:

- Prosesor: AMD Ryzen 7 5800H / Intel Core i5/i7 (varian seri)
- GPU: NVIDIA GeForce RTX 3050 / 3050Ti
- RAM: 16 GB
- Storage: 512 GB SSD NVMe
- Sistem Operasi: Windows 11
- Lingkungan kerja: VS Code, Python Virtual Environment

Perangkat tersebut memadai untuk kebutuhan pelatihan model machine learning skala menengah, eksperimen deep learning dasar, serta pemrosesan data.

##### V.1.2 Persiapan Data

Tahap ini mencakup:

- Penentuan format data input dan struktur variabel.
- Eksplorasi karakteristik data, identifikasi missing values, dan pemeriksaan distribusi.
- Proses pembersihan data (cleaning) dan normalisasi.
- Penyusunan sequence atau time-window untuk mendukung pemodelan deret waktu.

### **V.1.3 Pengembangan Model Prediksi**

Tahap pemodelan mencakup:

1. Pembuatan model baseline (misal: Random Forest, Support Vector Regression, MLP).
2. Pengembangan model berbasis *deep learning* seperti LSTM atau GRU.
3. Tuning hiperparameter untuk meningkatkan performa model.
4. Pemilihan model terbaik berdasarkan metrik evaluasi.

### **V.1.4 Pembangunan Digital Twin**

Digital Twin digunakan sebagai representasi keadaan pasien secara virtual. Kegiatan yang dilakukan antara lain:

- Perancangan state digital yang mencerminkan kondisi glukosa.
- Implementasi mekanisme pembaruan state berdasarkan prediksi model.
- Simulasi skenario perubahan variabel seperti insulin, karbohidrat, dan aktivitas.

### **V.1.5 Integrasi Retrieval-Augmented Generation (RAG)**

Tahapan ini meliputi:

- Penyusunan basis pengetahuan eksternal.
- Implementasi *embedding* dan *vector store*.
- Pengembangan modul *retriever* dan *generator*.
- Integrasi modul RAG dengan Digital Twin untuk memberikan penjelasan berbasis bukti.

### **V.1.6 Pengembangan Antarmuka dan Visualisasi**

Antarmuka sederhana akan dikembangkan untuk menampilkan:

- Grafik glukosa aktual dan hasil prediksi.
- Simulasi Digital Twin.
- Penjelasan prediktif yang dihasilkan oleh RAG.

### **V.1.7 Dokumentasi dan Penyusunan Laporan**

Seluruh proses, hasil eksperimen, serta evaluasi sistem akan didokumentasikan untuk penyusunan laporan Tugas Akhir.

## **V.2 Desain Pengujian dan Evaluasi**

Pengujian sistem dilakukan melalui beberapa tahap:

### **V.2.1 Verifikasi Sistem**

Verifikasi mencakup:

- Konsistensi preprocessing.
- Stabilitas model selama pelatihan.
- Kesesuaian pembaruan state pada Digital Twin.
- Relevansi dokumen hasil retrieval pada modul RAG.

### **V.2.2 Validasi Model Prediksi**

Evaluasi dilakukan menggunakan metrik:

- Root Mean Square Error (RMSE)
- Mean Absolute Error (MAE)
- Clarke Error Grid Analysis

### **V.2.3 Evaluasi Integrasi Digital Twin dan RAG**

Evaluasi dilakukan terhadap:

- Konsistensi pembaruan state Digital Twin.
- Akurasi konteks penjelasan yang diberikan RAG.
- Keterbacaan insight bagi pengguna.

### V.3 Analisis Risiko dan Mitigasi

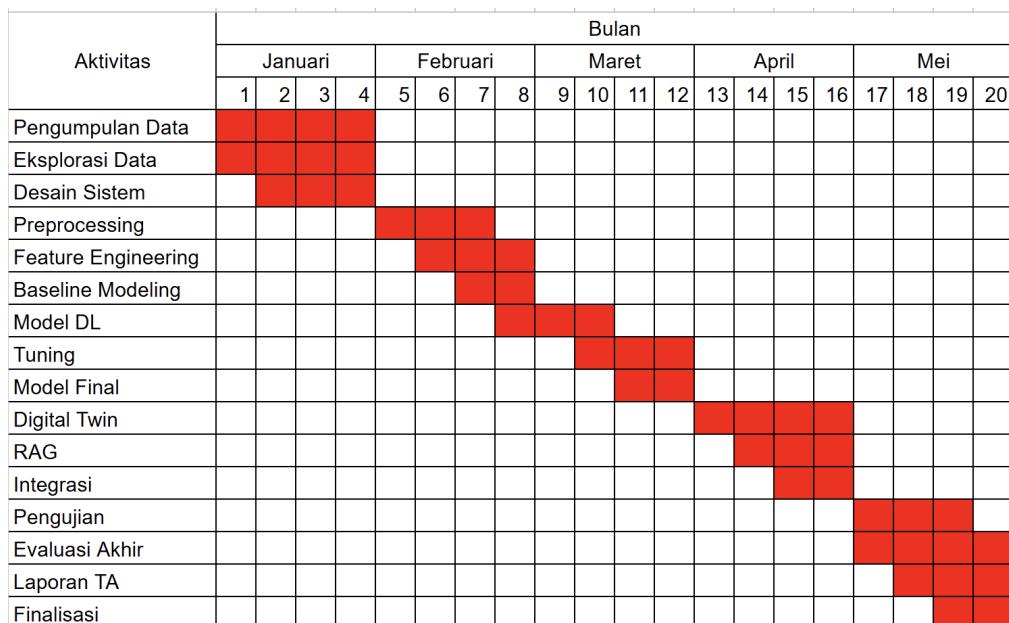
Tabel V.1 Analisis Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Kualitas data tidak konsisten	Model tidak stabil	Pembersihan data, normalisasi, pemeriksaan manual
Overfitting	Generalisasi buruk	Regularisasi, dropout, early stopping
Keterbatasan perangkat komputasi	Waktu pelatihan lebih lama	Penggunaan batch kecil, optimasi model, opsi GPU cloud
RAG menghasilkan insight tidak relevan	Penjelasan menyesatkan	Perbaikan knowledge base, evaluasi retrieval
Integrasi DT kompleks	Hambatan implementasi	Pendekatan bertahap, mulai dari versi minimal

### V.4 Timeline Pengerjaan

Timeline disusun berdasarkan periode Januari–Mei 2026, dengan pembagian per minggu. Format tabel mengikuti struktur jadwal pada laporan kerja praktik sebelumnya.

Tabel Timeline Pelaksanaan Tugas Akhir (Januari–Mei 2026)



Gambar V.1 Timeline Pelaksanaan Tugas Akhir (Januari–Mei 2026)

## DAFTAR PUSTAKA

- Abodunrin, O., T. Akande, dan G. Osagbemi. 2020. “Awareness and Perception Toward Electronic Health Records Among Healthcare Professionals in a Developing Country”. *Health Information Management Journal* 49 (2-3): 98–107.
- Aisyah, D. N., A. H. Setiawan, A. F. Lokopessy, N. Faradiba, S. Setiaji, L. Manikam, dan Z. Kozlakidis. 2024. “The Information and Communication Technology Maturity Assessment at Primary Health Care Services Across 9 Provinces in Indonesia: Evaluation Study”. *JMIR Medical Informatics* 12:e55959.
- Alkaff, F. F., A. A. Suwantika, R. Abdulah, dan K. Lestari. 2021. “Challenges and Opportunities in the Management of Diabetes Mellitus in Indonesia: A Systematic Review”. *Journal of Global Health Science* 3 (2): e25. <https://doi.org/10.35500/jghs.2021.3.e25>.
- Battelino, T., T. Danne, R. M. Bergenstal, dkk. 2019. “Clinical Targets for Continuous Glucose Monitoring Data Interpretation”. *Diabetes Care* 42 (8): 1593–1603.
- Borgeaud, Sebastian, Arthur Mensch, Jordan Hoffmann, Trevor Cai, Eliza Rutherford, Katie Millican, George van den Driessche, dkk. 2022. “Improving language models by retrieving from trillions of tokens”. *Nature* 603 (7902): 587–593. <https://doi.org/10.1038/s41586-022-04587-z>.
- Bruynseels, K., F. Santoni de Sio, dan J. van den Hoven. 2018. “Digital Twins in Health Care: Ethical Implications of an Emerging Engineering Paradigm”. *Frontiers in Genetics* 9:31.
- Cappon, G., A. Facchinetti, dan G. Sparacino. 2024. “Digital Twins in Type 1 Diabetes: A Systematic Review”. *npj Digital Medicine* 7 (1): 55–68.

- Ghimire, Saurav, Xuefeng Chen, Helene Schenck, dkk. 2024. “Deep learning for blood glucose level prediction: How well do models generalize across different data sets?” *npj Digital Medicine* 7 (1): 166. <https://doi.org/10.1038/s41746-024-01021-0>. <https://www.nature.com/articles/s41746-024-01021-0>.
- Grieves, Michael, dan John Vickers. 2017. “Digital Twin: Mitigating Unpredictable, Undesirable Emergent Behavior in Complex Systems”. Dalam *Transdisciplinary Perspectives on Complex Systems*, 85–113. Cham, Switzerland: Springer. [https://doi.org/10.1007/978-3-319-38756-7\\_4](https://doi.org/10.1007/978-3-319-38756-7_4).
- Harahap, N. C., P. W. Handayani, dan A. N. Hidayanto. 2023. “Integrated Personal Health Record in Indonesia: Design Science Research Study”. *JMIR Medical Informatics* 11:e44784.
- Harahap, N. C., P. W. Handayani, A. N. Hidayanto, dan I. Budi. 2024. “An Exploratory Study of Electronic Medical Record Implementation and Record-keeping Culture: The Case of Hospitals in Indonesia”. *BMC Health Services Research* 24:199.
- International Diabetes Federation. 2024. *IDF Diabetes Atlas 11th Edition*. Technical report. Brussels: International Diabetes Federation.
- Kementerian Kesehatan Republik Indonesia. 2019. *Laporan Nasional Riset Kesehatan Dasar (Risksdas) 2018*. Menunjukkan sebagian besar kasus diabetes di Indonesia belum terdiagnosis. Jakarta, Indonesia: Badan Penelitian dan Pengembangan Kesehatan, Kementerian Kesehatan RI. <https://www.litbang.kemkes.go.id/laporan-riset-kesehatan-dasar-risksdas-2018/>.
- Knowledge Sourcing Intelligence. 2020. *Indonesia Diabetes Devices (SMBG & POCT, CGM, Insulin Pens & Pumps) Market Outlook to 2023*. Technical report.
- Lewis, Patrick, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, dkk. 2020. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *Advances in Neural Information Processing Systems (NeurIPS)* 33:9459–9474. <https://arxiv.org/abs/2005.11401>.
- Li, Xiaoyu, Yifan Zhang, dan Qiang Zhao. 2022. “Time-Series Deep Learning Models for Glucose Prediction: A Comparative Study”. *IEEE Journal of Biomedical and Health Informatics* 26 (8): 4150–4162.

- Rad, F. S., R. Hendawi, X. Yang, dan J. Li. 2024. “Personalized Diabetes Management with Digital Twins: A Patient-Centric Knowledge Graph Approach”. *Journal of Personalized Medicine* 14 (4): 359.
- Ramadaniati, H. U., Y. Anggriani, M. Lepeska, D. Beran, dan M. Ewen. 2024. “Availability, Price and Affordability of Insulin, Delivery Devices and Self-Monitoring Blood Glucose Devices in Indonesia”. *PLOS ONE* 19 (10): e0309350.
- Woldaregay, A. Z., E. Årsand, S. Walderhaug, dkk. 2019. “Data-Driven Modeling and Prediction of Blood Glucose Dynamics: Machine Learning Applications in Type 1 Diabetes”. *Artificial Intelligence in Medicine* 98:109–134.
- World Health Organization. 2023. *Global Report on Diabetes*. Technical report. Geneva: World Health Organization.
- Zhang, X., dkk. 2024. “A Framework Towards Digital Twins for Type 2 Diabetes”. *Frontiers in Digital Health* 6:1336050.